Technische Hochschule Nürnberg

Machine Learning

Basics

Prof. Dr. Tobias Bocklet

Warum Maschinelles Lernen?

Heutige Lerninhalte

- Was versteht man unter Maschinellem Lernen
- Wichtige Begriffe im Bereich ML
  - Überwachtes vs. Unüberwachtes Lernen
  - Klassifikation vs. Regression
  - Batch vs. Online Lernen
  - Overfitting/Underfitting
  - Generalisierung
- Instanzbasiertes vs. Modellbasiertes Lernen

Bekannte ML Anwendungen

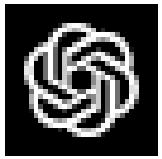






amazonadvertising







Hey Siri



Google Lens

From: cheapsales@buystufffromme.com
To: ang@cs.stanford.edu
Subject: Buy now!

Deal of the week! Buy now!
Rolex w4tchs - $100
Medicine (any kind) - $50
Also low cost M0rgages
available.

Spam

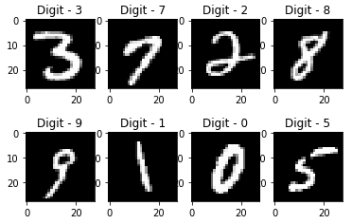
From: Alfred Ng
To: ang@cs.stanford.edu
Subject: Christmas dates?

Hey Andrew,
Was talking to Mom about plans
for Xmas. When do you get off
work. Meet Dec 22?
Alf

Non-spam







Speech Processing

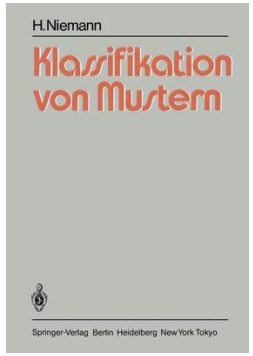


Generative Systeme



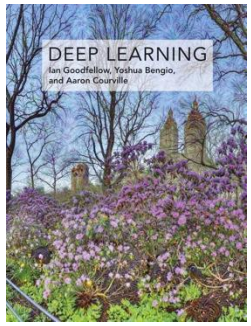
Literatur

- Heinrich Niemann: Klassifikation von Mustern, Springer Verlag, 1983 zweite Auflage, 2013, online: http://aiweb.techfak.uni-bielefeld.de/files/Klassifikation-von-Mustern.pdf

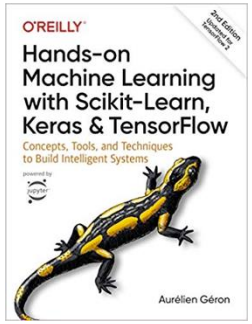


- Duda, Hart, Storck: Pattern Classification, Wiley, 2000

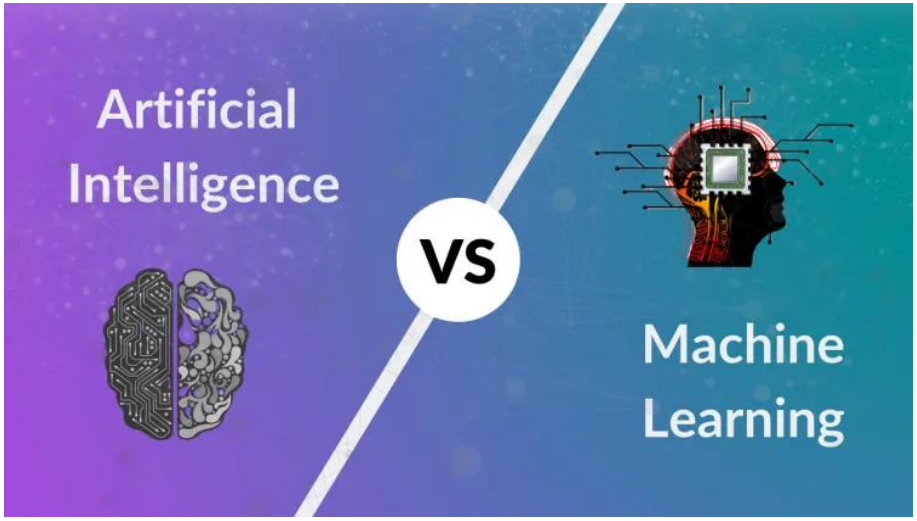
- Ian Goodfellow et. al: Deep Learning, MIT Press, 2016 http://www.deeplearningbook.org/



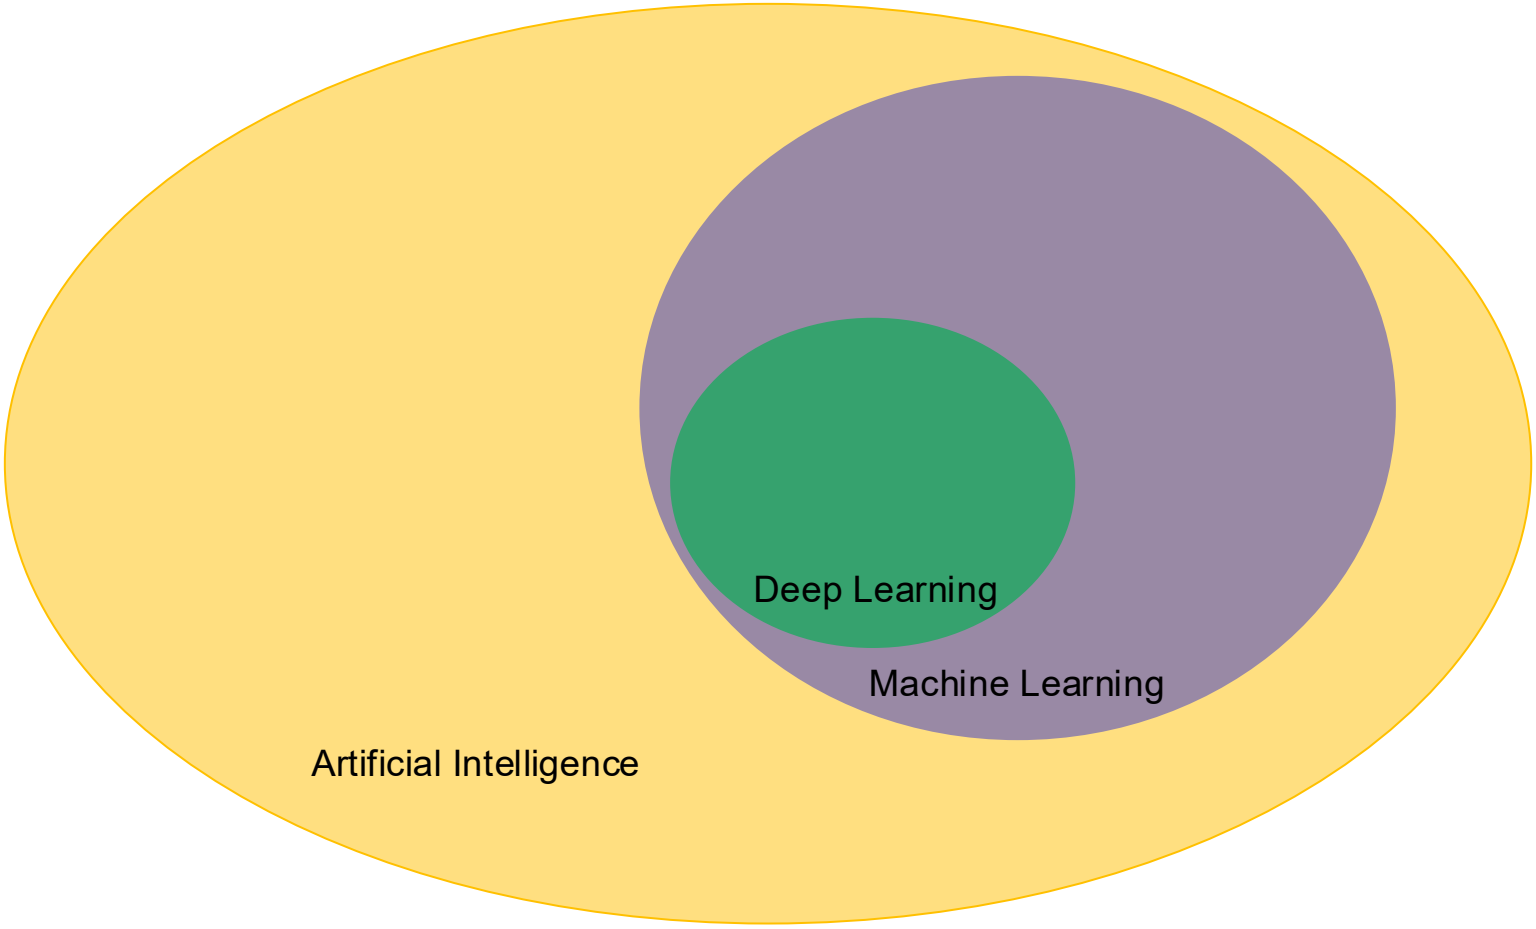
- **Aurelien Geron: Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd Edition, O'Reilly, 2022**



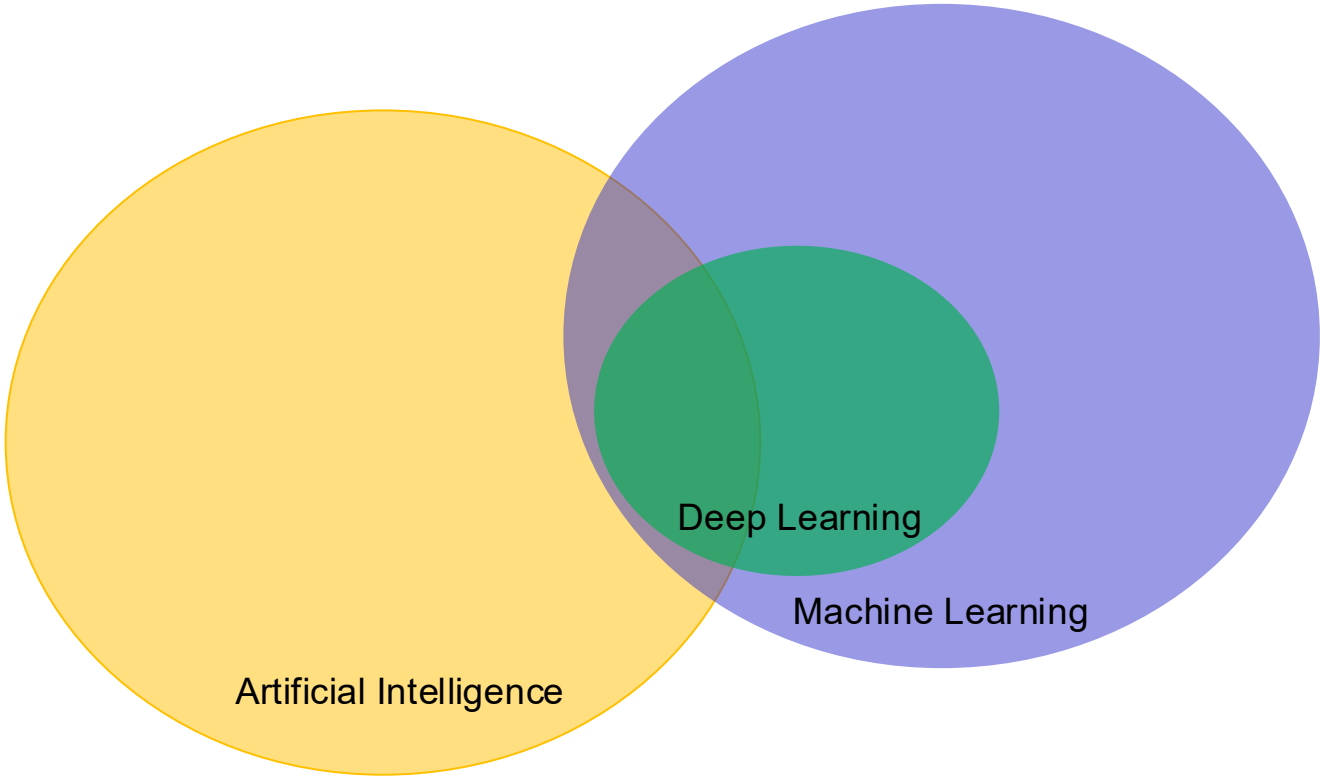
AI vs. ML



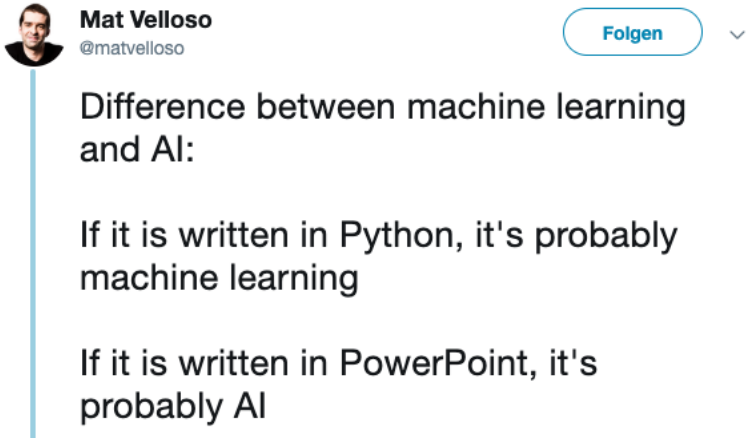
AI vs. ML



AI vs. ML



AI vs. ML


Mat Velloso
@matvelloso
Folgen
Difference between machine learning and AI:
If it is written in Python, it's probably machine learning
If it is written in PowerPoint, it's probably AI

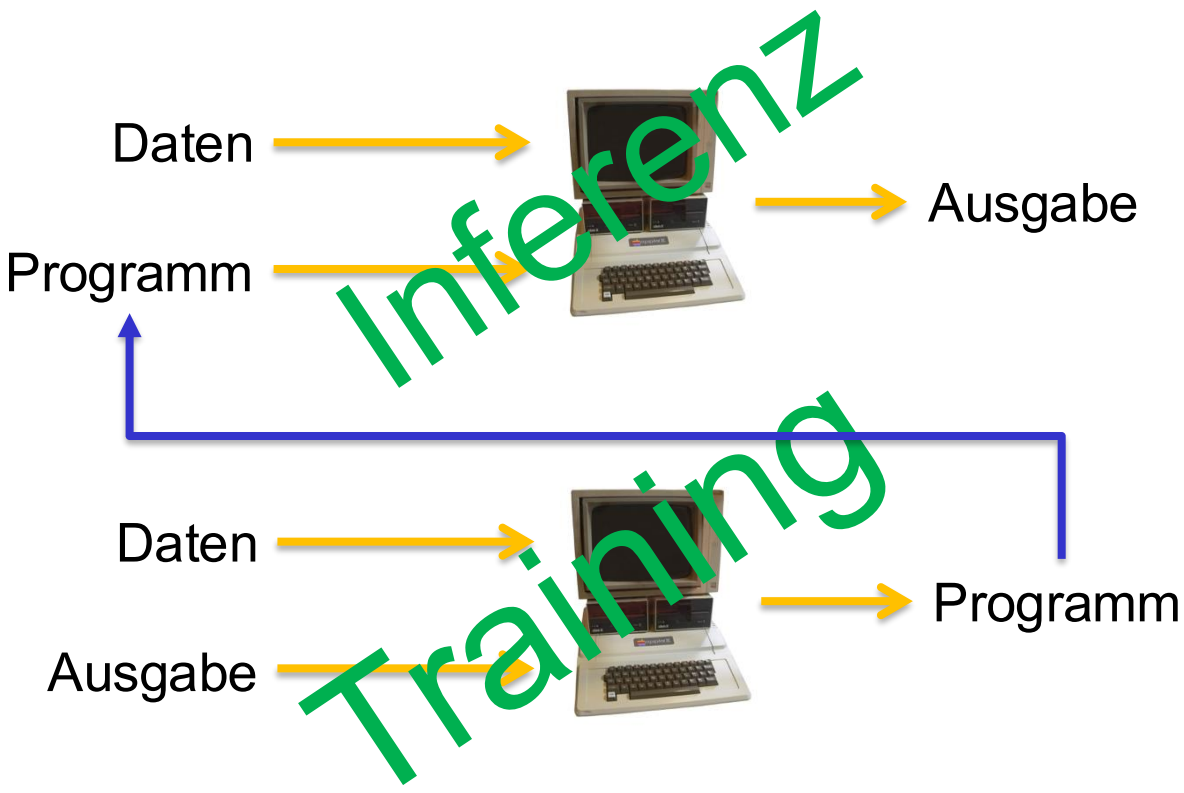
Was ist maschinelles Lernen

Machine learning is the field of study that gives computers the ability to learn without being explicitly programmed.

-- *Arthur Samuel, 1959*



Programmieren vs. Maschinelles Lernen



Formellere Definition von ML

A computer program is said to learn from experience E with respect to some task T and some performance measure P, if its performance on T as measured by P, improves with experience E.

-- *Tom Mitchell, 1997*

Wie würde man einen Spam-filter programmieren?

From: cheapsales@buystufffromme.com
To: ang@cs.stanford.edu
Subject: Buy now!

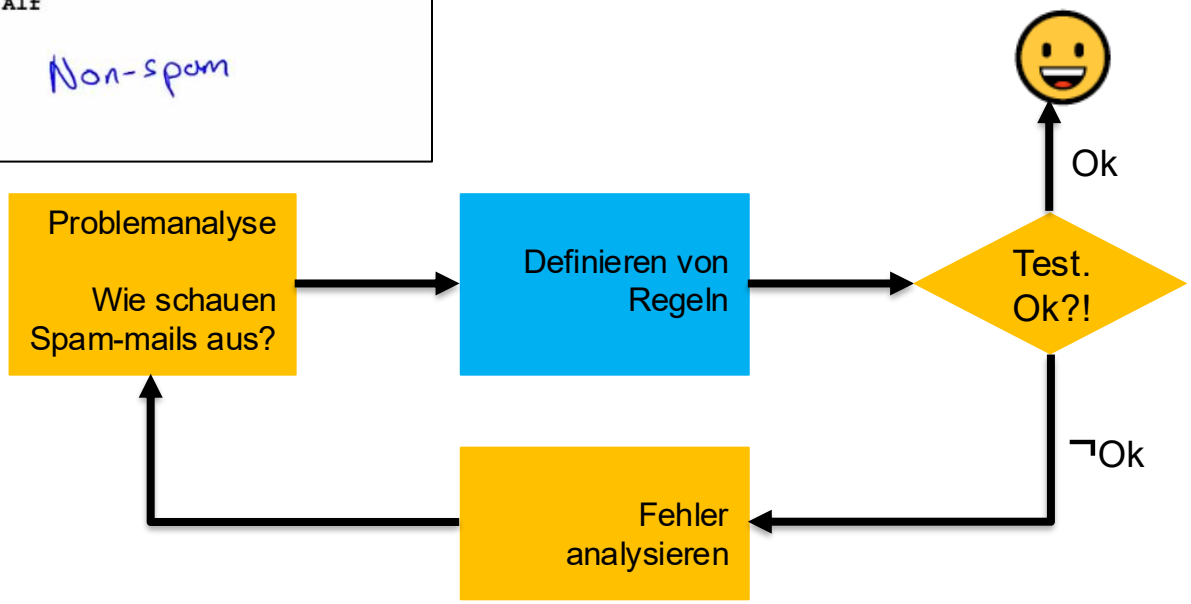
Deal of the week! Buy now!
Rolex w4tchs - $100
Medicine (any kind) - $50
Also low cost M0rgages
available.

Spam

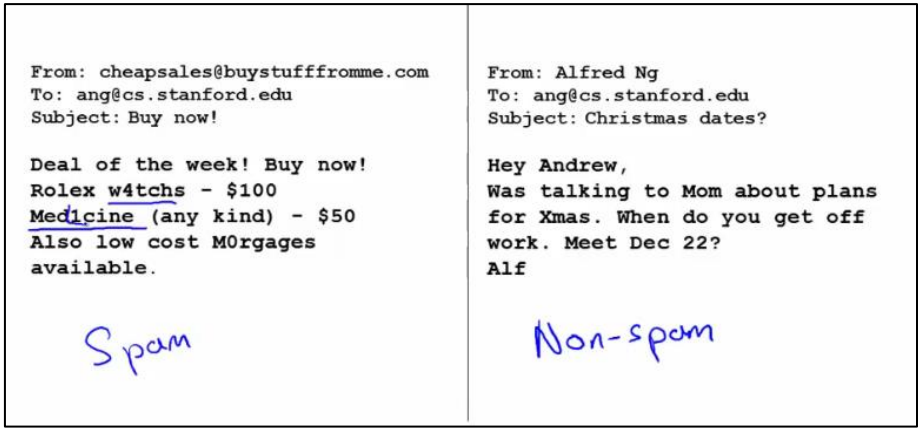
From: Alfred Ng
To: ang@cs.stanford.edu
Subject: Christmas dates?

Hey Andrew,
Was talking to Mom about plans
for Xmas. When do you get off
work. Meet Dec 22?
Alf

Non-spam



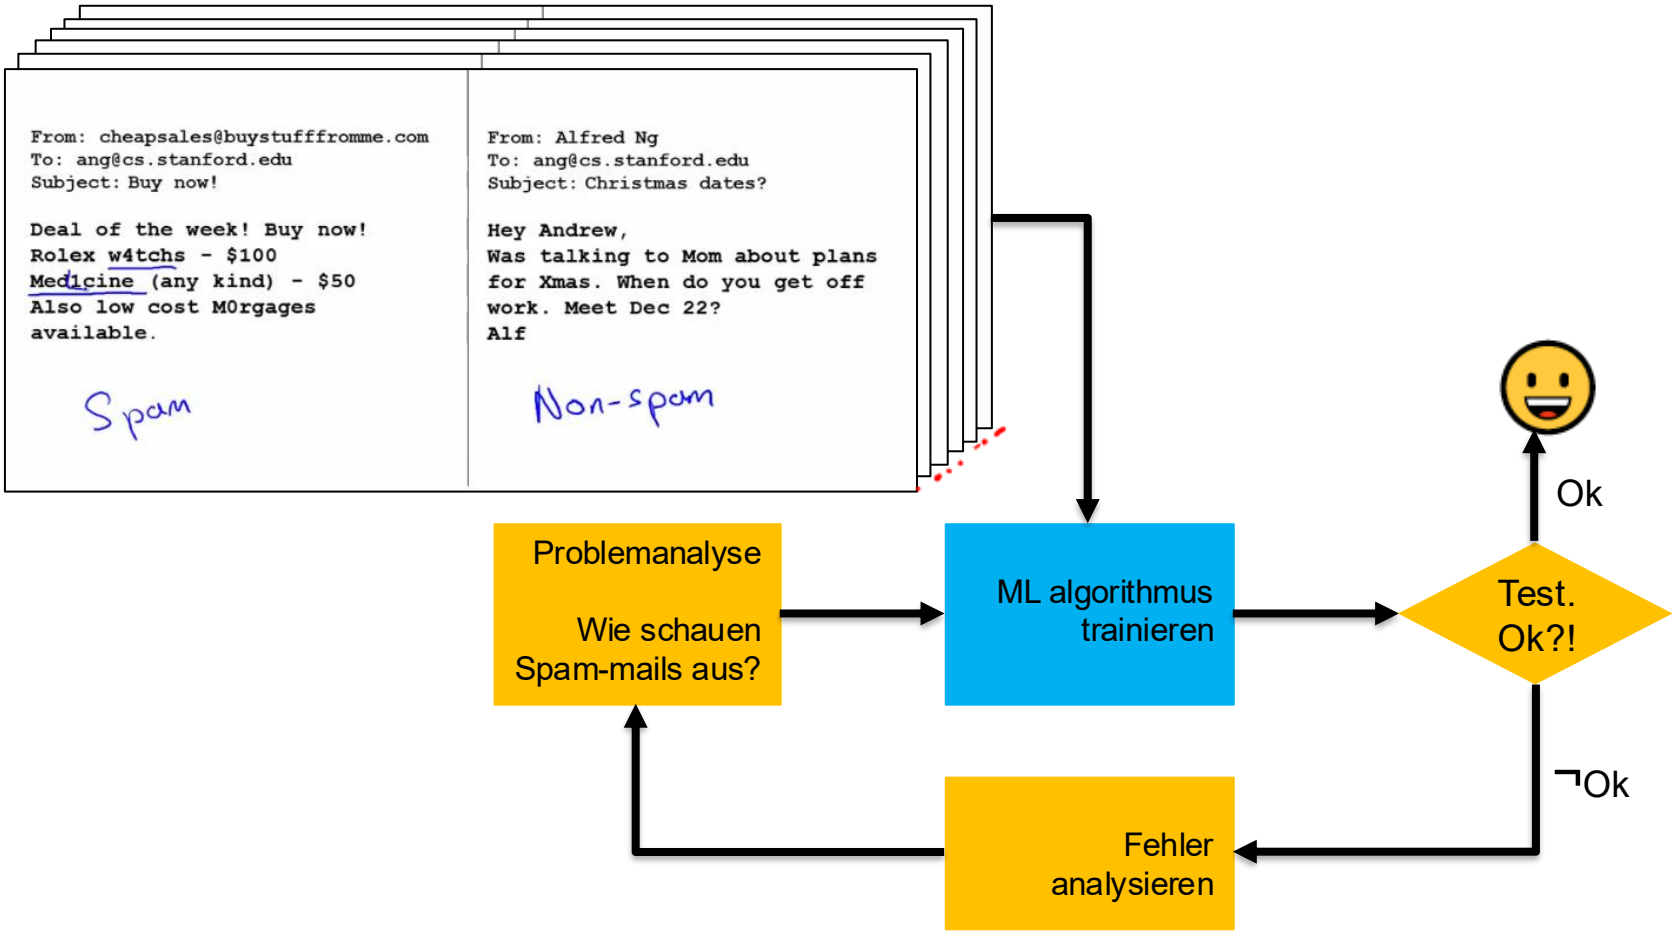
Wie würde man einen Spam-filter programmieren?



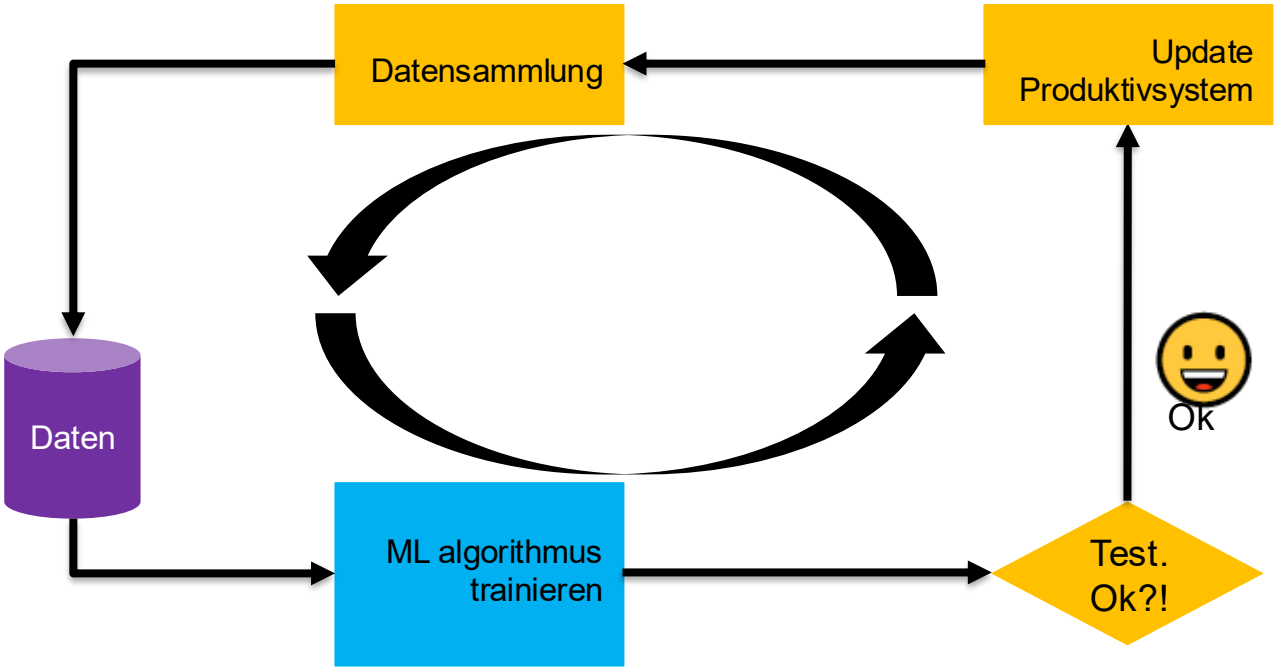
A computer program is said to learn from experience E with respect to some task T and some performance measure P, if its performance on T as measured by P, improves with experience E.

-- Tom Mitchell, 1997

Spam-filter mit Machine Learning Ansatz



Spam-filter mit Machine Learning Ansatz



ML ist sinnvoll zur …

- Lösung von Problemen bei denen eine Liste von händisch erzeugten Regeln verwendet werden könnte
- Anpassung (Adaption) an sich verändernde Daten
- Lösung von Problemen mit hohem Grad an Variabilität
  - Sprache (Akzent, Hintergrundgeräusche, Stimm/Sprech-Veriabilität)
  - Text
  - Bilder
- Datenanalyse

Wie lassen sich ML-System einordnen?

- Wie bzw. mit welchen Daten wird gelernt?
  - Überwacht vs. Unüberwacht (Supervised vs. Unsupervised)
  - Semi-supervised
  - Reinforcement Learning
- Was soll erkannt werden?
  - Kategorien: Klassifikation
  - Kontinuierliche Werte: Regression
  - Detektion
- Batch vs. Online Lernen
- Instanz-basiertes vs. Modell-basiertes Lernen

Lernen aus Daten

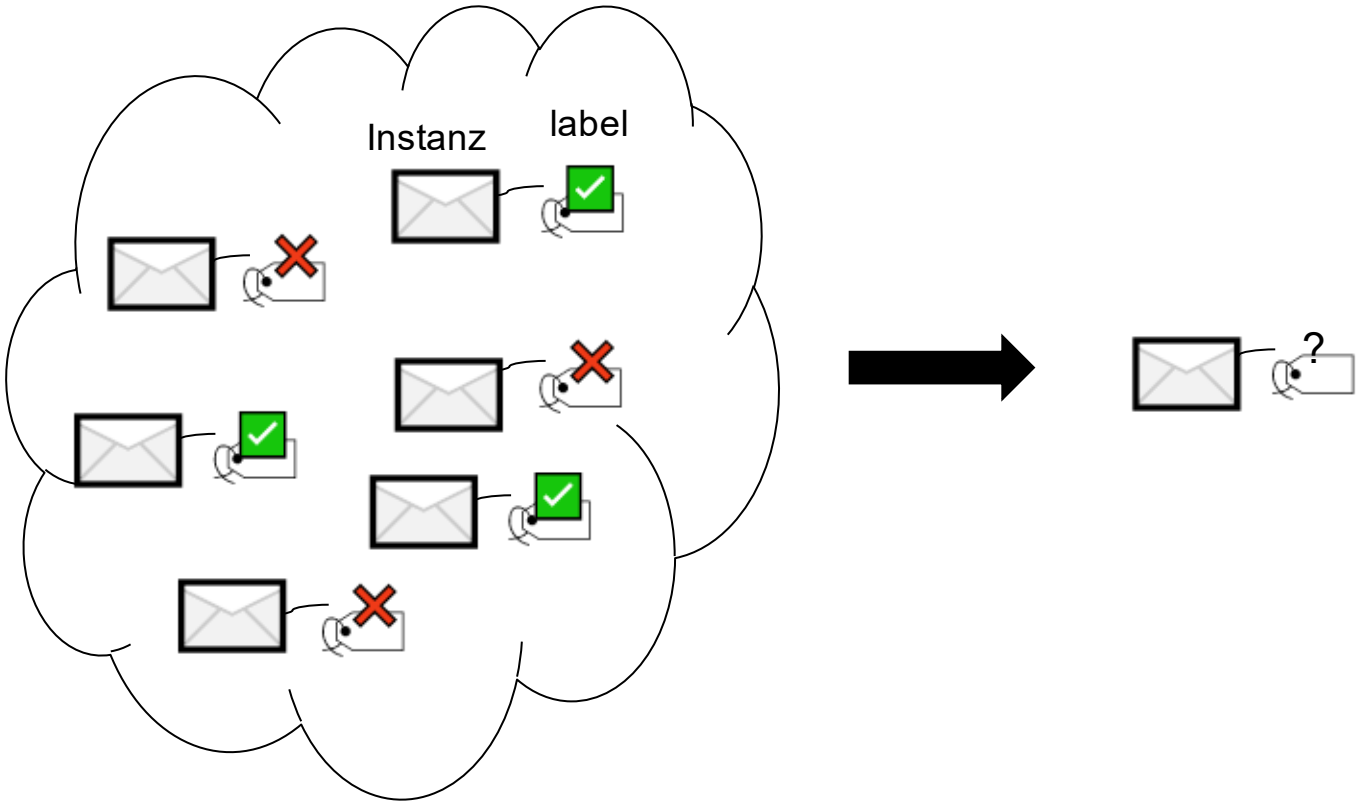
- ML Systeme arbeiten datengetrieben → wir benötigen Daten zum Training
- Daten können Infos zugewiesen sein (sogenannte labels)
- Erzeugen von labels teuer und zeitaufwendig
  (Sprachdaten ca. 300Euro/verschrifteter Stunde)
- Beispiele von gelabelten Datensätzen:
  - Bilder von mit labels über Inhalt
  - Sprachaufnahmen + Info über sprechende Person (m/w, Alter, Sprache, Akzent)
  - E-Mails mit labels: Spam ja/nein

Überwacht vs. Unüberwacht

- Überwacht:
  - Gelabelte Daten liegen vor
  - Mit diesen wird ein System trainiert (wir geben dem System das Label als Info)
  - Beschreibung auf Folien 22 - 29

- Unüberwacht:
  - Keine Labels zu den existierenden Daten
  - Durchführung einer Datenanalyse, bzw. Clustering
  - Interpretation der Daten
  - Beschreibung auf Folien 30 - 35

Überwachtes Lernen



Überwachtes Lernen

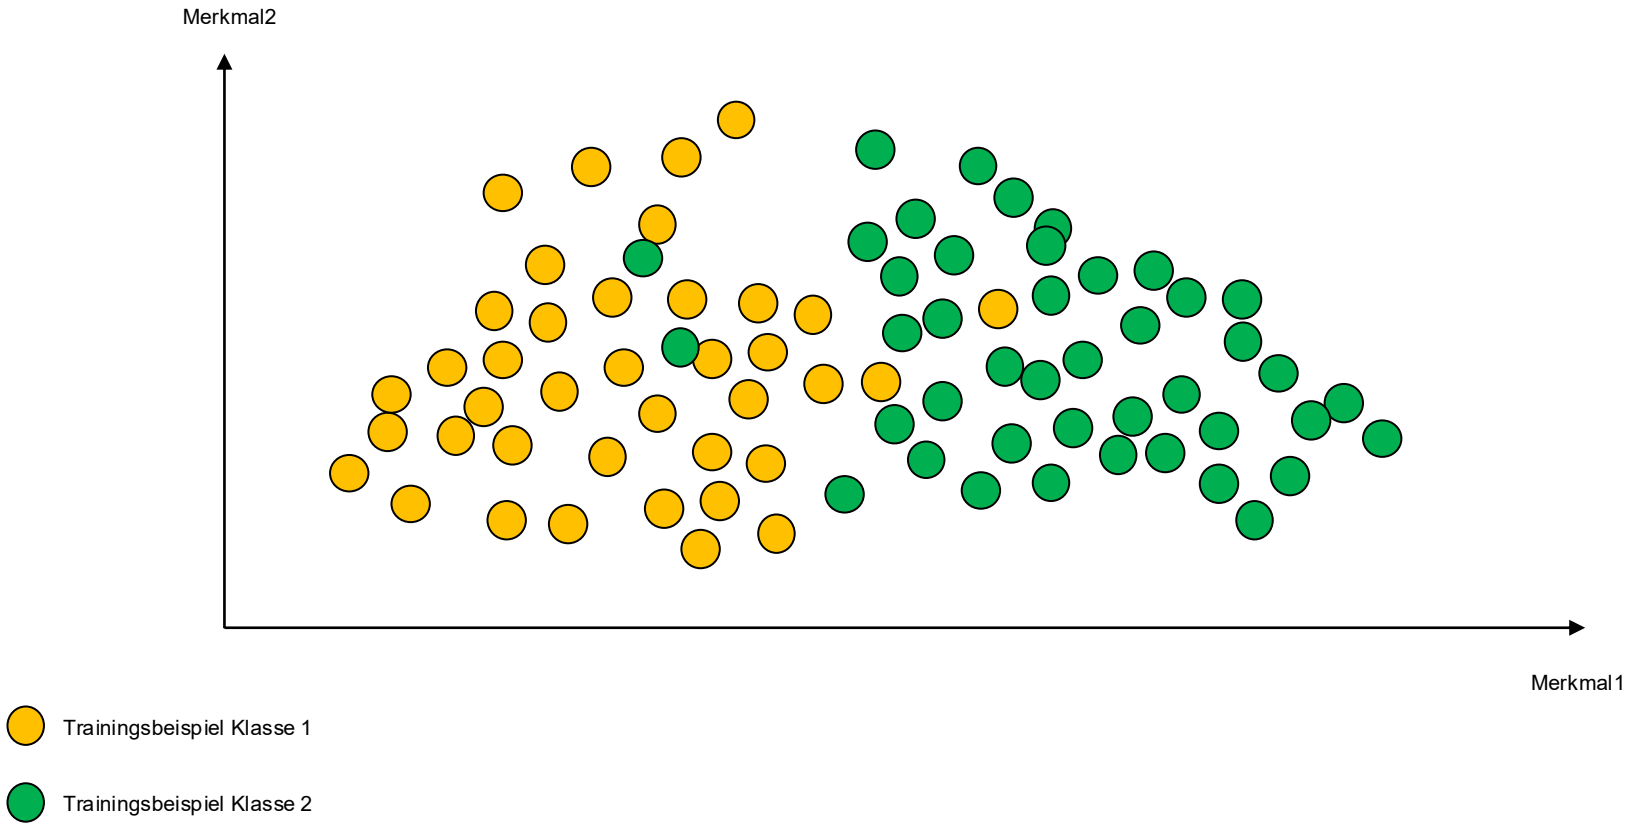
- Bekannte Klassifikatoren
  - Perceptron
  - k-Nearest-Neighbor
  - Logistic Regression
  - Support Vector Machines (SVMs)
  - Gaussian Mixture Models (GMMs)
  - Neuronale Netze
  - Decision Trees and Random Forests

Klassifikation vs. Regression

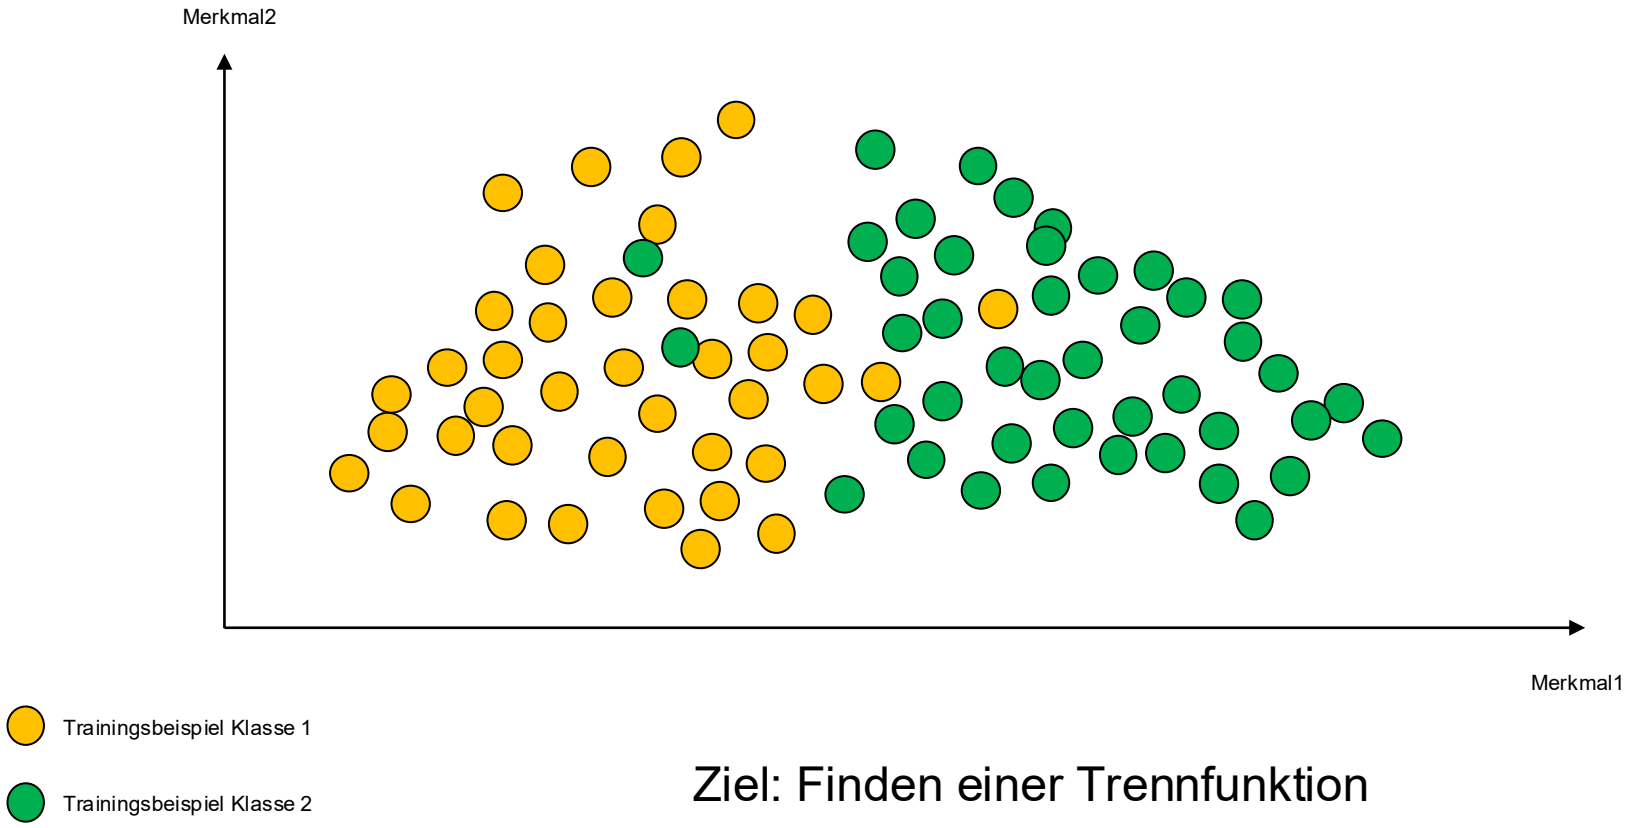
- Klassifikation:
  - Labels der Trainingsdaten sind fixe Kategorien bzw. Klassen
  - 2-Klassenprobleme (z.B. Spam vs. Nicht-Spam)
  - Mehrklassen-Probleme (z.B. Ziffernerkennung)
  - Ziel: Trennen der Klassen

- Regression:
  - Vorhersage eines numerischen Wertes
  - Beispiele:
    - Vorhersage des Gehalts einer Person anhand unterschiedlicher Merkmale
    - Wert eines Autos

Klassifikation: 2 Klassenproblem

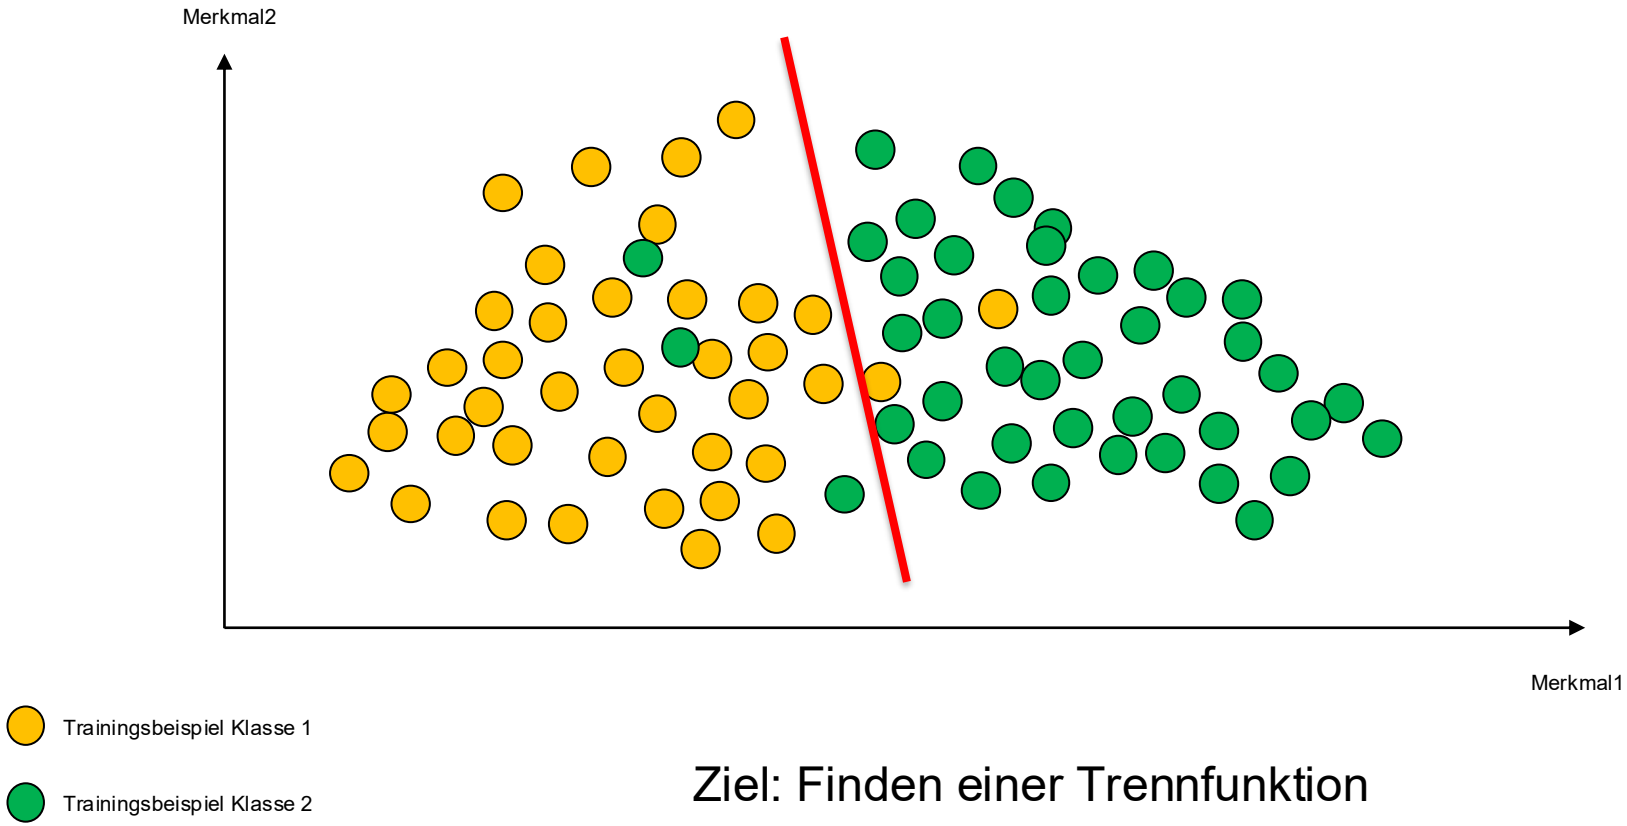


Klassifikation: 2 Klassenproblem



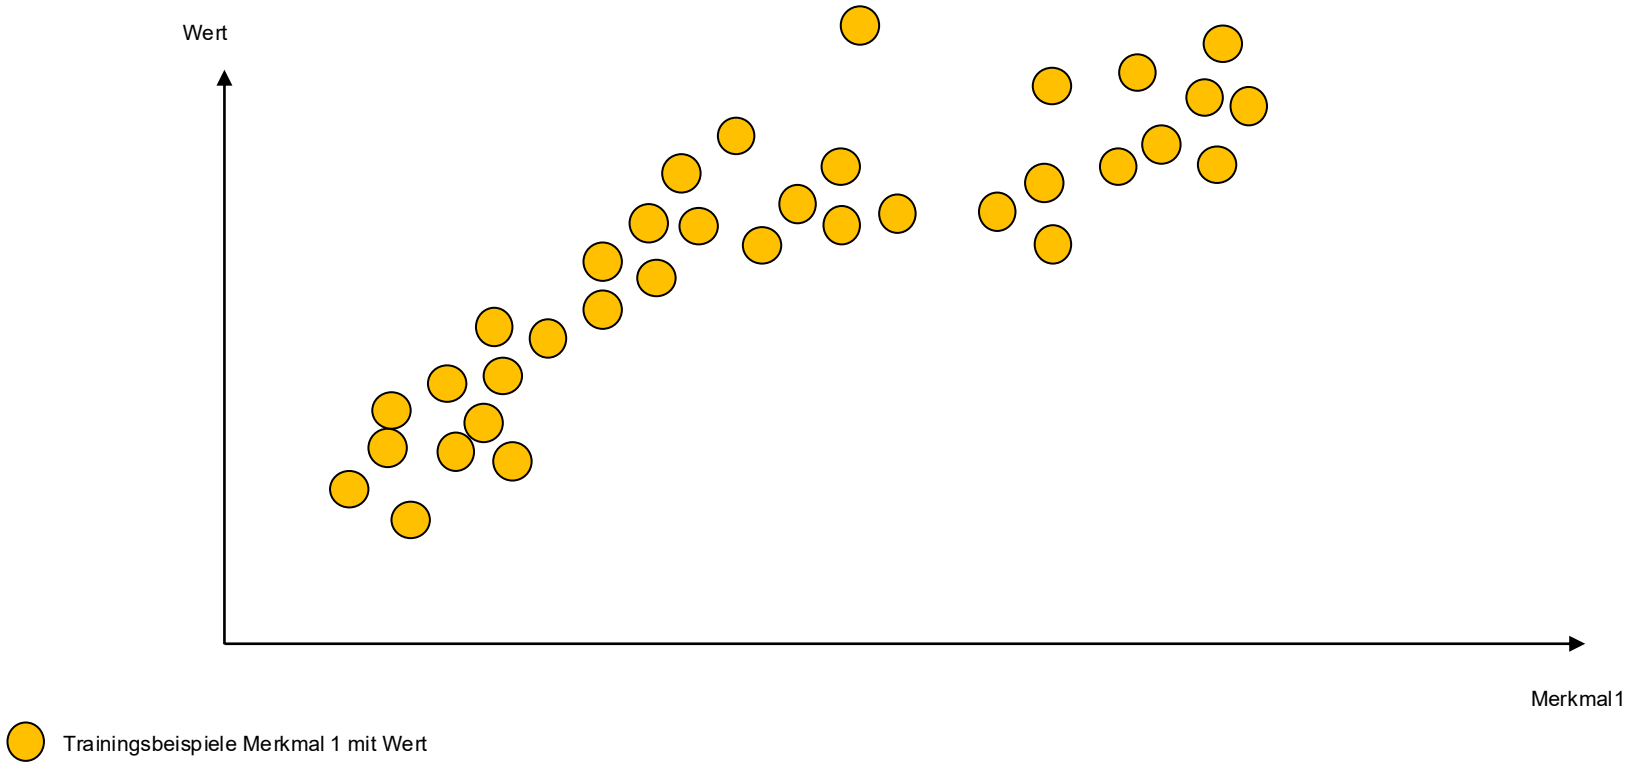
Ziel: Finden einer Trennfunktion

Klassifikation: 2 Klassenproblem

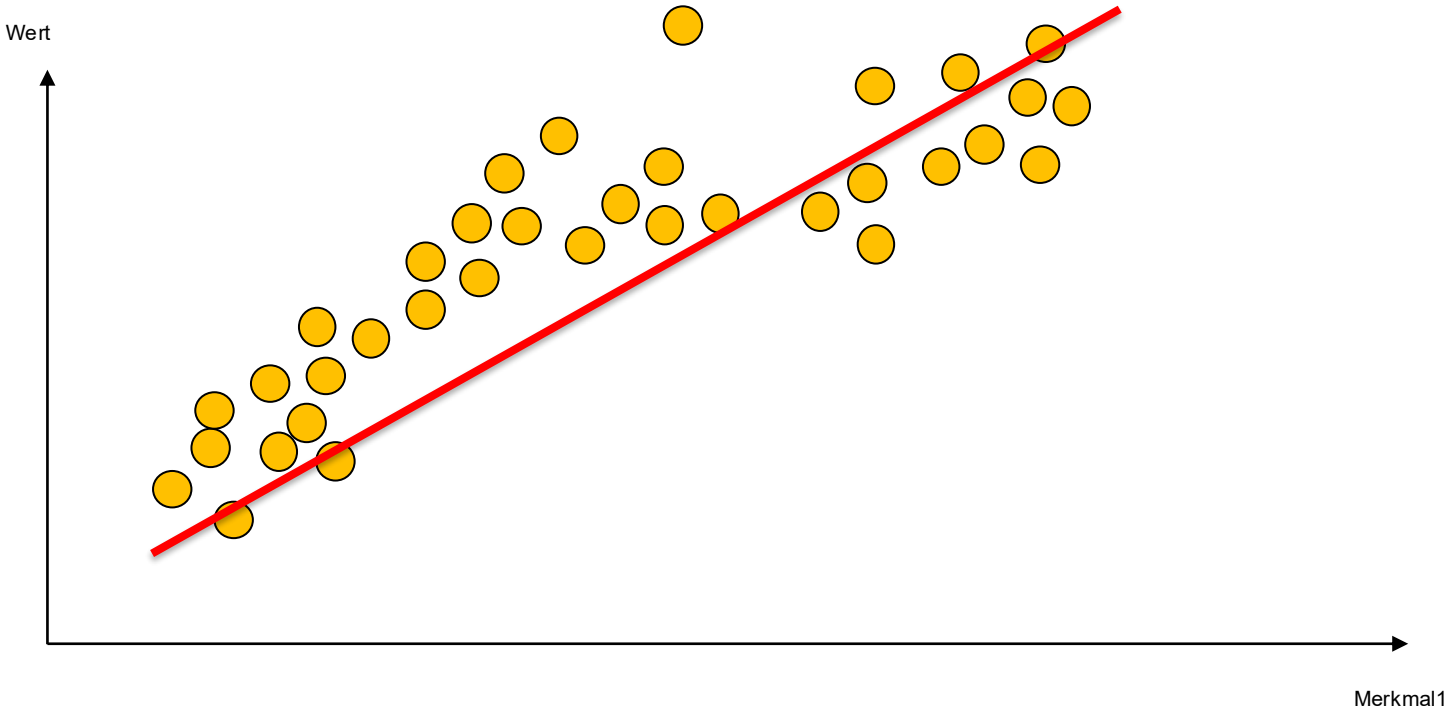


Ziel: Finden einer Trennfunktion

Regression



Regression

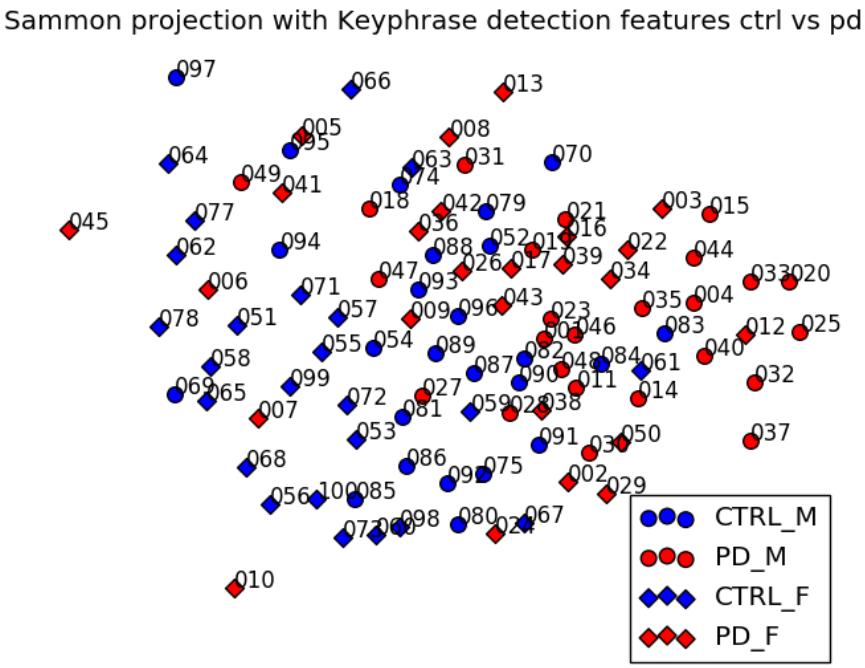


Ziel: Schätzen einer Vorhersage-Funktion

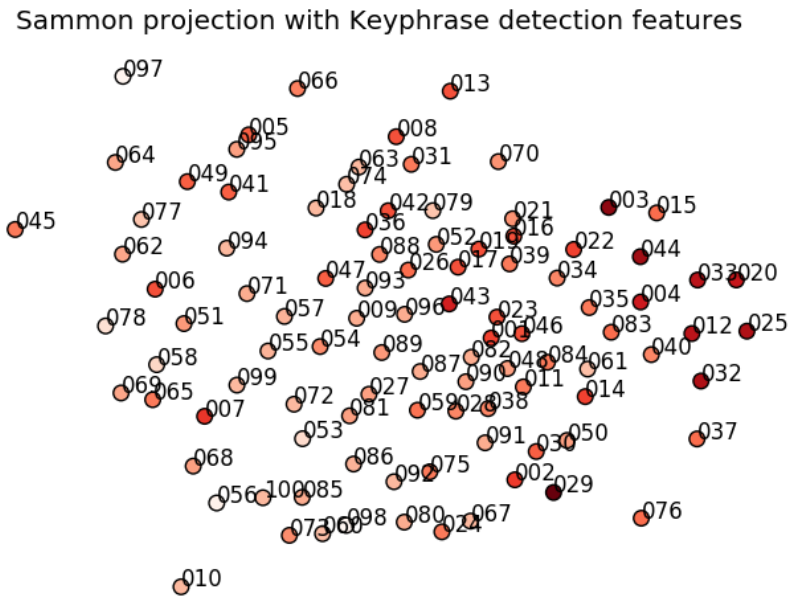
Unüberwachtes Lernen

- Unterschied zum überwachten Lernen:
  Keine gelabelten Daten
- System kann nicht ohne weiteres Trainiert werden
- Wozu sinnvoll?
  - Klustern → Finden von Häufungsgebieten
  - Anomalie Erkennung → Wann weicht etwas von der Norm ab
  - Visualisierung und Dimensionsreduktion
- Beispiele:
  - Thematisches Klustern von blogs
  - Klustern von Bildern mit ähnlichem Inhalt
  - Gruppieren von Kunden
  - Kreditkartenbetrug

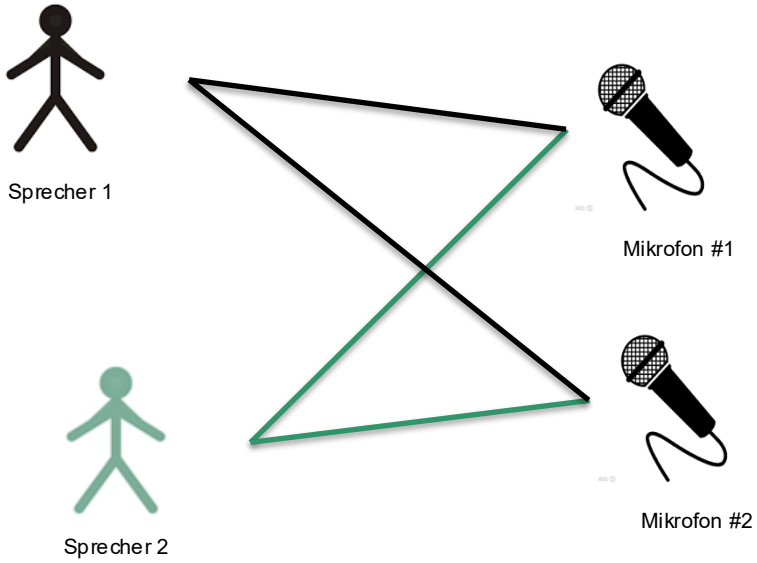
Unüberwachtes Lernen

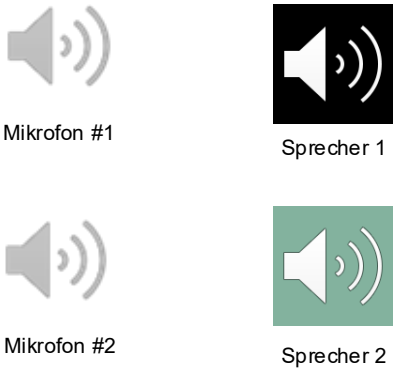


Unüberwachtes Lernen



Cocktail-Party-Problem







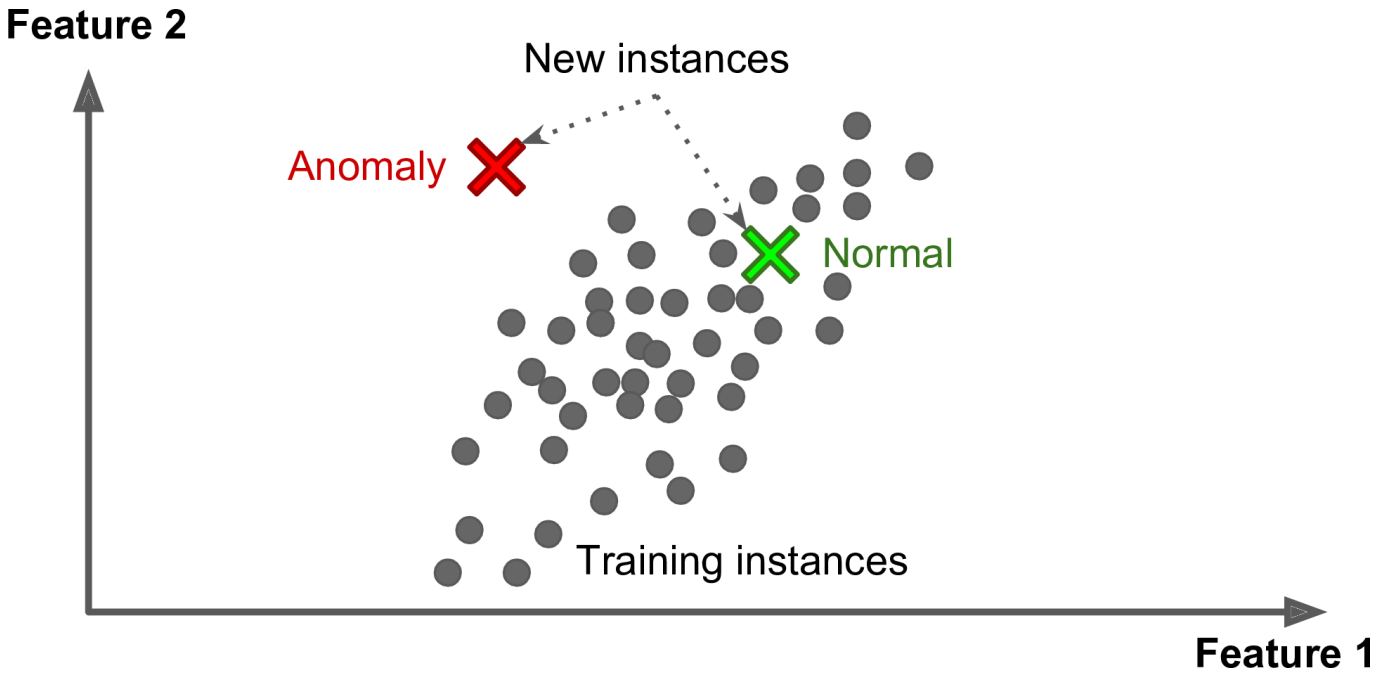
Audio Beispiele siehe git-Repository (Verzeichnis *material*)

Unüberwachtes Lernen

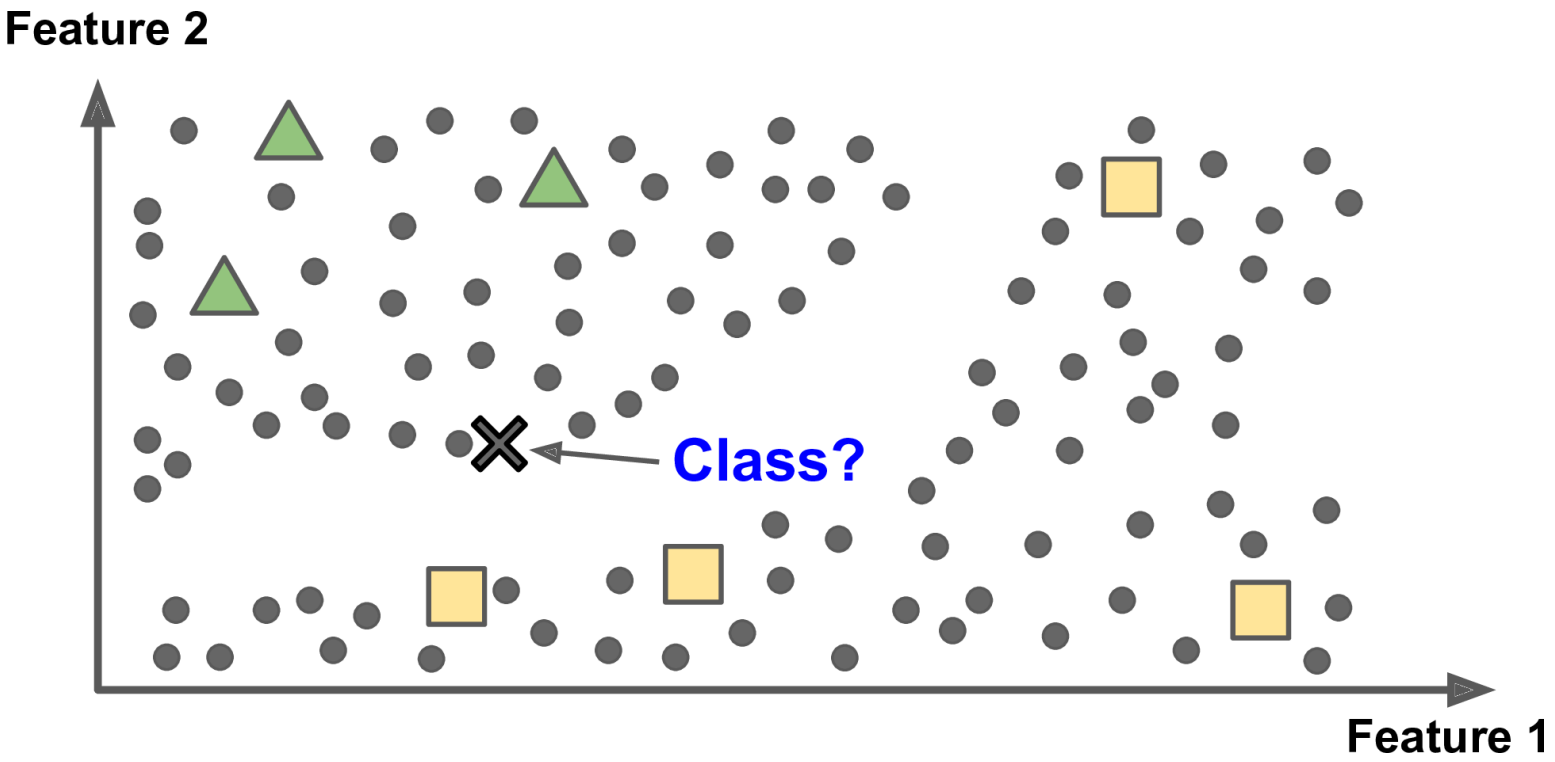
- K-Means clustering
- Hierarchische Cluster
- Principal Component Analysis
- Independent Component Analysis
- Sammon-Mapping
- T-SNE

Anomalieerkennug

- Keine (kaum) gelabelete Trainingsdaten für Anomalie



Semi-überwachtes Lernen

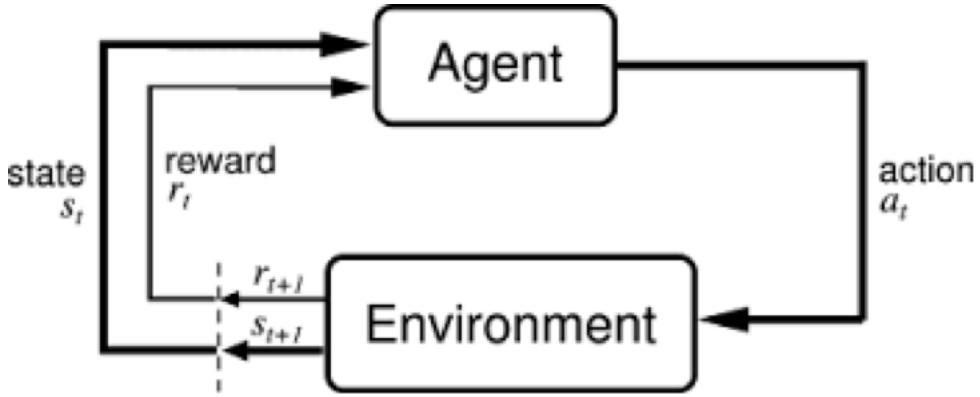


Semi-überwachtes Lernen

- Es existiert ein **kleiner Teil gelabelte Daten**
- Sowie ein **großer Teil ungelabelte Daten**
- Beispiel: Gesichtserkennung in Photos
  1. Gesichter werden detektiert
  2. Anhand der Ähnlichkeit werden Gesichter geclustert
  3. Labeln der Gesichter durch Nachfrage des Systems
- Kombination aus supervised und unsupervised Verfahren wird angewandt

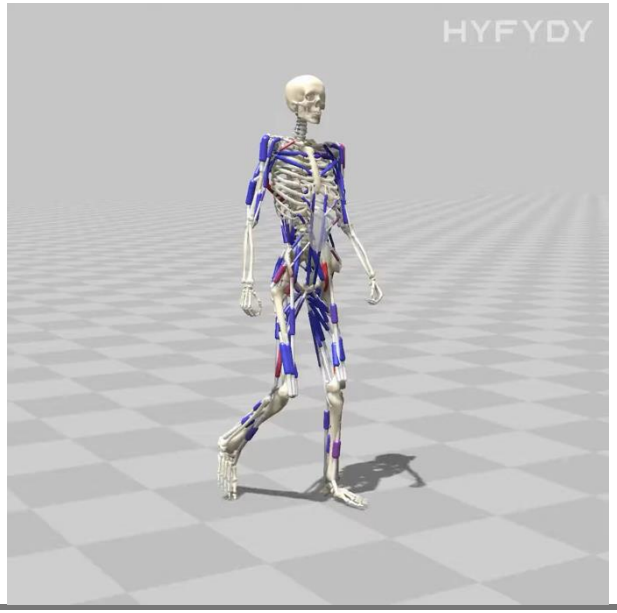
Reinforcement Learning

- Basiert auf Belohnung bzw. Bestrafung
- System(Agent) beobachtet die Umwelt und lernt selbständig die beste Strategie um Belohnung zu maximieren



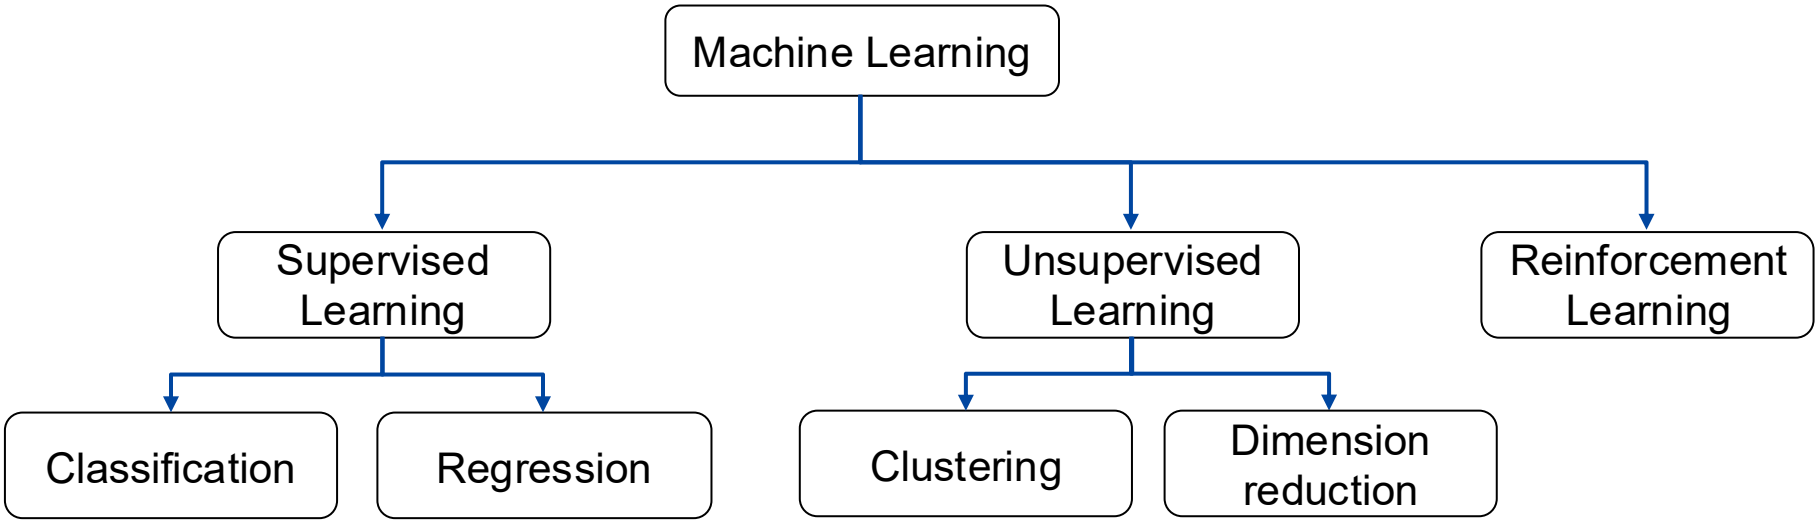
Reinforcement Learning

- Basiert auf Belohnung bzw. Bestrafung
- System(Agent) beobachtet die Umwelt und lernt selbständig die beste Strategie um Belohnung zu maximieren
- Beispiele:
  - Deep Mind‘s AlphaGo: System lernte optimale Strategie durch Analyse von Millionen von Spielen
  - Wie lernen Roboter laufen

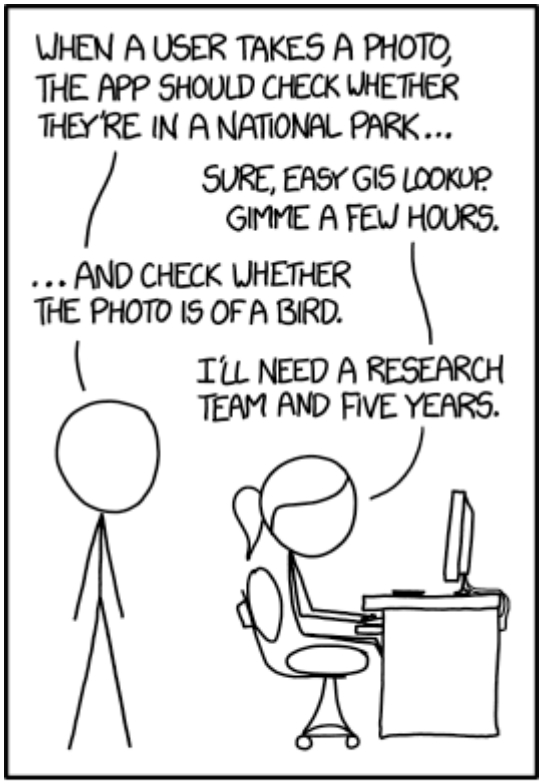


https://www.youtube.com/shorts/c3R3-QXlL4s

Machine Learning Landscape



Grundsätzliche Vorgehensweise





Chihuahua or Muffin?

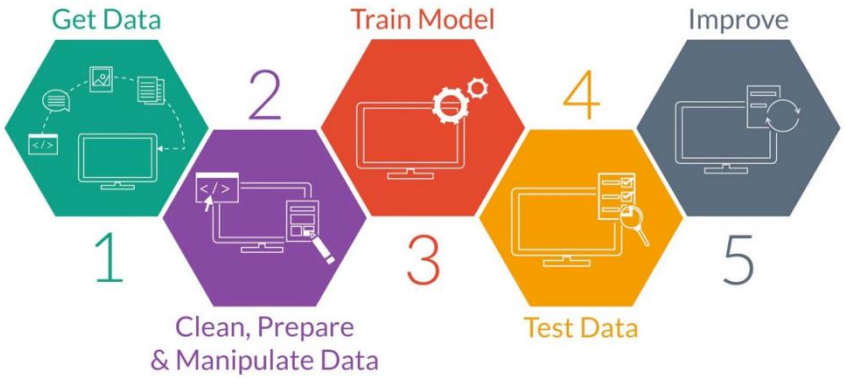
Grundsätzliche Vorgehensweise

- Problemdefinition: Was soll erkannt werden?

- Sammlung von Daten
- Erzeugen von Labels für die Daten
- Datenbereinigung bzw. Verrauschen der Daten
- Einteilung der Daten in ein Trainings- bzw. Testset
- Zusätzliches Development-Set zum Parameter-Tuning

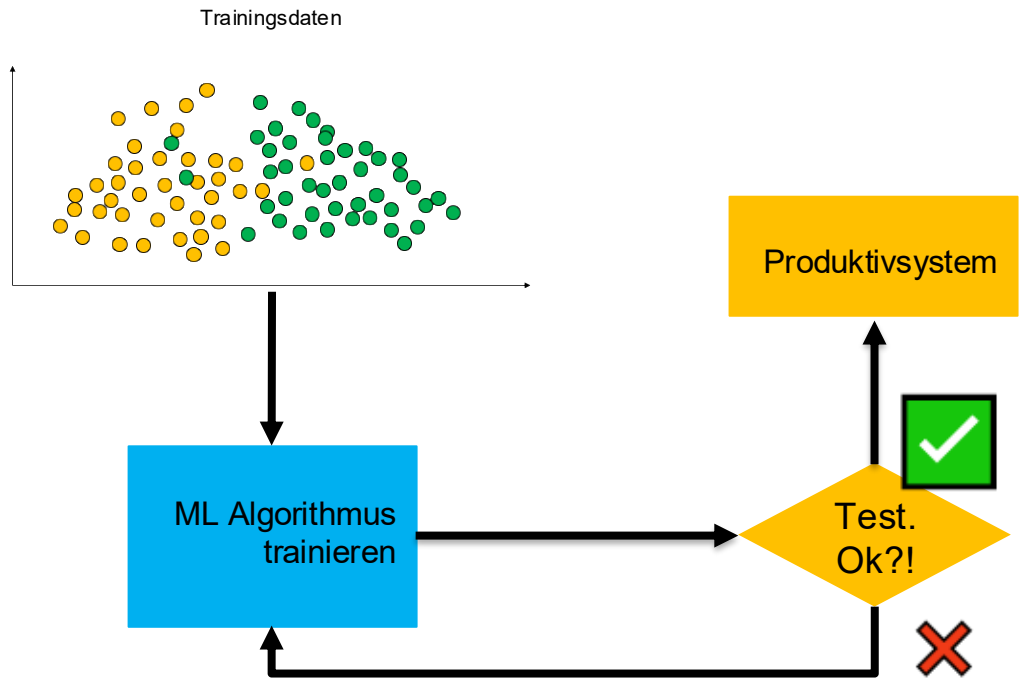
- Evtl. Extraktion von Merkmalen
- Auswählen/Trainieren eines Klassifikators

- Entscheidung über die Güte



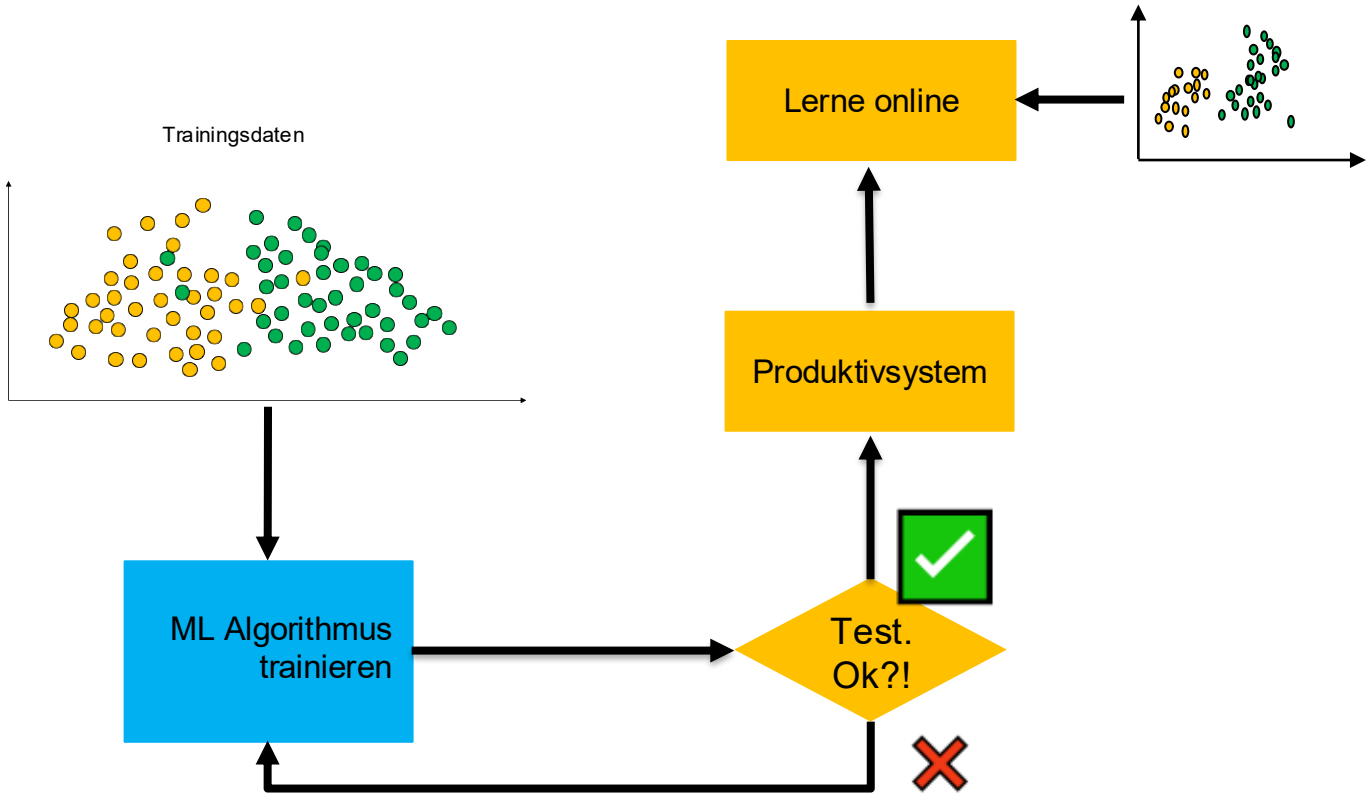
Batch learning

- System lernt „offline“ anhand der Trainingsdaten



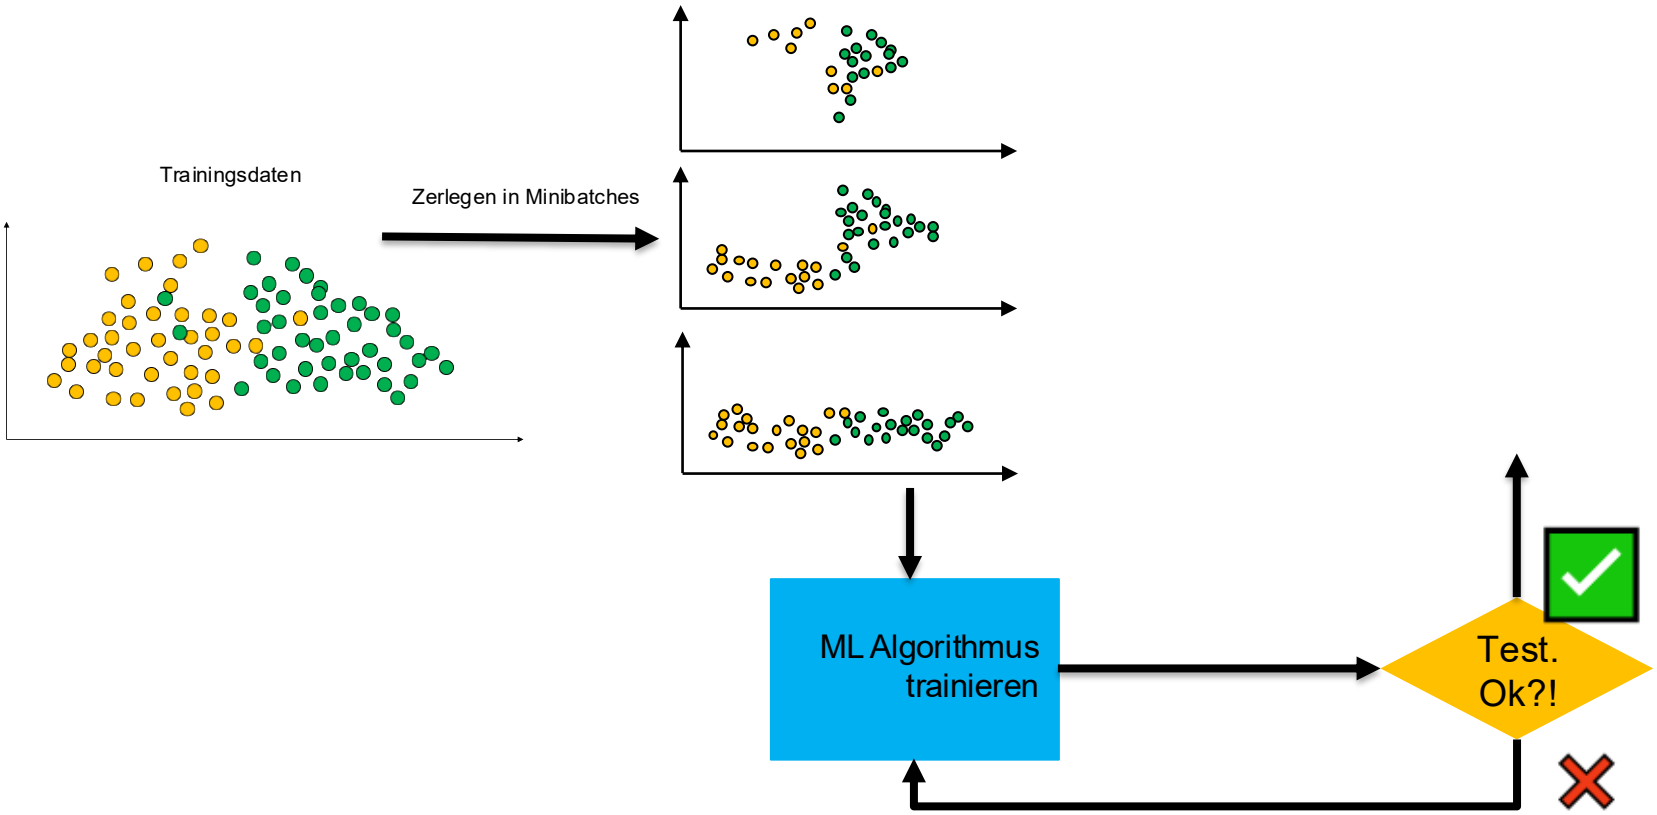
Online Learning

- System lernt „online“ anhand neuer Beispiele



Out-of-core learning/Minibatch-Learning

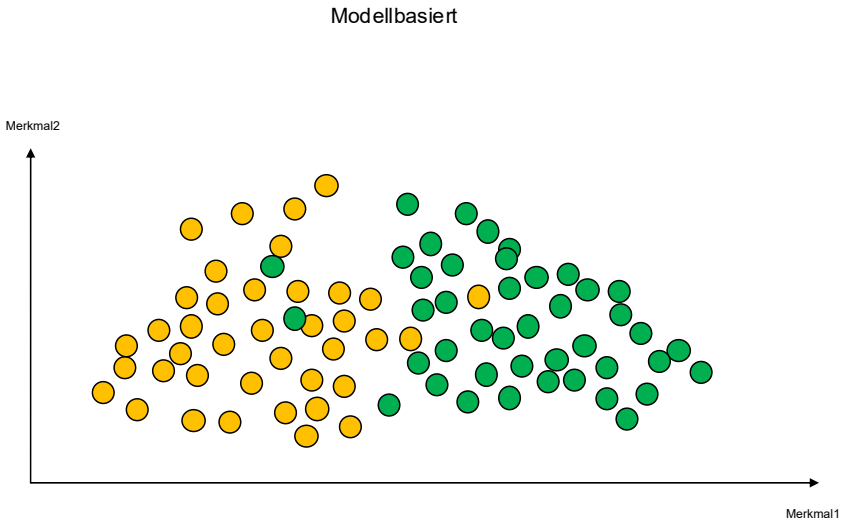
- Problem: Offline learning auf rießigen Datenbasen



Modell-basiertes vs. Instanz-basiertes Lernen

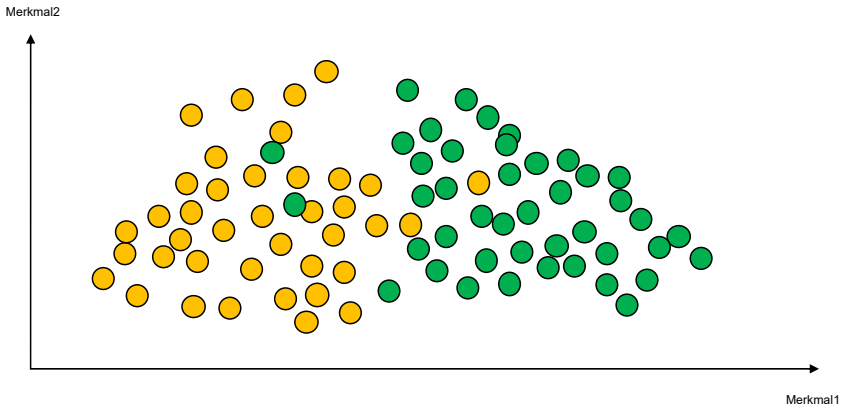


Modell-basiertes vs. Instanz-basiertes Lernen

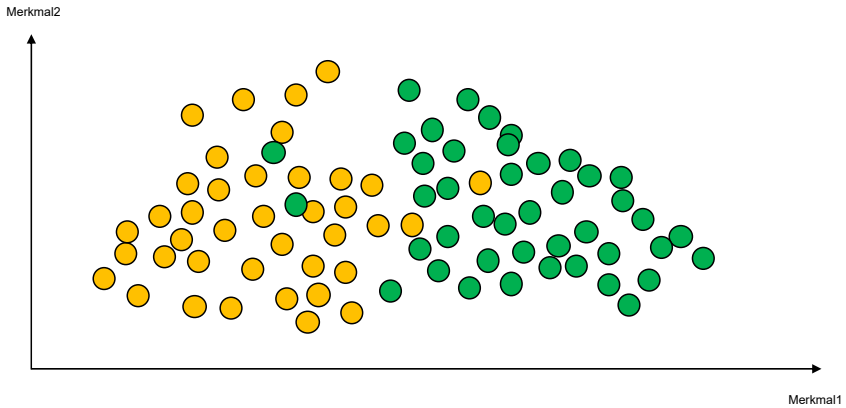


Modell-basiertes vs. Instanz-basiertes Lernen

Modellbasiert



Instanzbasiert



Themen

1. k-Nearest Neighbor
2. Evaluation von Klassifikatoren
3. Clustering
4. Lineare Regression
5. Evaluation von Regressionsalgorithmen
6. Logistische Regression
7. Merkmalvorverarbeitung, Regularisierung
8. Neuronale Netze
9. Random Forrests/Trees
10. Bayes, Statistische Klassifikation
11. Support Vector Machines
12. Transforms/Principal Component Analysis
13. Gaußsche Mischverteilungsmodelle
14. Decision Trees, Random Forest

Themen

1. k-Nearest Neighbor
2. Evaluation von Klassifikatoren
3. Clustering
4. Lineare Regression
5. Evaluation von Regressionsalgorithmen
6. Logistische Regression
7. Merkmalvorverarbeitung, Regularisierung
8. Neuronale Netze
9. Random Forrests/Trees
10. BAYES, Statistische Klassifikation
11. Support Vector Machines
12. Transforms/Principal Component Analysis
13. Gaußsche Mischverteilungsmodelle
14. Decision Trees, Random Forest

Überwacht

Unüberwacht