Technische Hochschule Nürnberg

K Nearest Neighbor Klassifikator

Prof. Dr. Tobias Bocklet



Übungen

- Abgabe der ersten Übungsaufgabe bis nächsten Dienstag 31.03.2026. 8:00.
- Besprechung Musterlösung nächste Woche in den Übungen + Besprechung
- Abgabe bis 07.04.26. 8:00 → kNN Exercise, Besprechung in der Übung am 08.04.
- Abgabe via moodle upload!

Organisatorisches

- Nächsten Donnerstag (Gründonnerstag) → Vorlesung würde ich gerne stattfinden lassen Online!

- Stattdessen keine Vorlesung in der Woche darauf (8. und 9.4.).
- Übungen finden aber statt!

Lerninhalte

- Python ML
- Wiederholung: Was versteht man unter Klassifikation
- Warum unterschiedliche Klassifikatoren
- k-Nearest Neighbor Klassifikator
  - Grundidee
  - Pseudo-Code
- Distanzen

Klassifikationsproblem

- Datensatz mit Merkmalen $\mathbf{x} = (x_1, x_2, \ldots, x_d)$
- Bestimmen der Klasse $y \in \mathcal{Y}$
  - Binäre Klassifikation $\mathcal{Y} = \{-1, +1\}$
  - Multi-class Klassifikation $\mathcal{Y} = \{1, 2, \ldots, C\}$

Lernen der Abbildung: $f(\mathbf{x}) : \mathbb{R}^d \mapsto \mathcal{Y}$

Zum Vergleich Regression: $f(\mathbf{x}) : \mathbb{R}^d \mapsto \mathbb{R}$

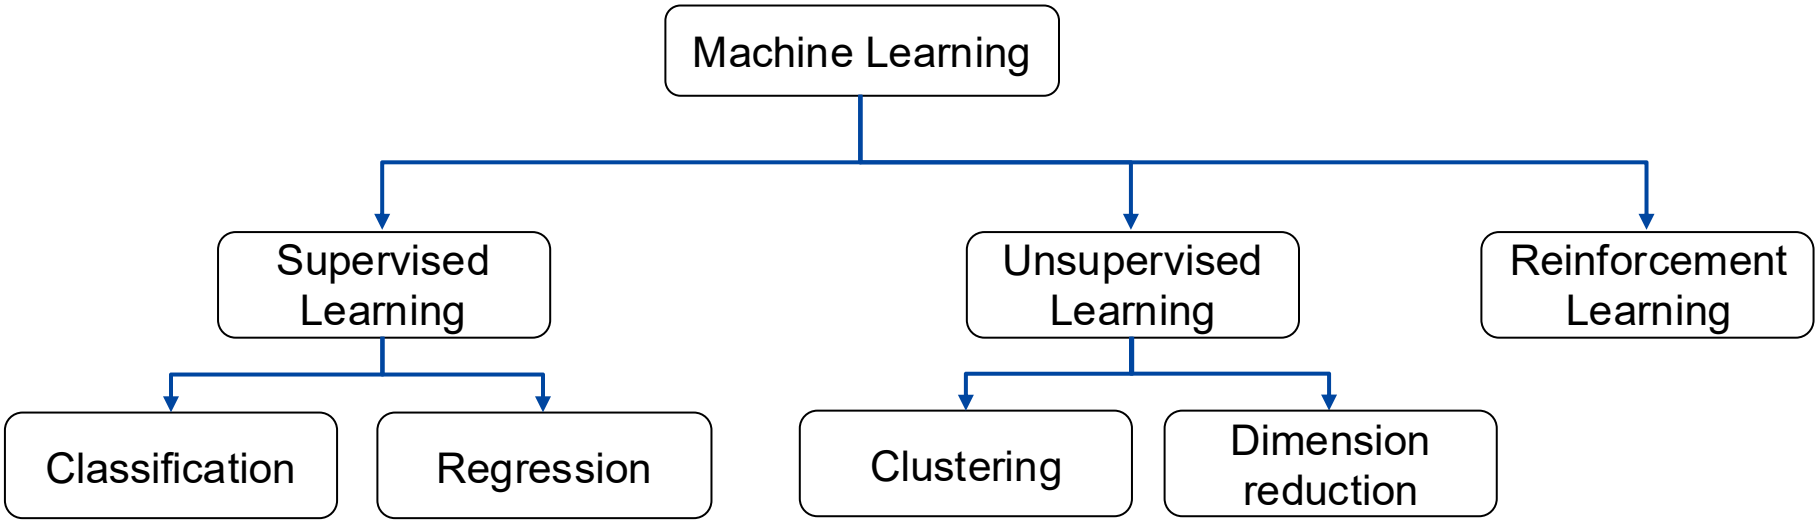
Überwachtes Lernen

- Trainingsbeispiele

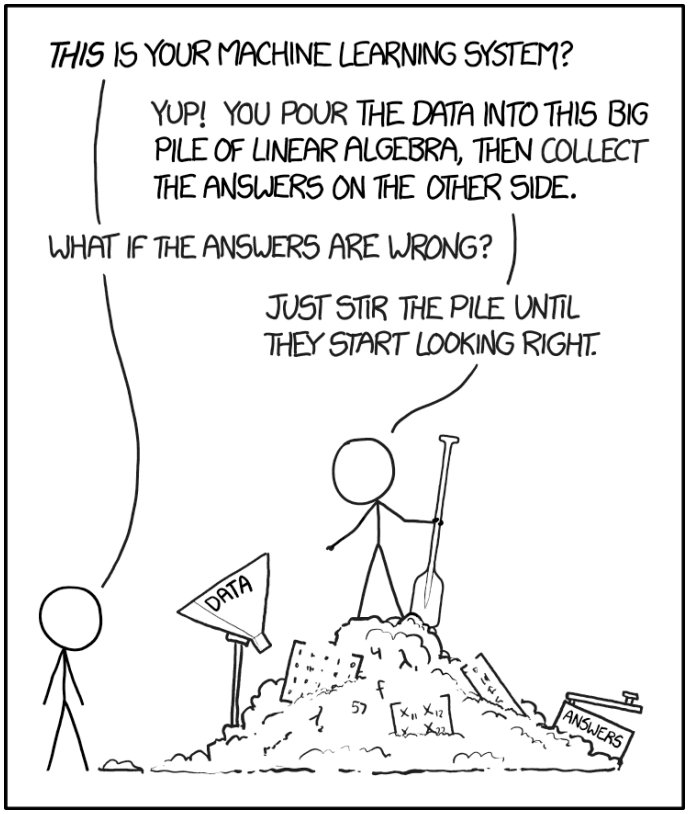
$$\mathcal{D} = \{(\mathbf{x}_i, y_i), i = 1, \ldots, n\}$$

- Unterschiedliche Klassifikatoren
  - Statistische Klassifikatoren
  - Verteilungsfreie Klassifikatoren
  - Nichtparametrische Klassifikatoren

Machine Learning Landscape



Grundsätzliche Vorgehensweise





Chihuahua or Muffin?

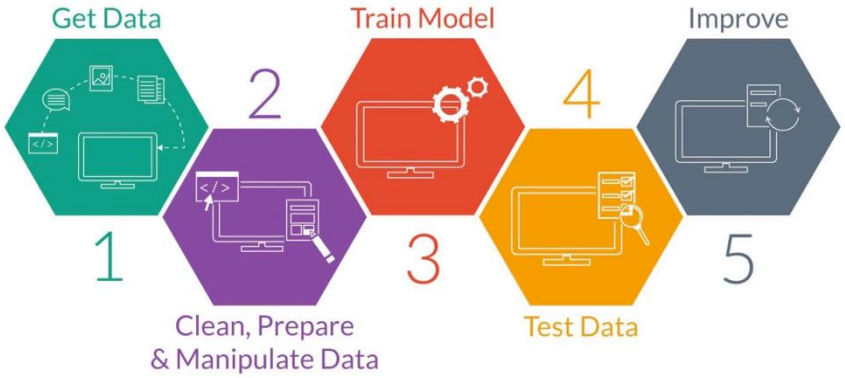
Grundsätzliche Vorgehensweise

- Problemdefinition: Was soll erkannt werden?

- Sammlung von Daten
- Erzeugen von Labels für die Daten
- Datenbereinigung
- Einteilung der Daten in ein Trainings- bzw. Testset
- Zusätzliches Development-Set zum Parameter-Tuning

- Evtl. Extraktion von Merkmalen
- Auswählen/Trainieren eines Klassifikators

- Entscheidung über die Güte



Warum unterschiedliche Klassifikatoren?

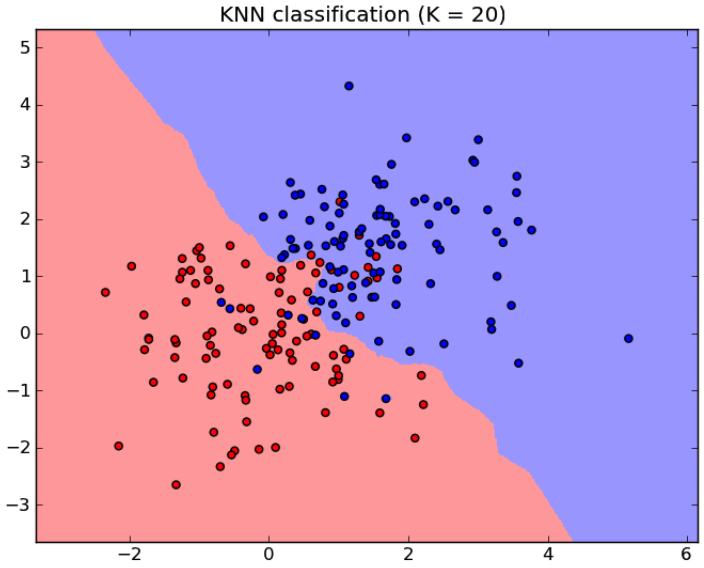
- ML-Modelle sind vereinfachte Version der Beobachtungen
- Vereinfachungen nötig für Generalisierung
- Vereinfachungen basieren auf Annahmen über die Datengrundlage
- z.B. Annahme eines linearen Modells

- Wenn man keine Annahmen über die Daten[illegible]nd eine ML-Modellierung zu bevorzugen
- Es gibt kein Modell, w[illegible]st als andere
- Im Mittel, a[illegible]n angewandt, sind alle gleich gut/schlecht
- Man m[illegible]oblieme alle möglichen Modelle evaluieren…

No free lunch theorem

Nächster-Nachbar-Klassifikator

- Beispiel eines Instanz-basierten Klassifikators
- Lazy learner → Es wird kein Modell erzeugt (Gegenteil nennt man Eager learning)
- Muster wird der Klasse zugeordnet, zu der die k nächsten Nachbarn gehören

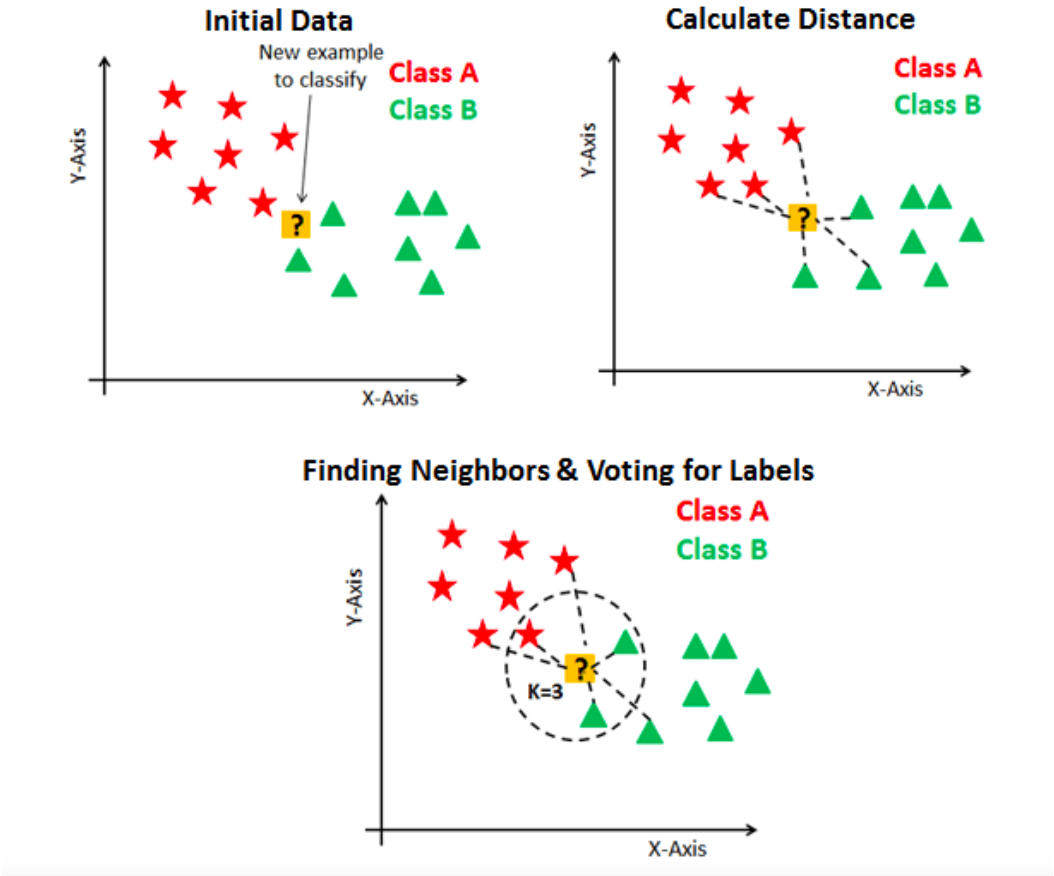


Grundidee

- Klassifikation anhand der *k* nächsten Nachbarn mit Distanzmaß
- Mehr als 2 Klassen werden unterstützt
- Klassifikation eines neuen Datums/Merkmalvektor $\boldsymbol{x}$
  - Distanzen zwischen $\boldsymbol{x}$ und Trainingsdaten bestimmen
  - Bestimmen der *k* nächsten Datenpunkte
  - Klasse für $\boldsymbol{x}$ wird der Mehrheit der Klassen der *k* Datenpunkte zugewiesen

- Bei binärer Klassifikation ist Wahl eines ungeraden Wertes sinnvoll
- Typische Werte für *k*: *5, 9, 15, 25*

Grundidee



https://www.datacamp.com/community/tutorials/k-nearest-neighbor-classification-scikit-learn

kNN Pseudocode

- Eingabe
  - ***x:*** Testvektor
  - Menge *T* von Trainingspunkten/Prototypen
  - Abbildung $c: t \rightarrow \{0, \ldots, C\}$ zur Klassenbestimmung
  - Funktion $\mathrm{d}: (\mathbf{a}, \mathbf{b}) \rightarrow \mathbb{R}$ zur Berechnung der Distanz
  - Zahl *k:* Anzahl der zu bestimmenden Nachbarn
- Begin
  - Let $U \leftarrow \{\}$
  - Foreach t in T:
    - $U \leftarrow U + (d(\mathbf{x},\mathbf{t}), c(\mathbf{t}))$
  - $U \leftarrow sort(U)[:k]$

McGurk-Effekt



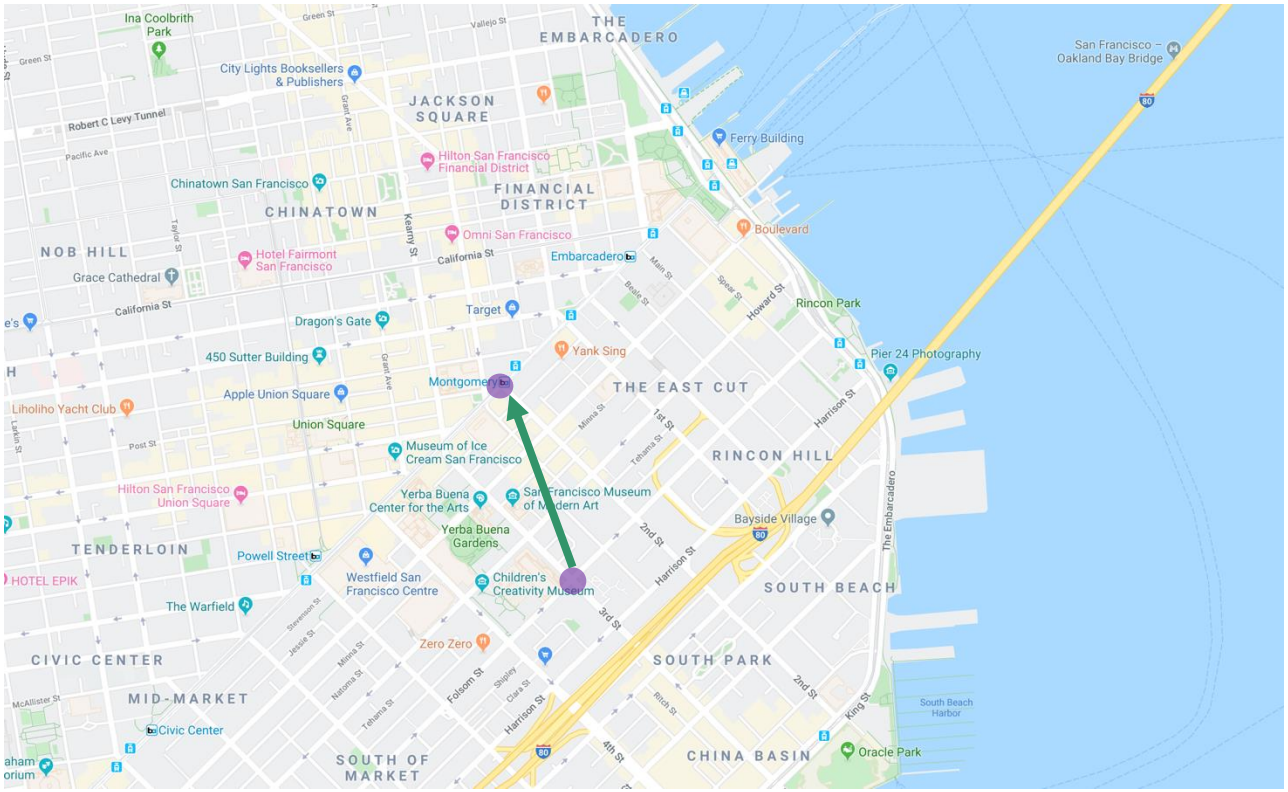
McGurk-Effekt

- Tonspur: /ba-ba/
- Videspur: /ga-ga/
- 98% der Versuchspersonen geben an /da-da/ gehört zu haben

Warum?

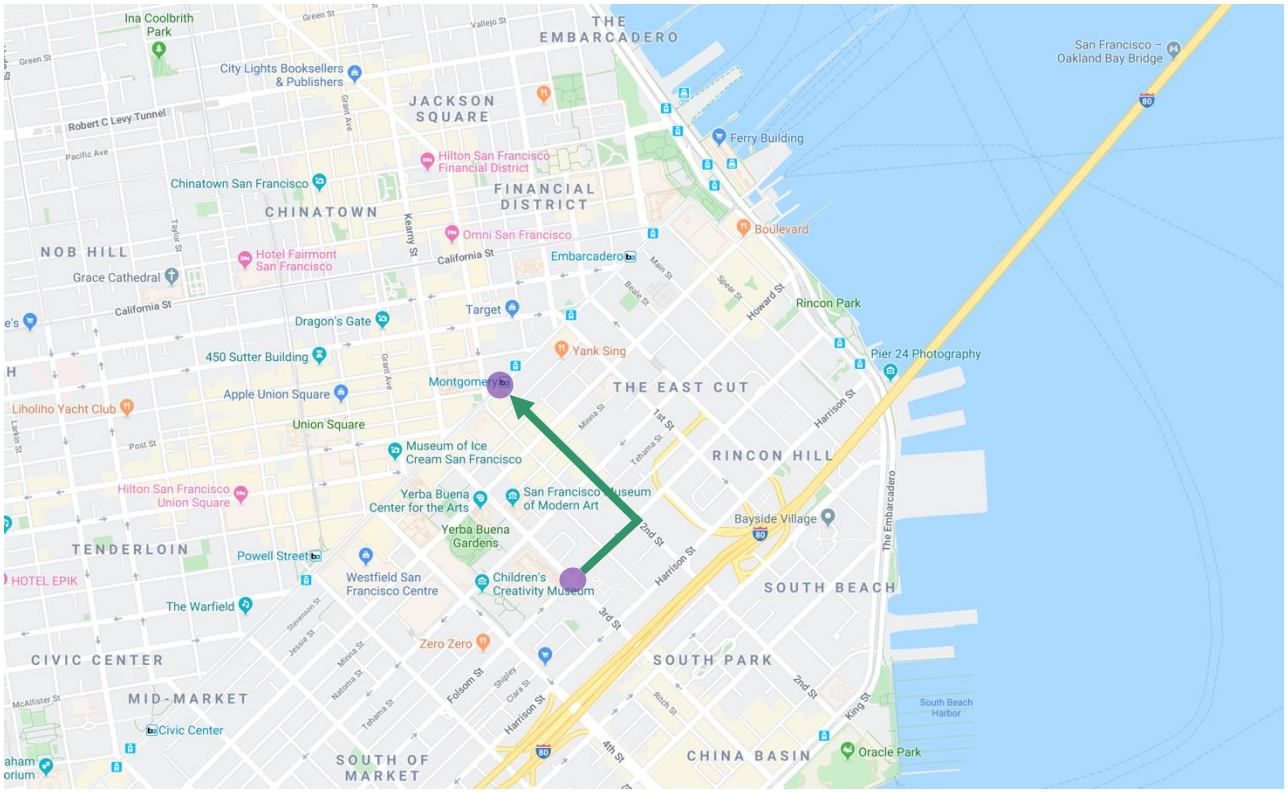
- Unser Gehirn nutzt alle verfügbare Information um akustisches Signal zu „entschlüsseln“.
- Wir haben gelernt, dass es einen direkten Zusammenhang zwischen Lippenbewegungen und Lauten gibt
- Visuelle Information der Lippenbewegungen hat großen Einfluss auf unser Gehirn
- Sprachzentrum kombiniert widersprüchliche Sinneseindrücke und schafft neuen, *virtuellen* Eindruck

Distanzen



- Euklid-Abstand (L_2-Norm): $\mathrm{d}(\boldsymbol{x},\boldsymbol{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$

Distanzen



Citiblock bzw. Manhattan-Abstand (L_1-Norm): $d(\boldsymbol{x}, \boldsymbol{y}) = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_n - y_n|$

Distanzen

- Werden auch *norm* oder *kernel* genannt
- Maximum-Norm (L_∞-Norm):

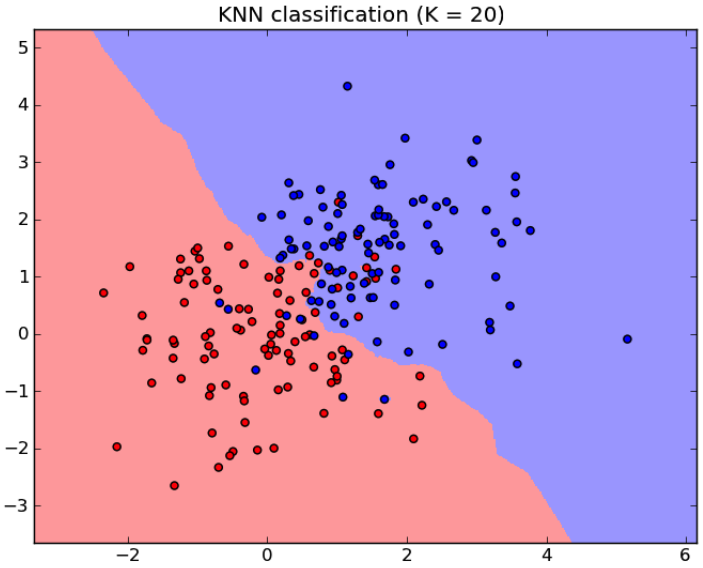
$$\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = \max\left(\left|x_1 - y_1\right|, \left|x_2 - y_2\right|, \ldots, \left|x_n - y_n\right|\right)$$

- Minkowski-Distance (L_p-Norm):

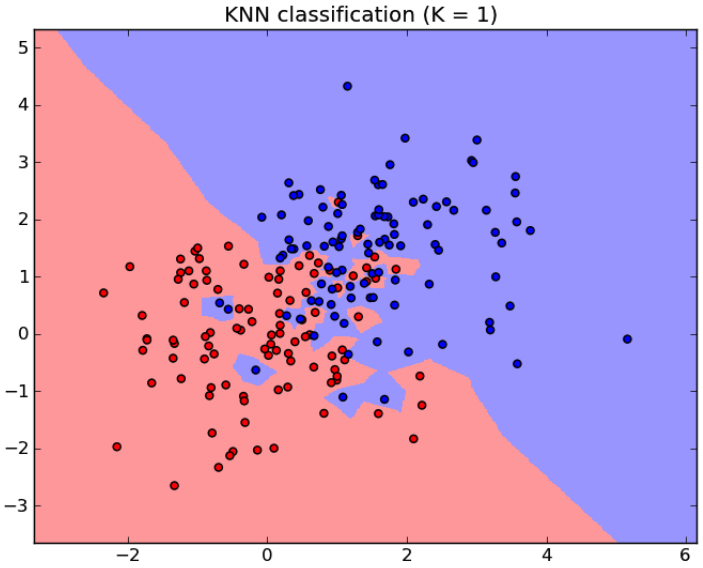
$$\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = \sqrt[p]{\left|x_1 - y_1\right|^p + \left|x_2 - y_2\right|^p + \cdots + \left|x_n - y_n\right|^p}$$

Cosine-Distance https://en.wikipedia.org/wiki/Cosine_similarity
Jaccard Index https://en.wikipedia.org/wiki/Jaccard_index
Hamming-Distance https://en.wikipedia.org/wiki/Hamming_distance
Mahalanobis-Distance https://en.wikipedia.org/wiki/Mahalanobis_distance

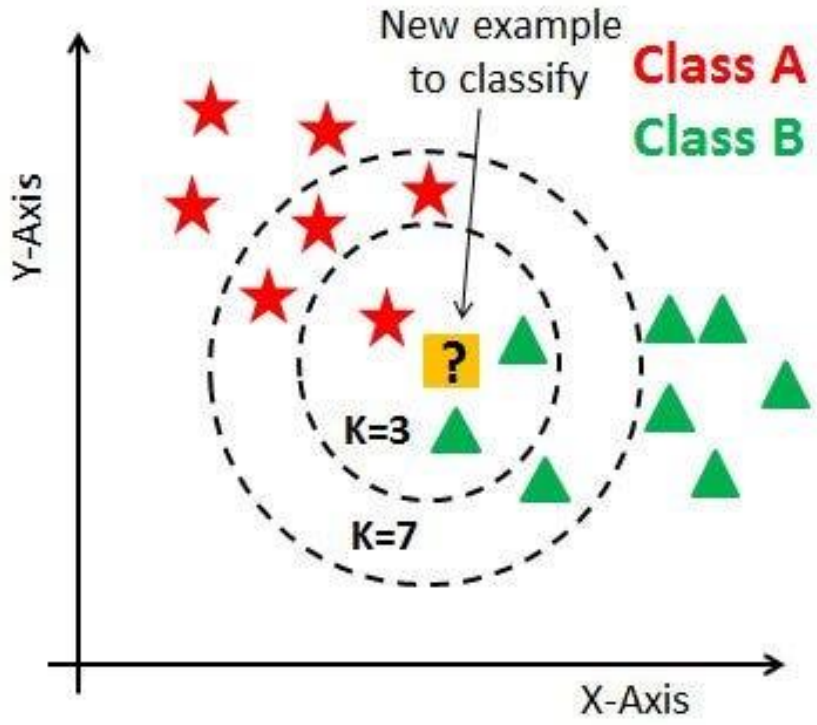
Wahl von k



Wahl von k



Wie k Auswählen?



Maximum Likelihood Prinzip

- Bedingte Wahrscheinlichkeit $P(y|\boldsymbol{x})$ durch Zählen der Klassenzugehörigkeit, in der Nachbarschaft von $\boldsymbol{x}$

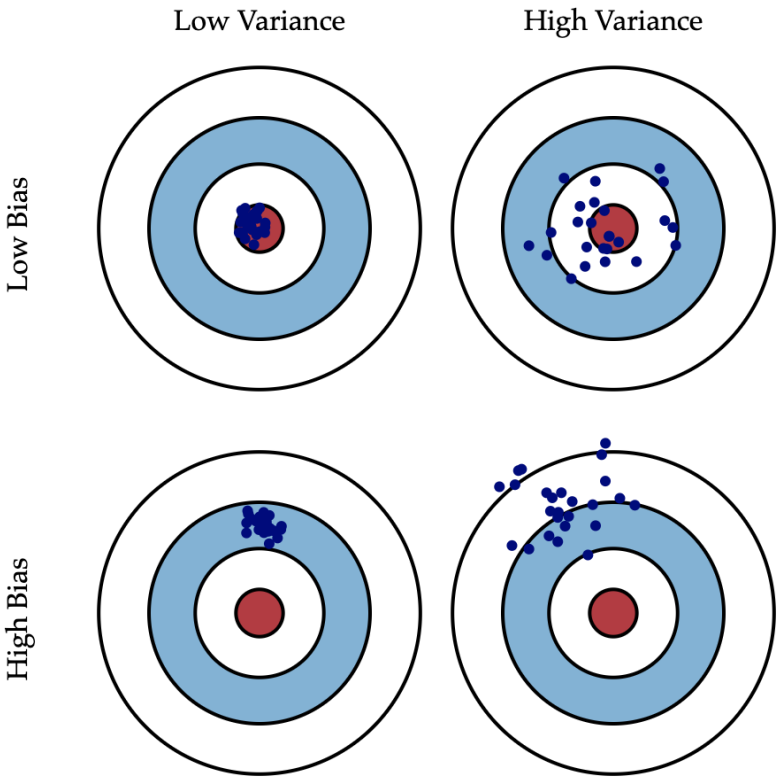
$$P(y|\boldsymbol{x}) = \frac{\#\boldsymbol{y}}{\boldsymbol{k}}$$

- Bias/Variance trade-off
  - Kleine *k* führen zu großer Varianz bzw. unsichere Klassifikation

    → **Keine Generalisierung, Overfitting**
  - Große *k* führen zu großem Bias bzw. Nicht-akkurate Entscheidung

    → ***Zu starke Vereinfachung/Generalisierung, Underfitting***

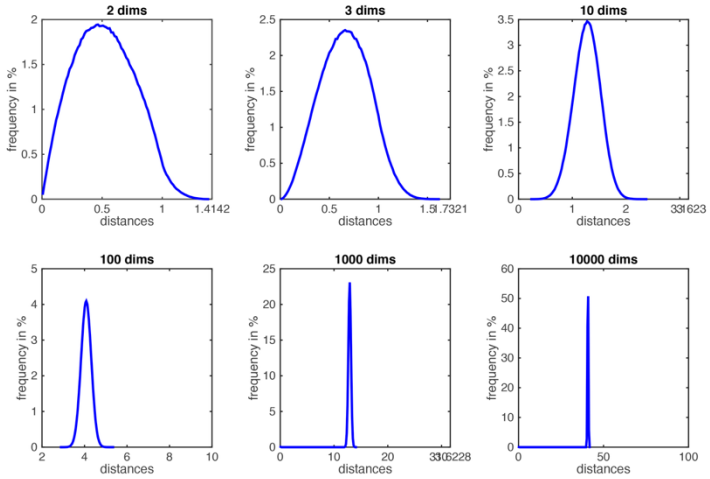
Bias und Varianz



http://scott.fortmann-roe.com/docs/BiasVariance.html

Fluch der Dimensionalität

- Ähnliche Punkte sollen nahe beieinander liegen
- Bei hochdimensionalen Daten, Distanzen immer ähnlich zueinander



- Bei K-NN muss Datenzahl exponentiell zur Dimension der Merkmale wachsen

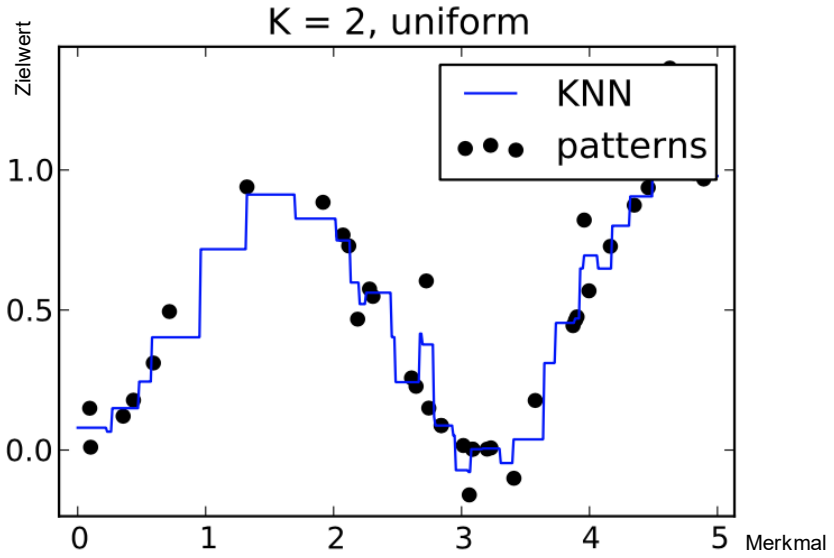
https://www.cs.cornell.edu/courses/cs4780/2018fa/lectures/lecturenote02_kNN.html

Komplexität

- Komplexität wächst mit der Anzahl der Trainingsbeispiele
- Mögliche Beschleunigungen:
  - *Partielle Distanzen:* Für hochdimensionale Probleme: Berechne die Distanz sequentiell, d.h. erst entlang von Dimension x1, dann x2 usw. Falls die Gesamtdistanz über dem momentanen Minimum liegt, brich Berechnung ab und gehe zum nächsten Prototypen.
  - *Suchbäume:* Fasse Prototypen in Regionen zusammen und suche einen repräsentativen Prototyp, der die dadurch gebildete Metazelle möglichst gut repräsentiert. Achtung: Methode garantiert nicht, dass tatsächlich der nächste Prototyp gefunden wird.
  - *Kondensieren, Pruning*: Eliminiere alle Prototypen, die komplett von Prototypen der gleichen Klasse umgeben sind (ändert Entscheidungsgrenzen nicht).

Regression mittels kNN

- Keine Klassen, sondern numerische Zielwerte
- Bestimme *k* nächste Nachbarn
- Mittelwertberechnung der numerischen Zielwerte dieser *k* nächsten Nachbarn
- Sinnvall bei fehlenden Daten, wenn Distanzmetrik sinnvoll gewählt wird



K-Nächster-Nachbar – The good

- Überwachter Klassifikator
- Instanz-basiert
  - erfordert kein Erzeugen eines Modells („training“)
  - Neue Daten können direkt in Modellierung eingebaut werden
- Kann auch zur Regression genutzt werden. Ausgabe ist Mittelwert der K nächsten Nachbarn
- Vergleicht paar-weise Distanzen
- Kann Nicht-Lineare Klassengrenzen lernen
- Funktioniert gut für kleinere Datensätze
- Rule of thumb: **k = sqrt(N)**

K-Nächster-Nachbar – The bad

- Instanz-basiert
  - erfordert kein Erzeugen eines Modells („training“)
  - Daten müssen alle gespeichert werden
- Nutzt Euklid-Distanz. Merkmale müssen alle im selben Wertebereich liegen, da Euklid empfindlich auf Werteunterschiede reagiert
- Empfindlich gegenüber ungleichgewichtete Klassenverteilungen der Daten
- K-NN nicht geeignet für hochdimensionale Merkmalvektoren
- Finden eines optimalen „K“ erfordert Experimentierung & Evaluation

Next on Machine Learning…

- Evaluation von Klassifikatoren