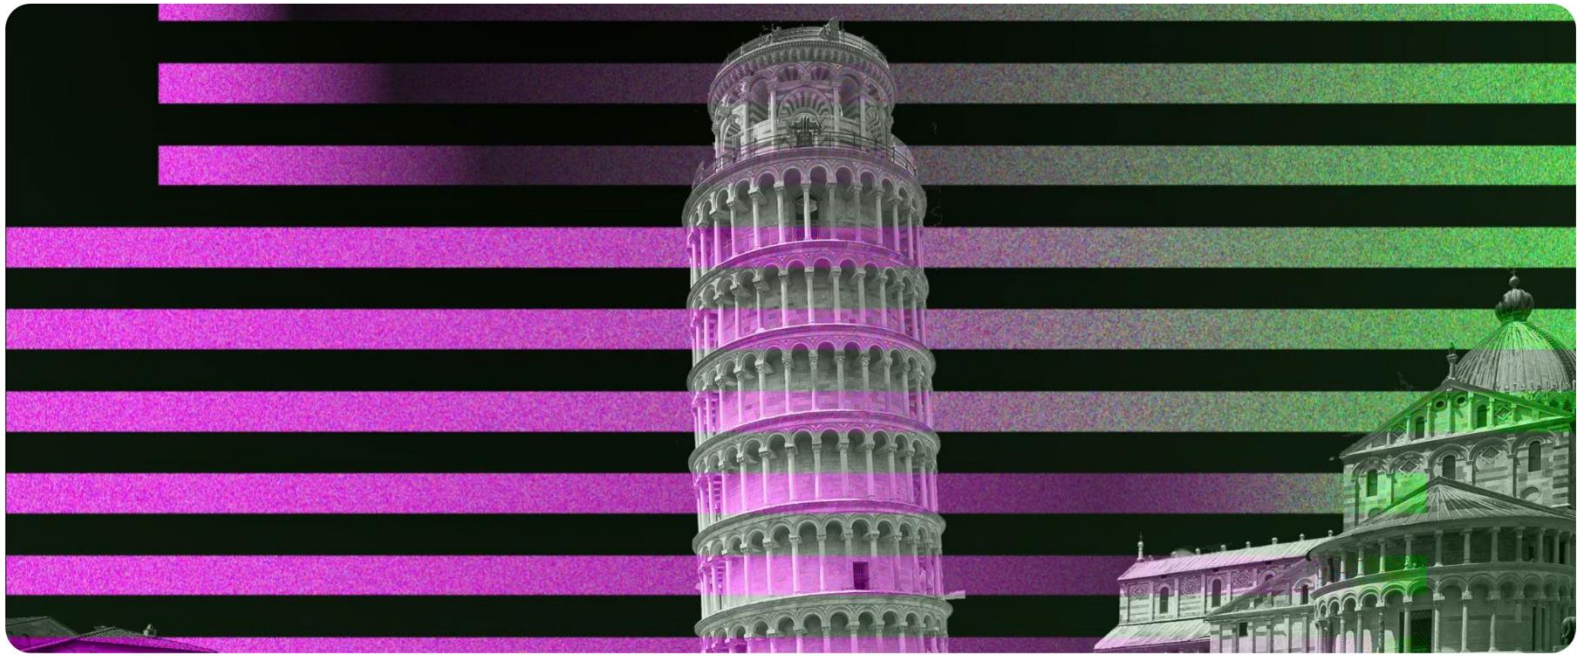
ohm Technische Hochschule Nürnberg

Evaluation von Klassifikatoren

Prof. Dr. Tobias Bocklet

ChatGPT banned in Italy over



Blog 1/22/2026

The Curious Case of ChatGPT: Banned in Italy, Admired Globally, and Raising Eyebrows Everywhere

ChatGPT.

Organisatorisches

- Drei Übungsgruppen
  - Mi, 11:30-13:00 (HQ.306)
  - Mi, 15:45-17:15 (HQ.305)
  - Mi, 15:45-17:15 (HQ.013)

Lerninhalte

Welche Evaluationsmaße gibt es?

Wie evaluiert man Klassifikatoren richtig?



Evaluation von Klassifikatoren – Evaluationsmaße

- Accuracy
- Precision und Recall
- Sensitivity und Specificity
- F-Score

Basieren auf Verwechslungsmatrix

- Receiver Operating Characteristics (ROC)
- Area under the Curve (AUC)

Verwechslungsmatrix / Confusion Matrix

- Tabelle, die die Güte eines Klassifikators visualisiert
- Beinhaltet Anzahl der klassifizierten Instanzen
- Beispiel 2 Klassenproblem
- Vier Werte bei binärer Klassifikation
  - TP: true positives = Anzahl der als positiv klassifizierten Instanzen, die tatsächlich positiv sind
  - TN: true negatives = Anzahl der als negativ klassifizierten Instanzen, die tatsächlich negativ sind
  - FP: false positive = Anzahl der als positiv klassifizierten Instanzen, die tatsächlich negativ sind
  - FN: false negative = Anzahl der als negativ klassifizierten Instanzen, die tatsächlich positiv

Vorhergesagte Klasse

Tatsächliche Klasse	pos	neg
pos	10	4
neg	1	15

Vorhergesagte Klasse

Tatsächliche Klasse	pos	neg
pos	TP	FN
neg	FP	TN

- **Akkuratheit / Accuracy**

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

- Warum ist das kein ausreichendes Maß?

	pos	neg
pos	10	15
neg	20	100

(10 + 100)/(10+15+20+100)
= 75.9%

	pos	neg
pos	0	25
neg	0	120

(0 + 120)/(0+25+0+120)
= 82.8%

- **Precision & Recall**

$$precision = \frac{TP}{TP + FP}$$

Precision: Wie viele von den Instanzen, die als positiv erkannt werden, sind tatsächlich positiv?

Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

$$recall = \frac{TP}{TP + FN}$$

Recall: Von allen positiven Instanzen, wie viele wurden als positiv klassifiziert?

- **Precision & Recall**

$$precision = \frac{TP}{TP + FP}$$

Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

$$recall = \frac{TP}{TP + FN}$$

	pos	neg
pos	10	15
neg	20	100

Precision: 10 /(10+20) = 33.3%
Recall: 10/(10+15) = 40%

	pos	neg
pos	0	25
neg	0	120

Precision: 0/0
Recall: 0/25

- **Sensitivity & Specificity**

$$sensitivity = \frac{TP}{TP + FN}$$

Von allen positiven Instanzen, wie viele wurden als positiv klassifiziert?

Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

$$specificity = \frac{TN}{TN + FP}$$

Wie viele von den Instanzen, die als negativ erkannt werden, sind tatsächlich negativ?

- **F-score**

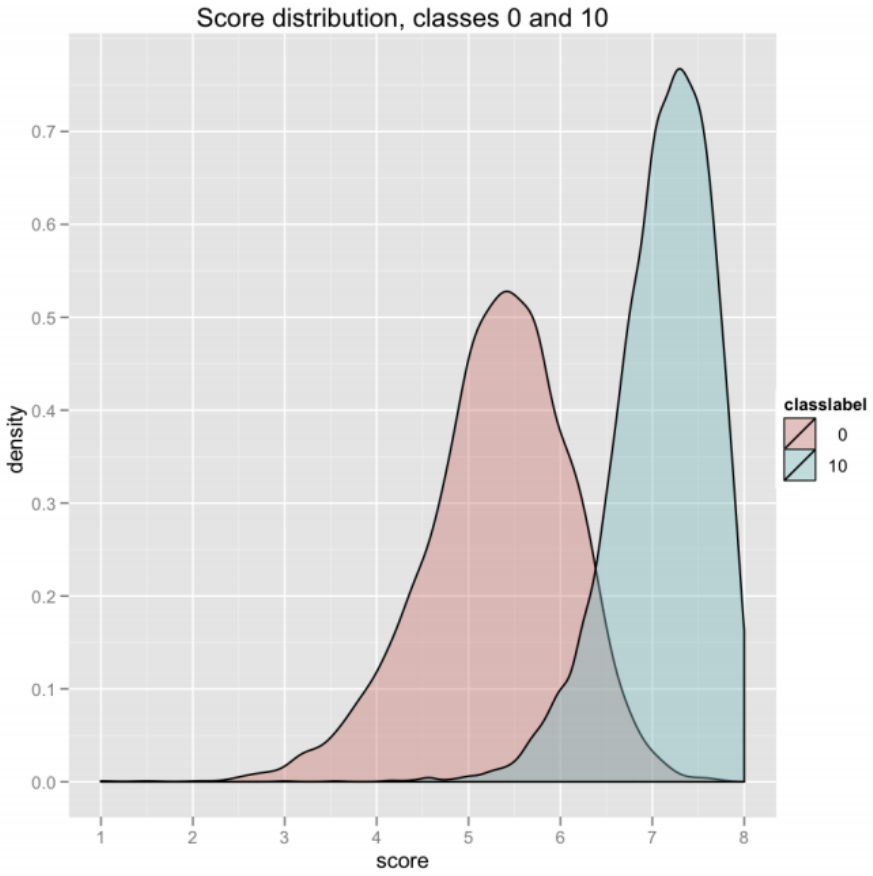
$$F_1 = \frac{2}{\frac{1}{precision} + \frac{1}{recall}}$$

Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

- Harmonischer Mittelwert von Precision and Recall
- F_1 ist nahe 1, wenn precision und recall hoch sind
- F_1 ist nahe 0, wenn precision und recall gering sind
- F_1 nimmt an, dass precision und recall gleichwichtig sind
- Erweiterung mit Gewichtung möglich: F_α

• Score Distribution

- Bisher waren unsere Entscheidungen *harte* Entscheidungen: Wir haben uns für eine Klasse entschieden
- Das ist bei den meisten Klassifikatoren nicht der Fall
- Diese produzieren kontinuierliche *scores*
- Klassenentscheidung basiert dann auf Schwellwertentscheidung



http://win-vector.com/dfiles/StatisticsToEnglishPart1_Accuracy.pdf

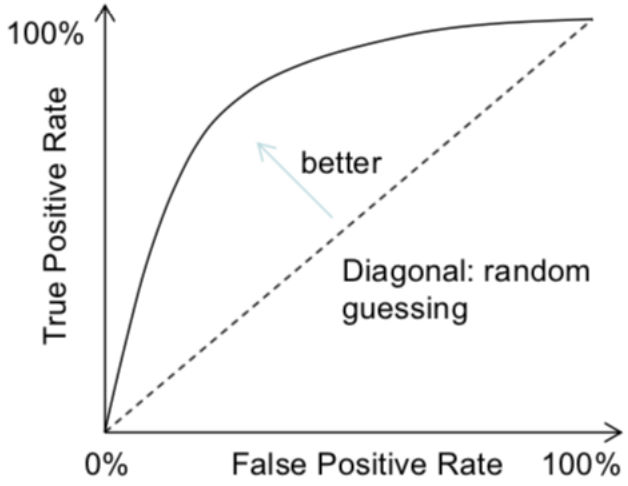
Klasse 0 = negativ
Klasse 10 = positiv

• ROC Curves

- Auftragen der FPR auf der x-Achse, bzw. der TPR auf der y-Achse

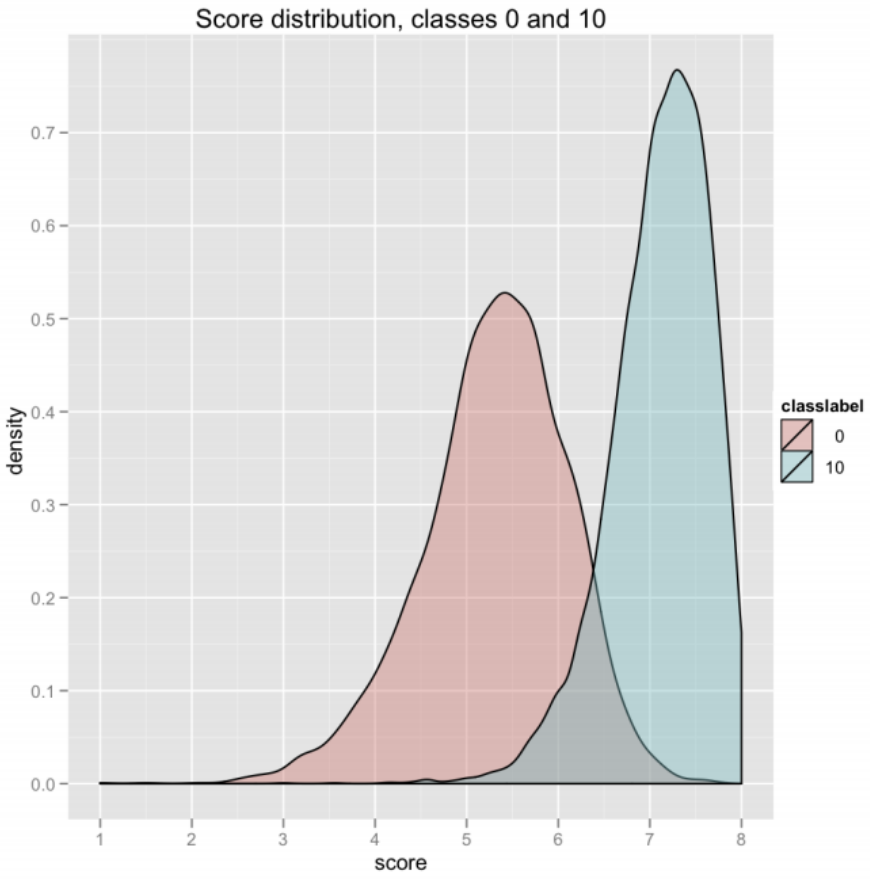
$$FPR = \frac{FP}{FP + TN}$$

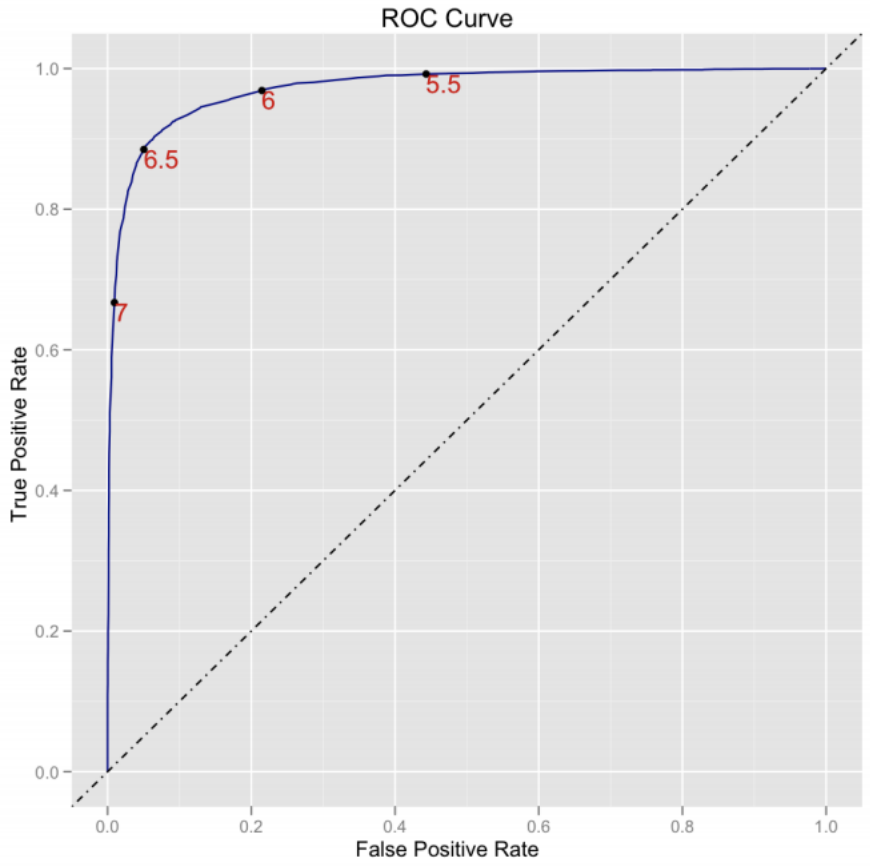
$$TPR = recall = \frac{TP}{TP + FN}$$



Tatsächliche Klasse \ Vorhergesagte Klasse	pos	neg
pos	TP	FN
neg	FP	TN

- **ROC Curves**

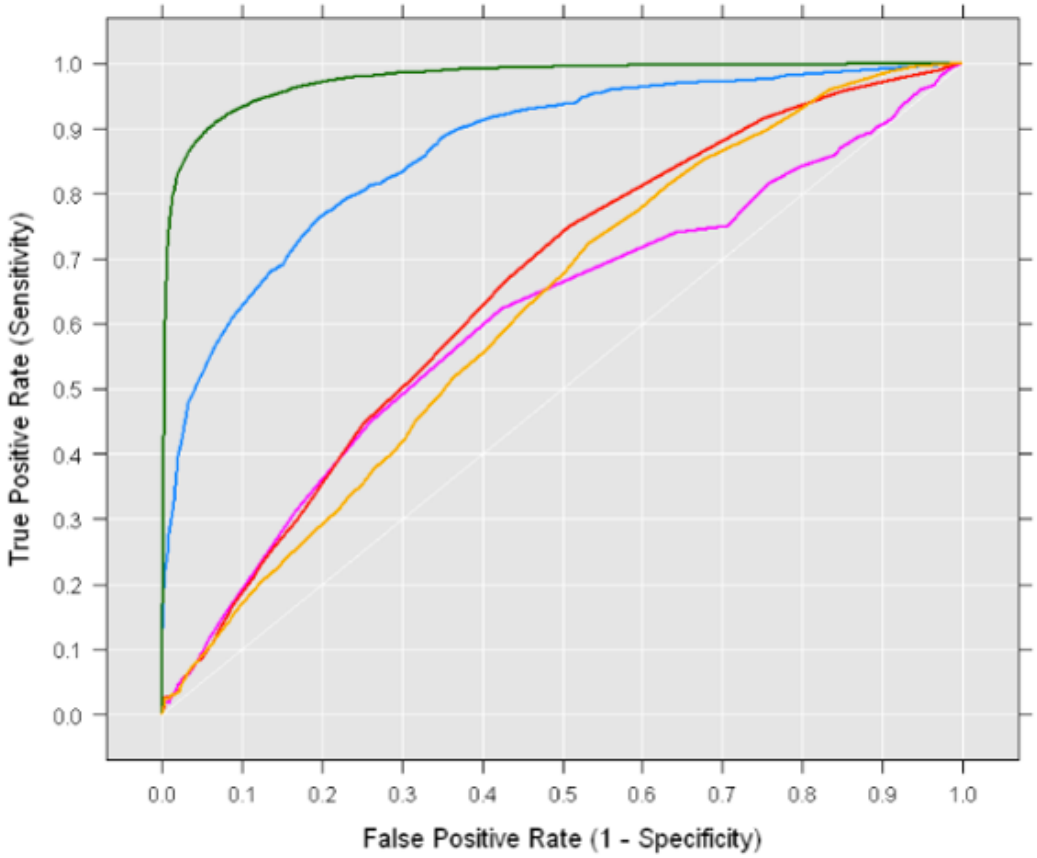

Score distribution, classes 0 and 10
density
score
classlabel
0
10


ROC Curve
True Positive Rate
False Positive Rate
5.5
6
6.5
7

• ROC Curves – Vergleich von Klassifikatoren

- Auftragen der ROC-Kurven
- Vergleich dieser

- Area under the curve (AUC)
- Einzelne Zahl, die die Fläche unter der Kurve bestimmt



https://www.displayr.com/what-is-a-roc-curve-how-to-interpret-it/

Evaluation von Klassifikatoren

- Richtige Evaluation der Klassifikatoren ist extrem wichtig um die Güte der Klassifikatoren zu bestimmen
- Wir müssen sicherstellen, dass unser Klassifikator gut generalisiert

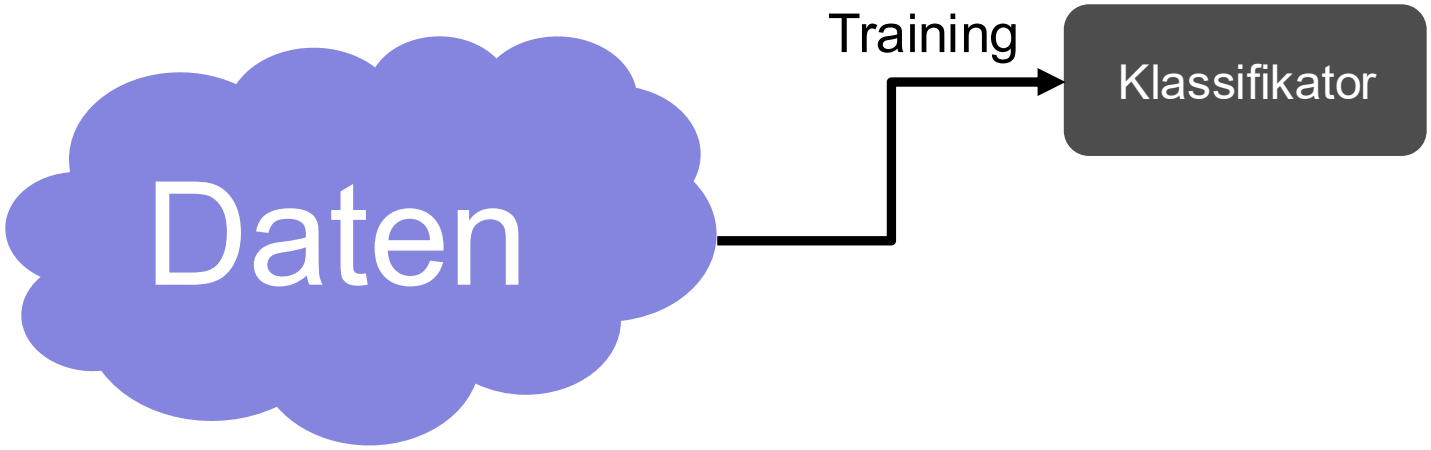
Warum und wie?

Evaluation von Klassifikatoren – Möglichkeiten

- Training = Test
- Hold-out
- Kreuzvalidierung
  - K-fold Cross-Validation
  - Stratified K-fold
  - Leave-One-Out Cross Validation
- Anmerkungen

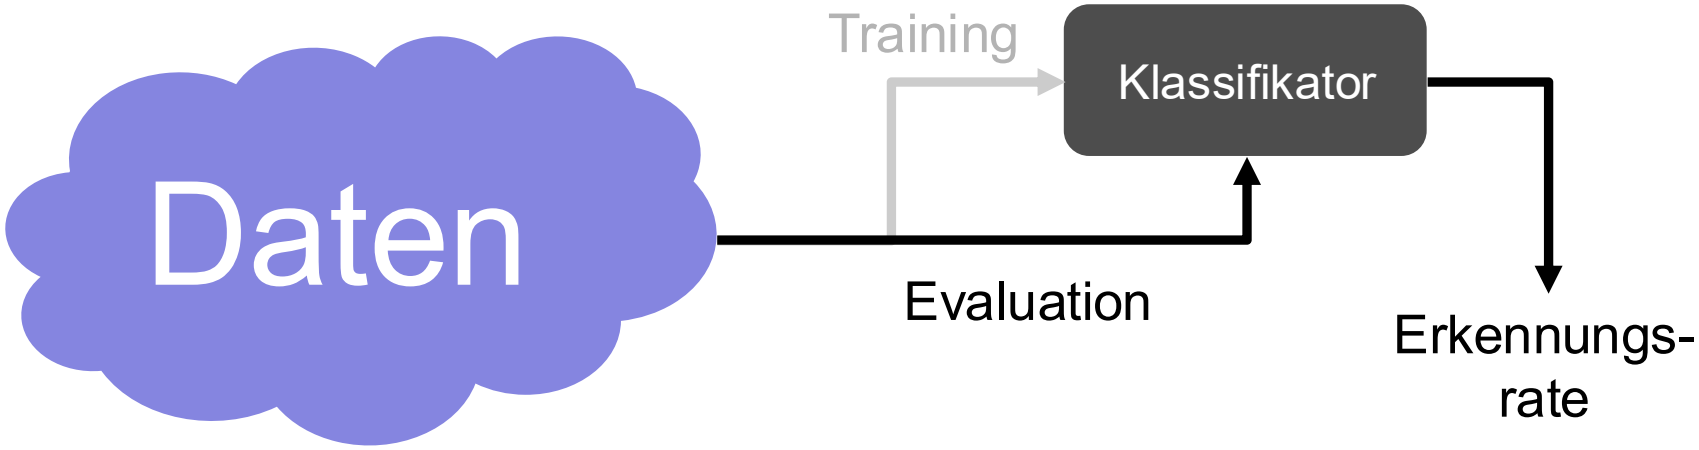
Training = Test

- Benutzen der kompletten Daten zum Trainieren
- Benutzen der kompletten Daten zum Test



Training = Test

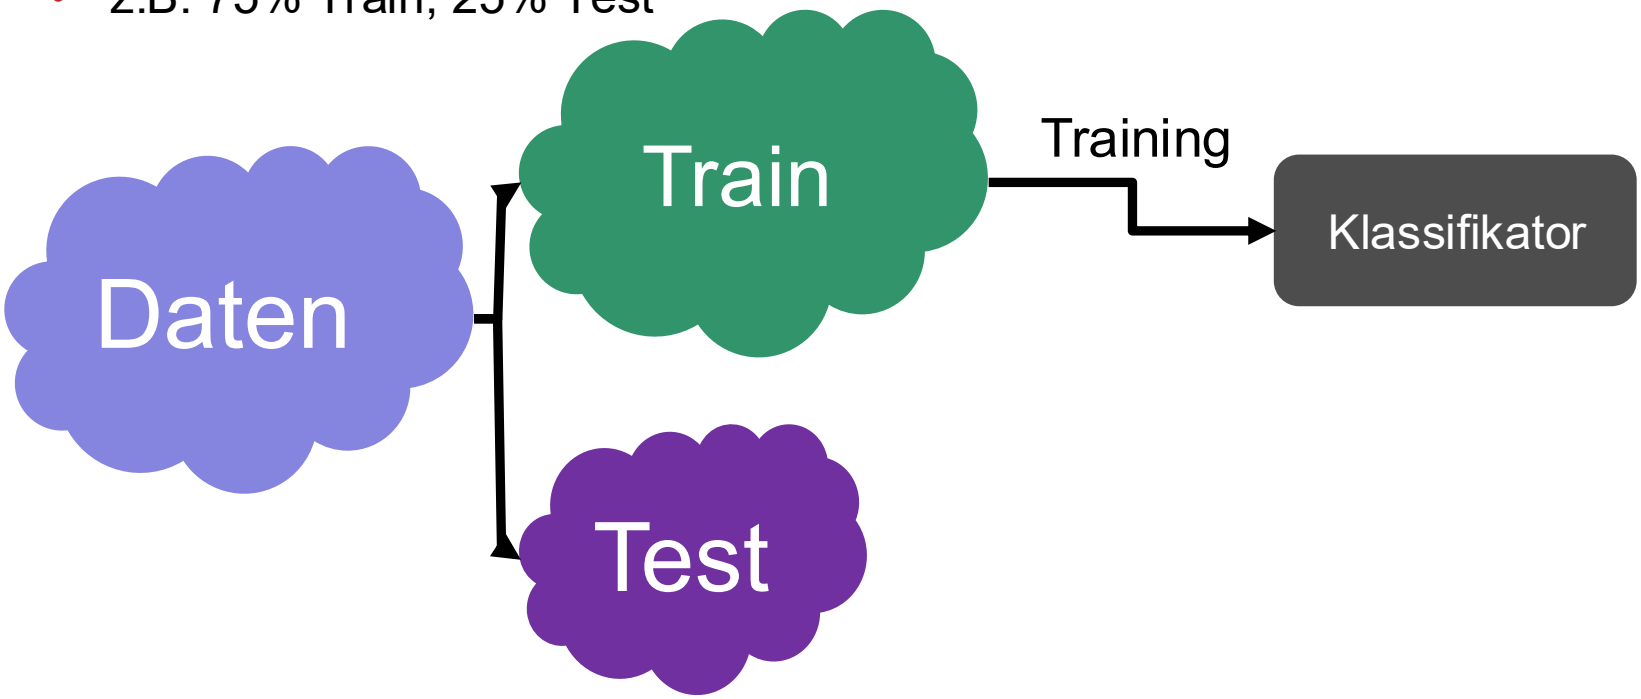
- Benutzen der kompletten Daten zum Trainieren
- Benutzen der kompletten Daten zum Test



Schlechte Einschätzung der Erkennungsrate

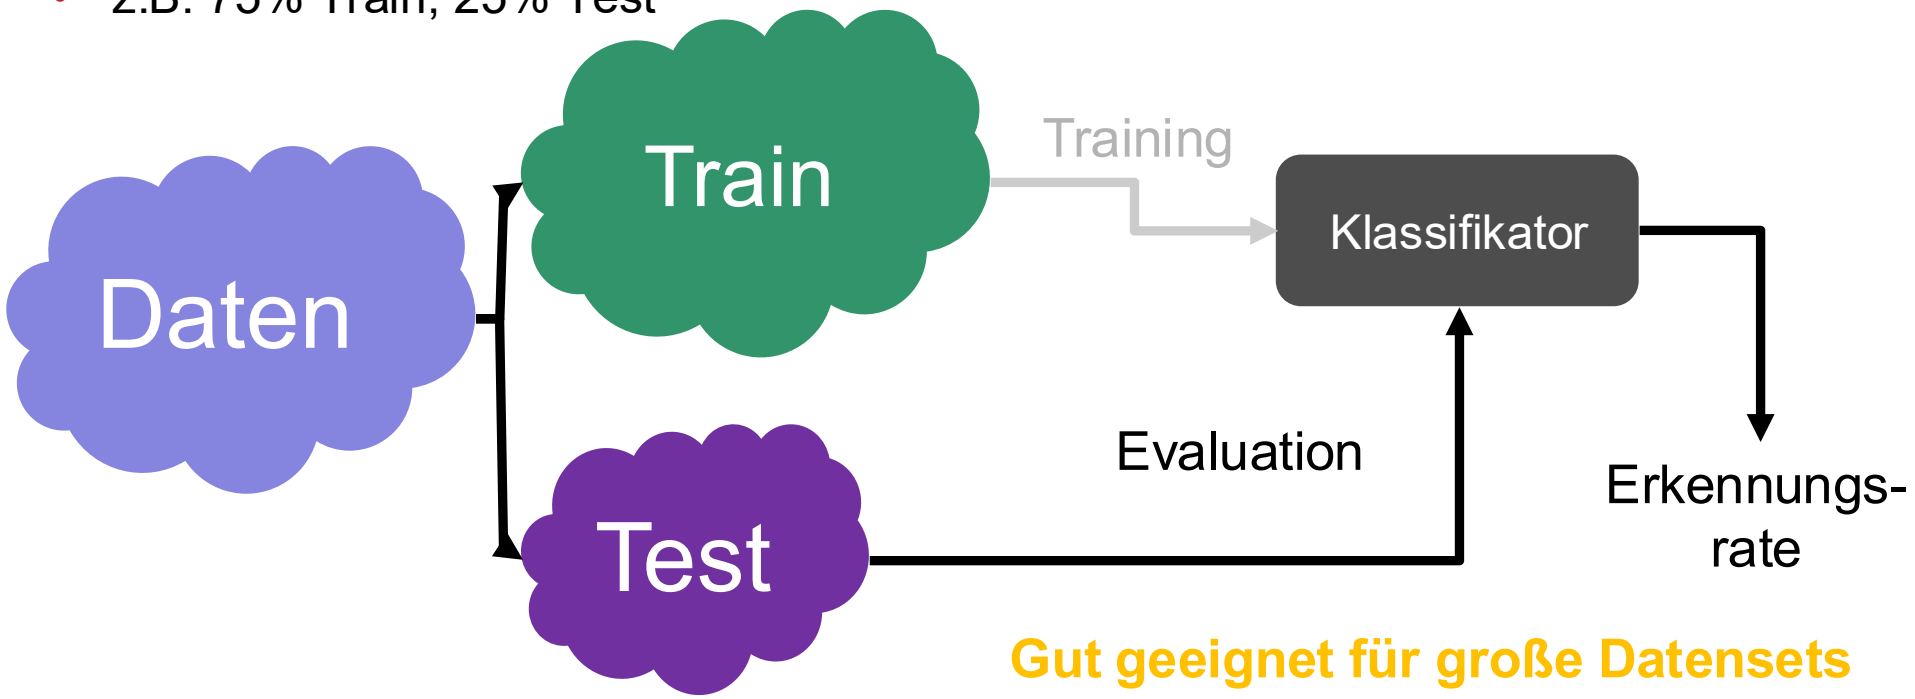
Hold-out

- Datenset wird in Training und Test-Sets geteilt
- Daten werden randomisiert geteilt
- z.B. 75% Train, 25% Test



Hold-out

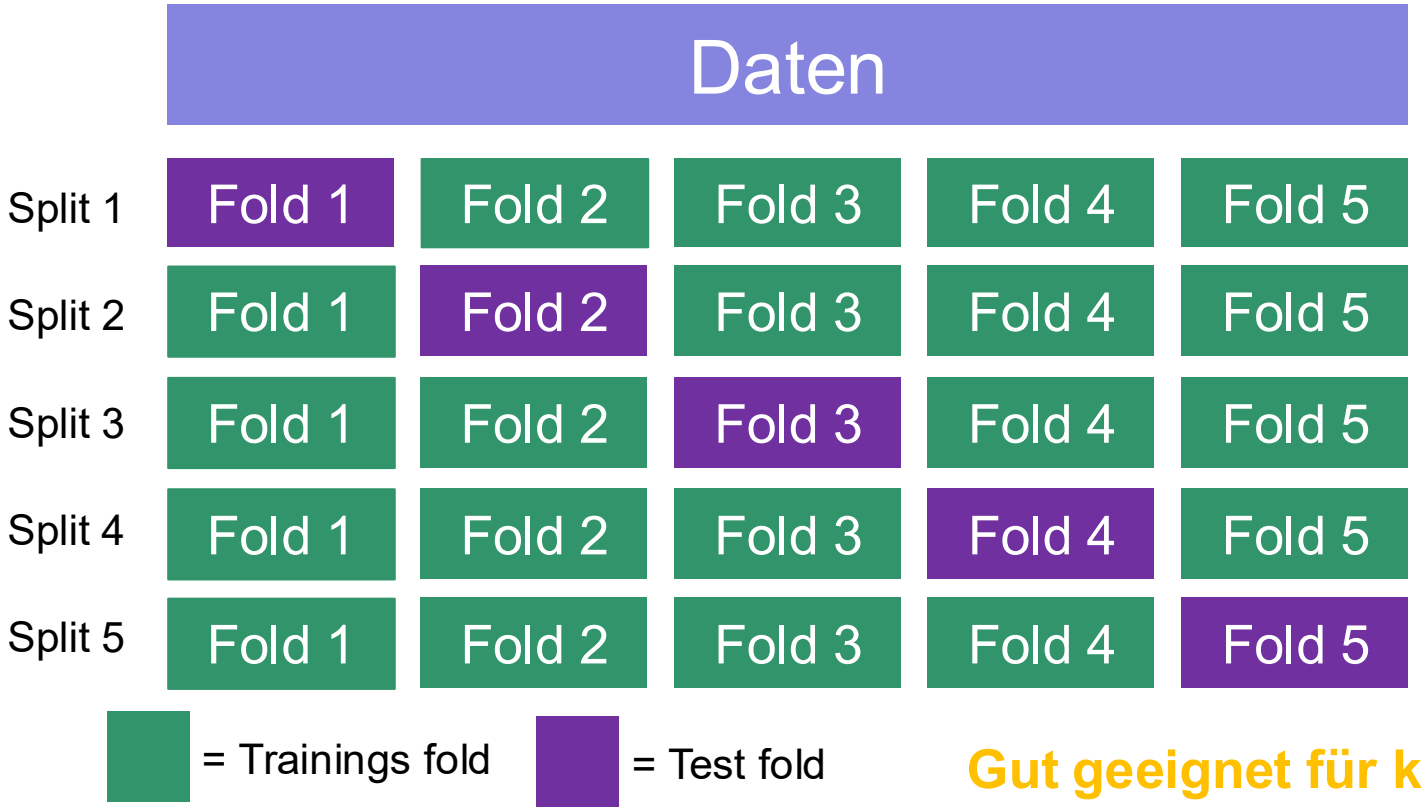
- Datenset wird in Training und Test-Sets geteilt
- Daten werden randomisiert geteilt
- z.B. 75% Train, 25% Test



Gut geeignet für große Datensets

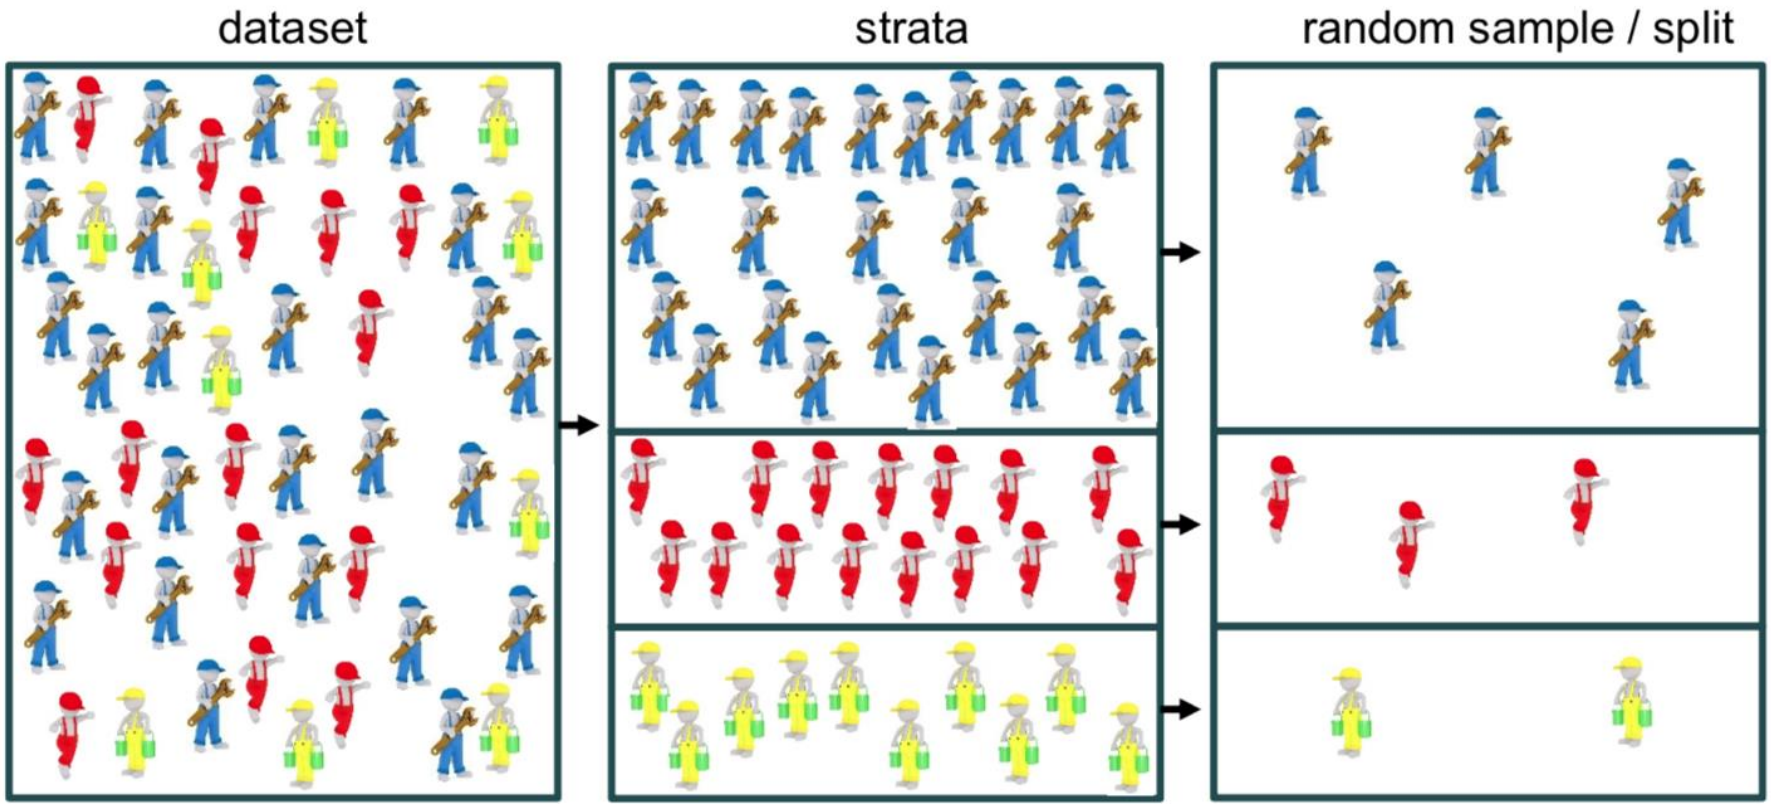
Kreuzvalidierung – k-Fold

- Datensatz wird in k-Blöcke eingeteilt



Gut geeignet für kleiner Datensets

Kreuzvalidierung – stratified k-Fold



https://en.wikipedia.org/wiki/Stratified_sampling

Kreuzvalidierung – stratified k-Fold

- Gleiche Einteilung wie k-Fold Kreuzvalidierung
- Allerdings sind die *Splits* so gewählt, dass die die Klassenverteilung in jedem *Split* der originalen Verteilung entspricht
- Sinnvoll bei nicht balancierten Datensätzen
  (Verteilung der Instanzen pro Klasse nicht gleichverteilt)
- Verhindert, dass die Folds keine Beispiele einer Klasse haben

Kreuzvalidierung – Leave-One-Out

- Erweiterung der k-Fold Kreuzvalidierung
- k= Anzahl der Instanzen N
- Klassifikator wird
  - immer auf N-1 Instanzen trainiert
  - Auf der verbleibenden getestet

Zusatz: Optimieren von Hyperparametern des Klassifikators

- Einteilung nach Train/Dev/Test
  - zuerst Train/Test Einteilung
  - Danach Train nochmals in Train/Dev aufteilen
  - z.B. 80%/20%
- Nachteil: Verkleinert Trainingsset nochmals
- Eventuelle Lösung:
  - K-Fold Kreuzvalidierung

  oder
  - Leave-one-Out

Zusammenfassung

- Training = Test
  - Nein!, nicht benutzen
- Hold-out (Einteilung in ein Trainings- bzw. Testset)
  - Gut für große Datensets
  - Nicht sonderlich rechenaufwendig
  - Größe der splits abhängig von der Größe des Datensets
  - Häufig verwendet: train/test: 80%/20%, 70%/30%
- Cross-Validation
  - Gut für keinere Datensätze
  - Rechenaufwendig
  - Stratification um nicht balancierte Datensätze zu handhaben

Next on Maschine Learning…

Clustering und KMeans