Technische Hochschule Nürnberg

Unüberwachtes Lernen
Clustering

Prof. Dr. Tobias Bocklet

Machine Learning



Überwachtes Lernen

- Datensatz mit Merkmalvektoren

$$\mathbf{x} = (x_1, x_2, \ldots, x_d)$$

- Trainingsbeispiele $\boldsymbol{x_i}$ mit Labels $\mathrm{y_i}$

$$\mathcal{D} = \{(\mathbf{x}_i, y_i), i = 1, \ldots, n\}$$

Unüberwachtes Lernen

- Datensatz mit Merkmalvektoren

$$\mathbf{x} = (x_1, x_2, \ldots, x_d)$$

- Trainingsbeispiele $\boldsymbol{x_i}$ ~~mit Labels y_i~~

$$\mathcal{D} = \{(\mathbf{x}_i, \sout{y_i}), i = 1, \ldots, n\}$$

Unüberwachtes Lernen

- Unterschied zum überwachten Lernen:

  Keine gelabelten Daten
- System kann nicht ohne weiteres trainiert werden
- Wozu sinnvoll?
  - Clustern → Finden von Häufungsgebieten
  - Anomalieerkennung → Wann weicht etwas von der Norm ab
  - Visualisierung und Dimensionsreduktion
- Beispiele:
  - Thematisches Clustern von blogs
  - Clustern von Bildern mit ähnlichem Inhalt
  - Gruppieren von Kunden

Heutige Lerninhalte

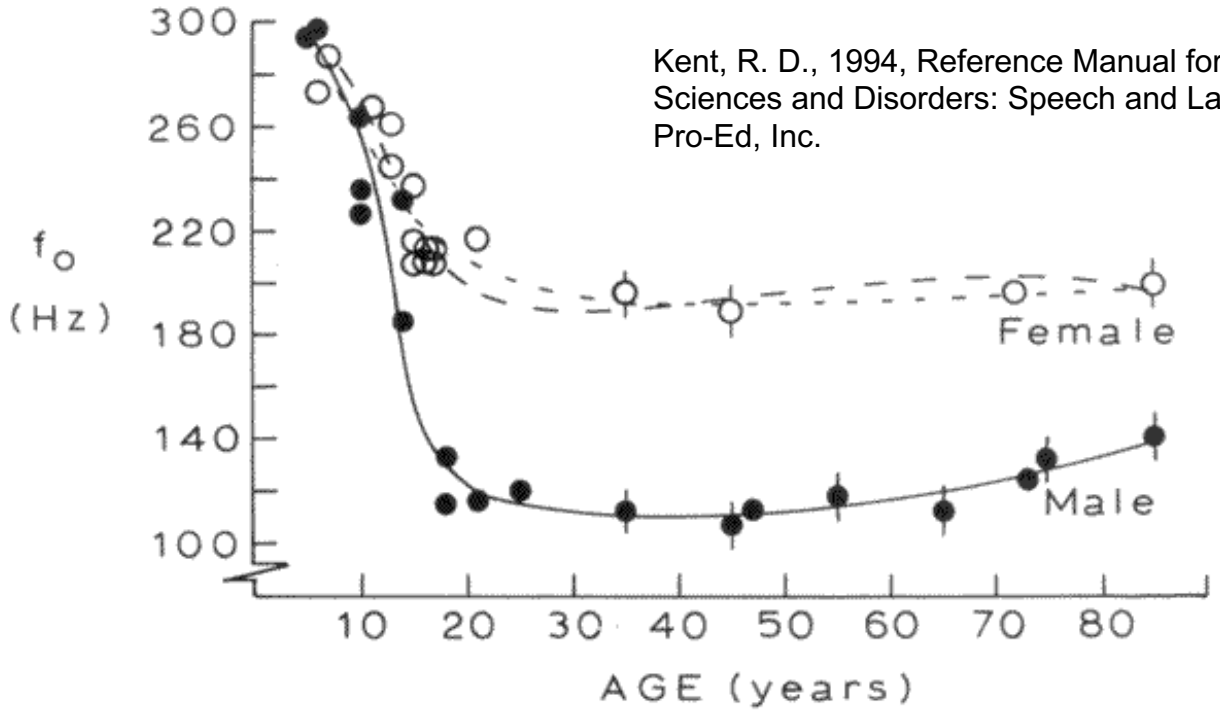
- Unüberwachtes Lernen
- Distanzen
- Clustering
  - Hierarchisches Clustering
  - k-Means
- Zusammenfassung

Was ist Clustering?

- Ein Cluster ist eine Zusammenfassung von Datenpunkten
- Ziel des Clusterns:
  - Finde eine repräsentative Zusammenfassung der Datenpunkte
  - Endliche Zahl von Clustern
  - **Klassen-Labels sind A-priori unbekannt**

Male and Female Voices

Average pitch, age and sex correlate

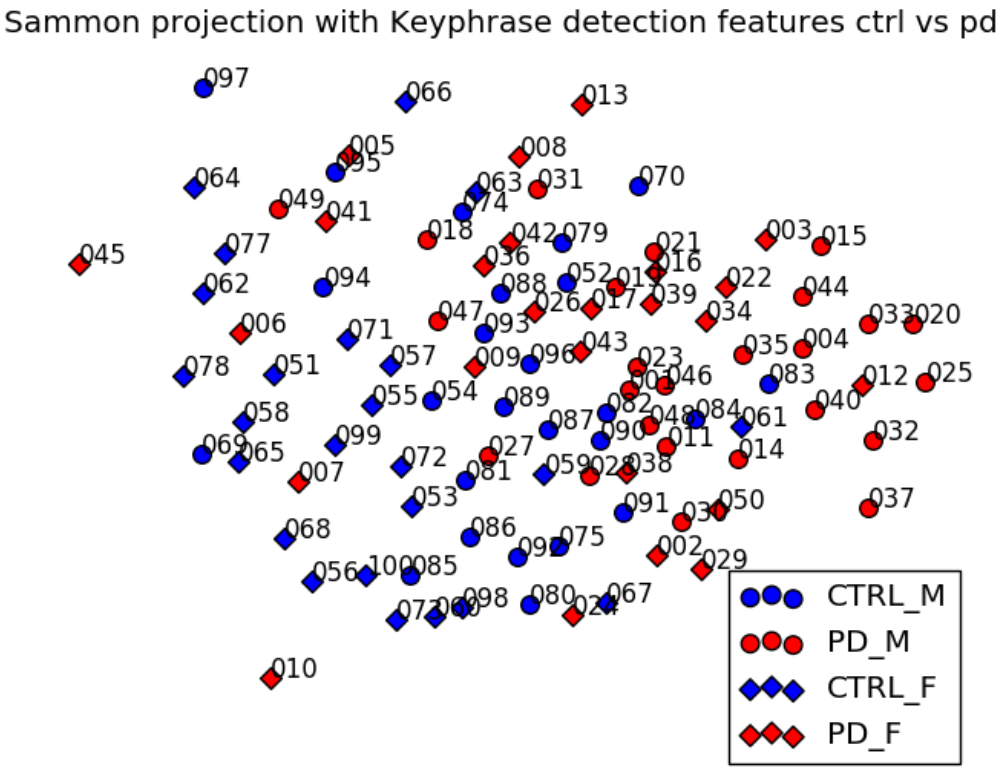


Kent, R. D., 1994, Reference Manual for Communicative Sciences and Disorders: Speech and Language, First Edition, Pro-Ed, Inc.

Face Clustering : Hybrid



Unüberwachtes Lernen



Was ist Clustering?



Wie viele Cluster?



Klar: 2



Oder vielleicht 4?



…or sogar 6?

Clustering ist Optimierungsproblem

$$variability(c) = \sqrt{\sum_{e \in c} distance(mean(c), e)^2}$$

$$dissimilarity(C) = \sum_{c \in C} variability(c)$$

Typen von Clustering Algorithmen

Hierarchischs Clustering:

- *Agglomerativ/*Bottom up: Beginne mit *n* >> *k* Clustern, kombinieren, bis *n=k erreicht ist*
- *Top Down*: Begine mit *n=1* Cluster, und splitte bis n=k

Partitionierung:

- Jedes Trainingsbeispiel gehört genau einem Cluster an
- Wird mit Anzahl finaler Cluster initialisiert

Soft/Hard Clustering:

- Hard: Samples gehören genau einem Cluster an
- Soft: Samples gehen gewichtet in die Cluster ein

Hierarchisches Clustering

1. Starte damit jedes Trainingsbeispiel einem eigenen Cluster zuzuweisen.
   Mit N Trainingsbeispielen, bekommt man N Cluster, also ein Beispiel pro Cluster.
2. Finde die nächsten (ähnlichsten) Cluster (bzgl. einer Distanzmetrik) und kombiniere (linke) diese in einen Cluster.
   Ausgabe: N-1 Cluster
3. Fahre fort bis alle N Beispiele in einem Cluster zusammengefasst sind.

Themen

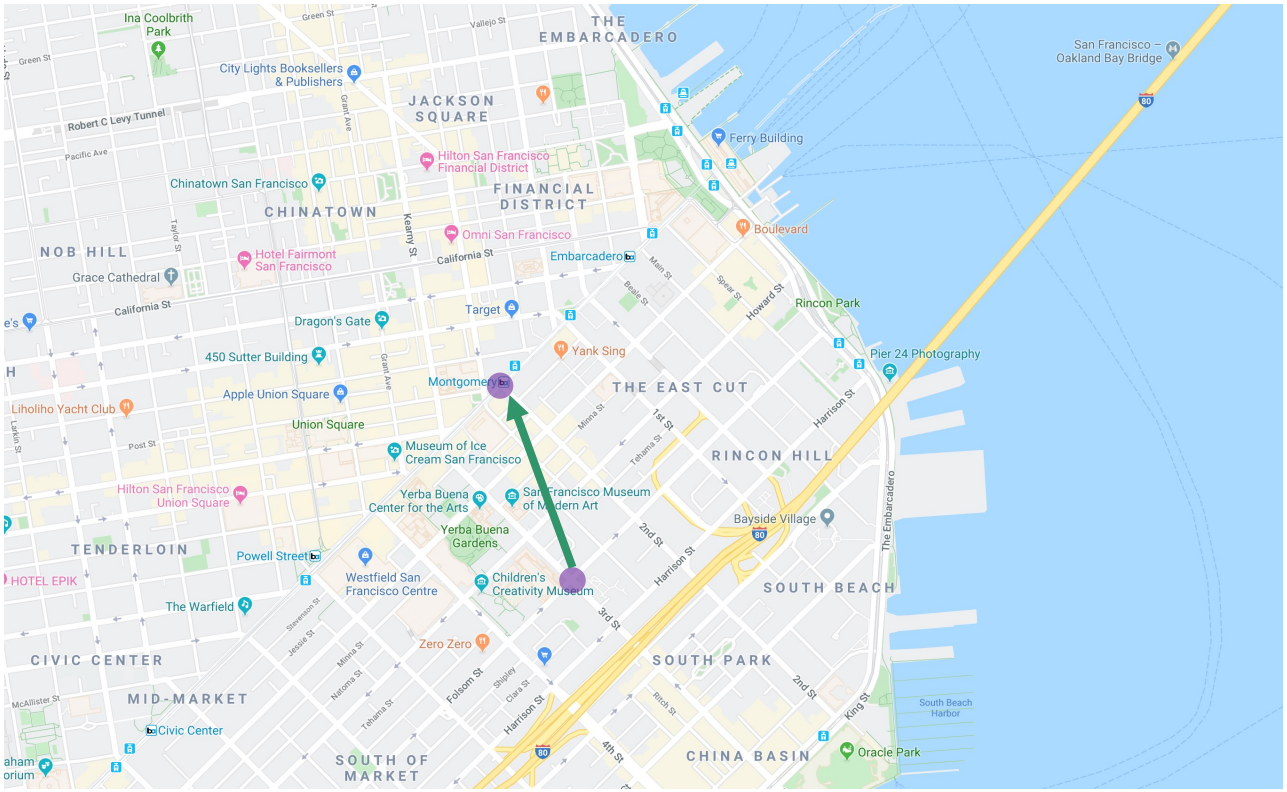
1. Was sind Distanzen?

   Nächsten Folien

1. Wie genau bestimme ich den Abstand zweier Cluster?

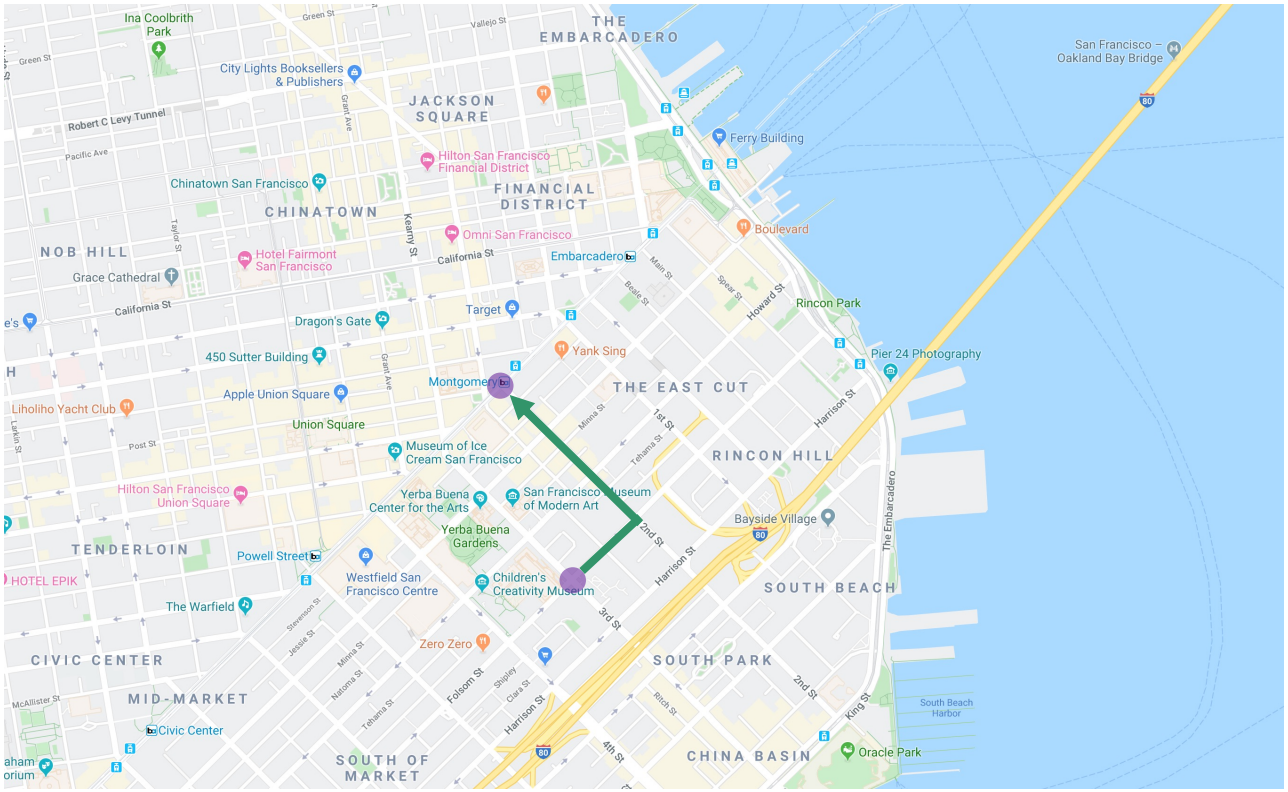
   Verknüpfungsmetrik/Linkage metrics

Distanzen – Numerische Werte



- Euklid-Abstand (L_2-Norm): $\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$

Distanzen – Numerische Werte



Citiblock bzw. Manhattan-Abstand (L_1-Norm): $\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = |x_1 - y_1| + |x_2 - y_2| + \cdots + |x_n - y_n|$

Distanzen – Numerische Werte

- Werden auch *norm* oder *kernel* genannt
- Maximum-Norm (L_∞-Norm):

$$\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = \max\left(\left|x_1 - y_1\right|, \left|x_2 - y_2\right|, \ldots, \left|x_n - y_n\right|\right)$$

- Minkowski-Distance (L_p-Norm):

$$\mathrm{d}(\boldsymbol{x}, \boldsymbol{y}) = \sqrt[p]{\left|x_1 - y_1\right|^p + \left|x_2 - y_2\right|^p + \cdots + \left|x_n - y_n\right|^p}$$

Cosine-Distance https://en.wikipedia.org/wiki/Cosine_similarity
Jaccard Index https://en.wikipedia.org/wiki/Jaccard_index
Hamming-Distance https://en.wikipedia.org/wiki/Hamming_distance
Mahalanobis-Distance https://en.wikipedia.org/wiki/Mahalanobis_distance

Distanzen für Binäre/Kategorielle Daten

- Hamming-Distanz
  - Annahme: 2 Vektoren gleicher Dimension
  - Zähle Anzahl der unterschiedlichen Werte
- Gleiches Gewicht für indviduelle Distanzen
- Beispiel: Hamming distances

Linkage-Metriken

- Single Linkage: Distanz zweier Clustern (C1 und C2) ist gleich der **kürzesten** Distanz jedes Mitglieds aus C1 zu jedem Mitglied aus C2.

- Complete Linkage: Distanz zweier Cluster (C1 und C2) ist gleich der **größten** Distanz jedes Mitglieds aus C1 zu jedem Mitglied aus C2.

- Average Linkage: Distanz zweier Cluster (C1 und C2) ist gleich der **durchschnittlichen** Distanz jedes Mitglieds aus C1 zu jedem Mitglied aus C2.

Beispiel des hierarchischen Clusterings

	BOS	NY	CHI	DEN	SF	SEA
BOS	0	206	963	1949	3095	2979
NY		0	802	1771	2934	2815
CHI			0	966	2142	2013
DEN				0	1235	1307
SF					0	808
SEA						0

Distanzen (Flugmeilen zwischen Städten in USA)

Hierarchisches Clustering – Zusammenfassung

- Kann die Anzahl der Cluster mit Hilfe des Dendograms bestimmen
- Deterministisch
- Flexibel bzgl. Linkage- und Distanz-Kriterien
- Langsam
  - Naiver Algorithmus $O(n^3)$
  - $O(n^2)$ möglich für Single-Linkage mit Optimierungen

- K-means sehr viel schnellerer *greedy* Algorithmus
  Am sinnvollsten, wenn Anzahl der Cluster a-priori bekannt sind

K-means

Wähle randomisiert k Trainingsbeispiele als initiale Centroids

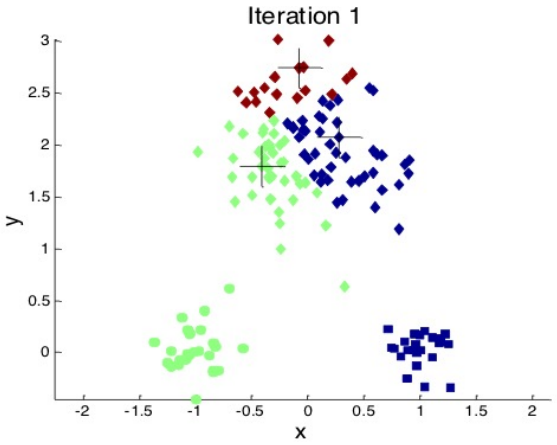
While true:

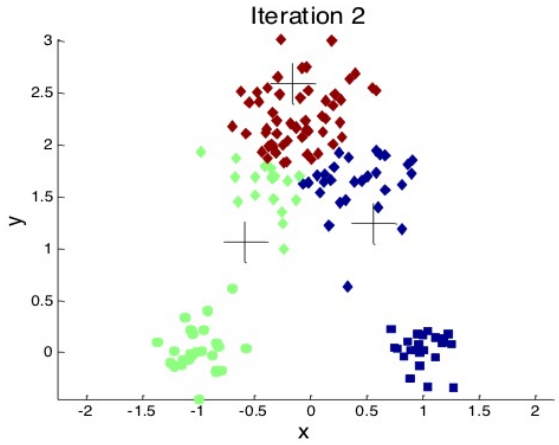
    ordne jedes Beispiel dem Cluster zu, mit dem geringsten Abstand zum Centroid (**Expectation**)

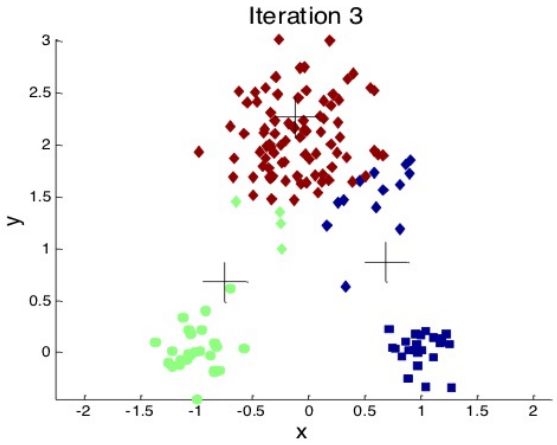
    berechne k neue Centroids durch Mitteln der Datenpunkte pro Cluster (**Maximization**)

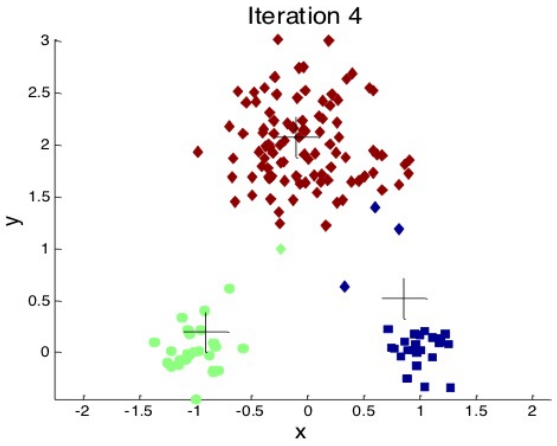
Komplexität?

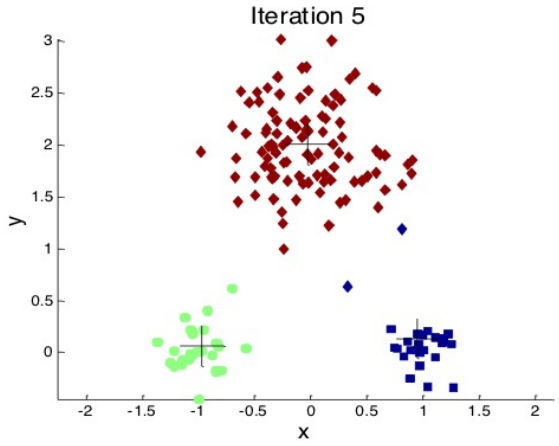
k-means: Beispiel

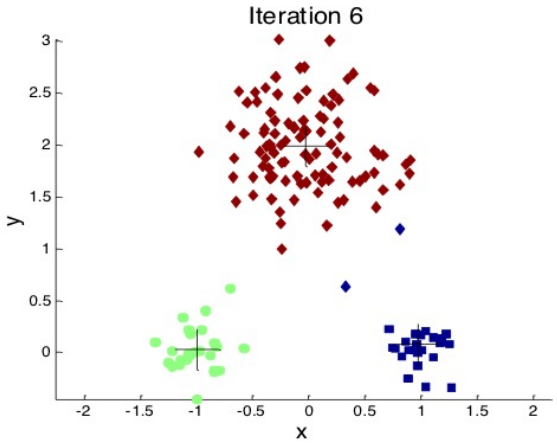










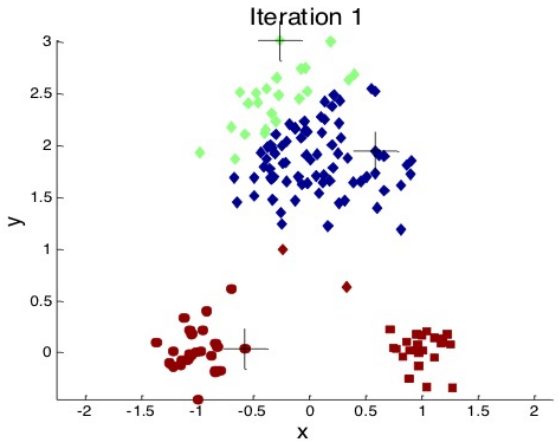


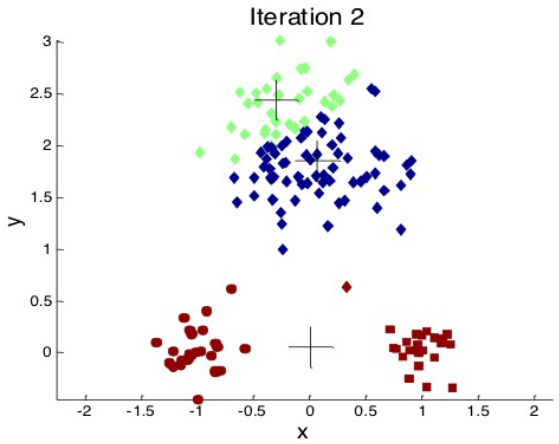
Wie k Bestimmen?

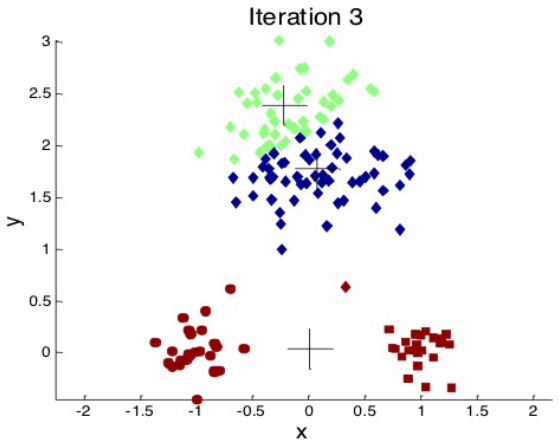
- A-priori Wissen/domänenspezifisches Wissen
  - Gutartige/Bösartige Tumore
  - Fünf unterschiedliche Bakterientypen
  - Parkinson vs. Gesund

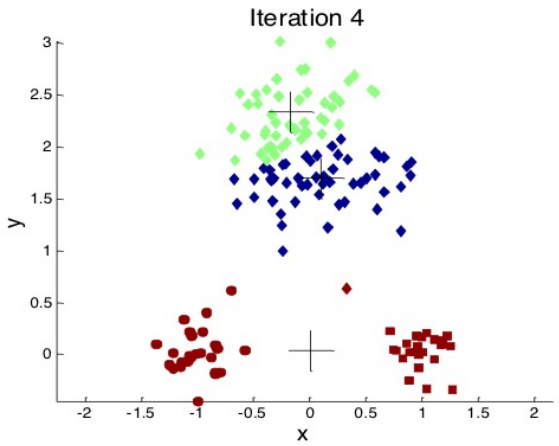
- Suchen eines guten Wertes für k
  - Ausprobieren unterschiedlicher Werte und evaluieren der Ergebnisqualität
  - Hierarchisches Clustern auf einem Subset
  - Elbow-Method

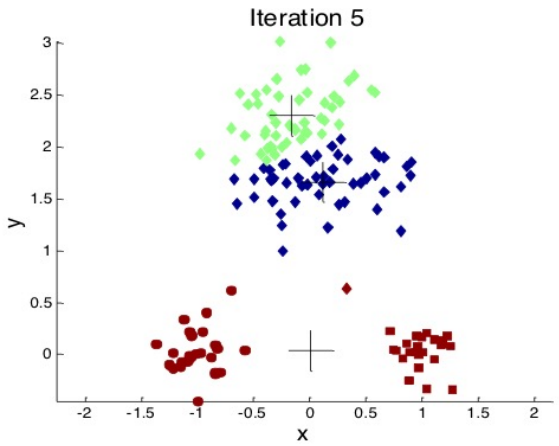
k-means: Initiale Centroids



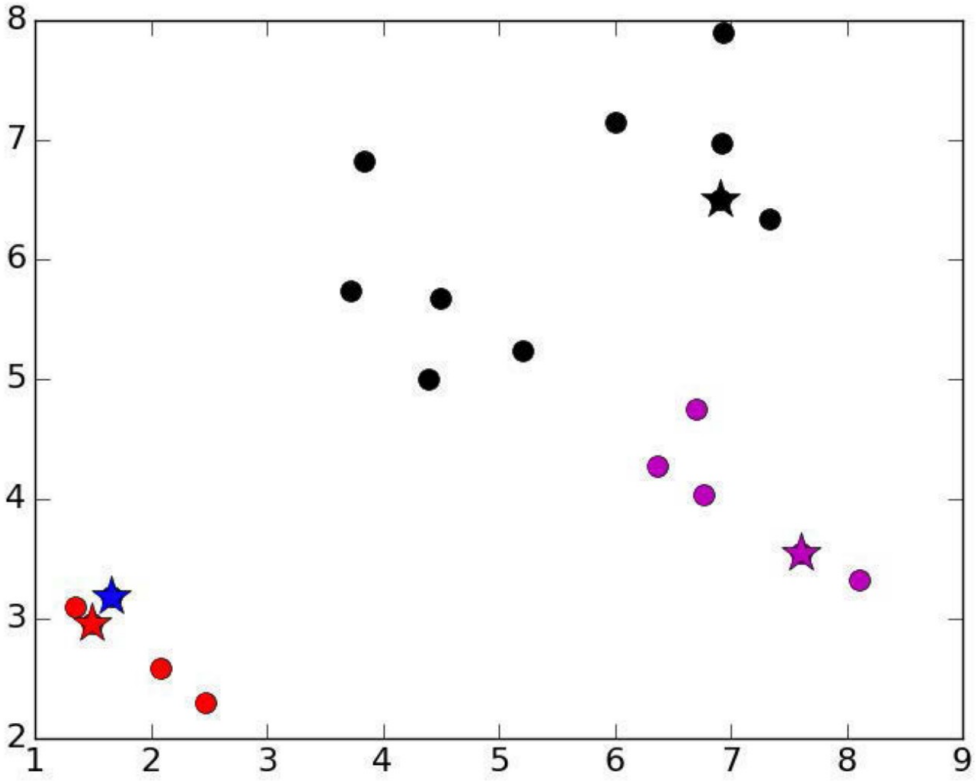




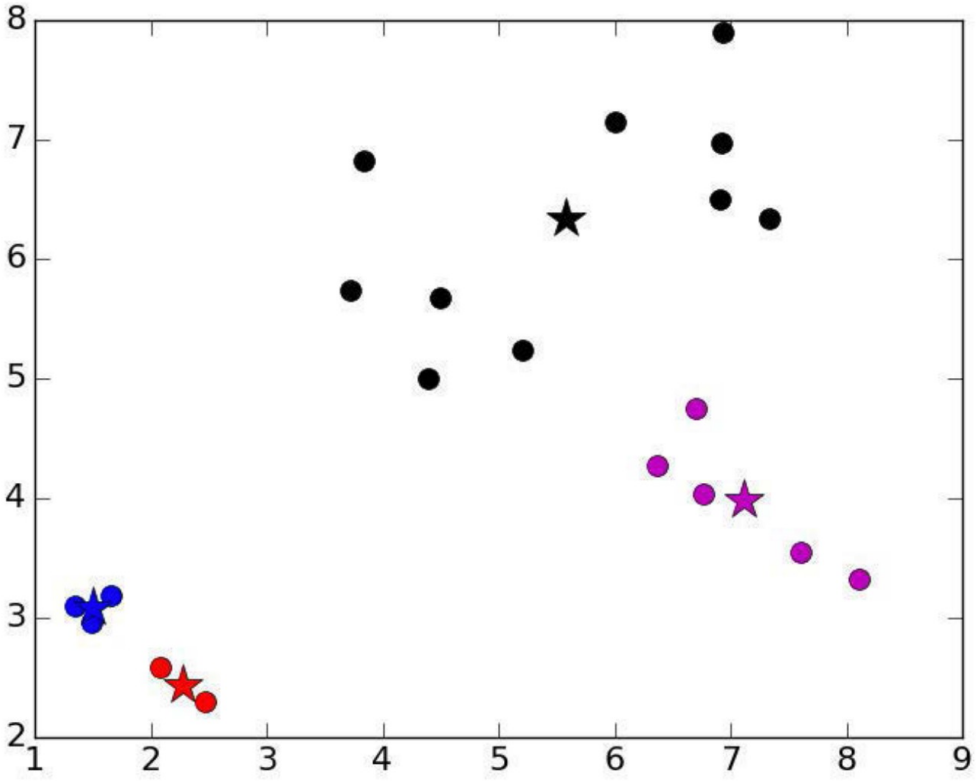




Initialisierung



Initialisierung



Verringern des Problems der initialen Gewichte

- Ausprobieren unterschiedlicher Initialisierungen
- Auswählen des besten Ergebnisses

```
best = kMeans(dataset)
for t in range(numTrials):
        C = kMeans(dataset)
        if dissimilarity(C) < dissimilarity(Best):
                best = C
return best
```

k-Means: Zusammenfassung

Vorteile

- Gute Ergebnisse auf numerischen Daten
- Ziemlich effizient: $\mathbf{O}(nki)$, n Beispiele, k Cluster, i iterations
- Einfache implementierung

Nachteile

- Nicht ideal auf nicht-numerischen Daten
- k muss gewählt werden
- Cluster sollten im Euklidischen Raum Convex sein
- Greedy → lokales Optimum, abhängig von den initialen Centroiden

Zusammenfassung

- Distanzen
- Hierarchisches Clustering
- k-Means