Technische Hochschule Nürnberg

Merkmale der Sprachverarbeitung

Prof. Dr. Tobias Bocklet

Heutige Lerninhalte

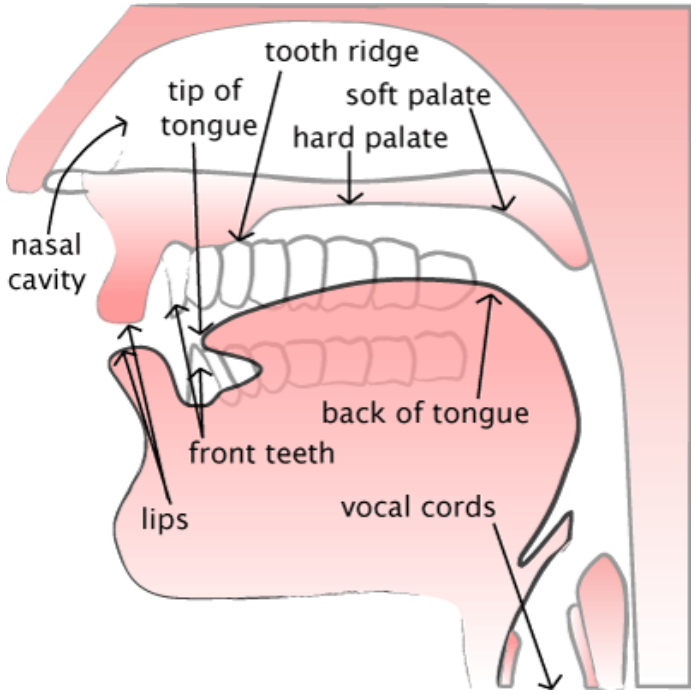
- Wie klassifiziert man Sprachsignale
- Grundlagen Audio Signale / Sprache
- Berechnung von Merkmalen auf dem Sprachsignal
- Mel Frequency Cepstrum Coefficients
- Clustern der MFCCs auf Vokalen mit kMeans

Übung

- Geschlechtsklassifikation anhand des Sprachsignals mit kNN

Sprachproduktion

- Schallproduktion
  - Stimmbänder
- Klangformung
  - Rachenraum, Mundraum, Nasenraum
  - Vokaltrakt (Zunge, Lippen, Zähne, etc.)
  - Glottale Impulse → Vokaltrakt als Filter

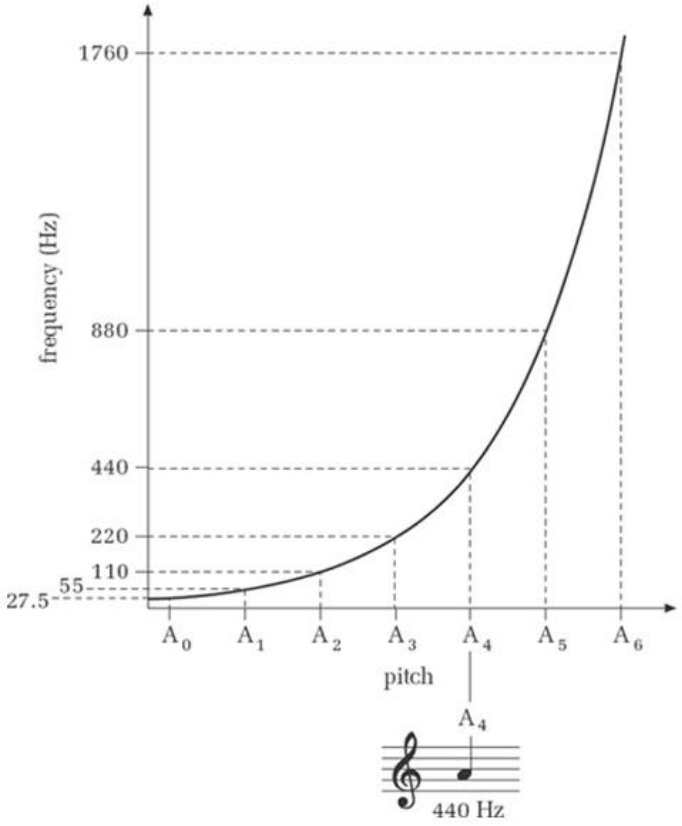


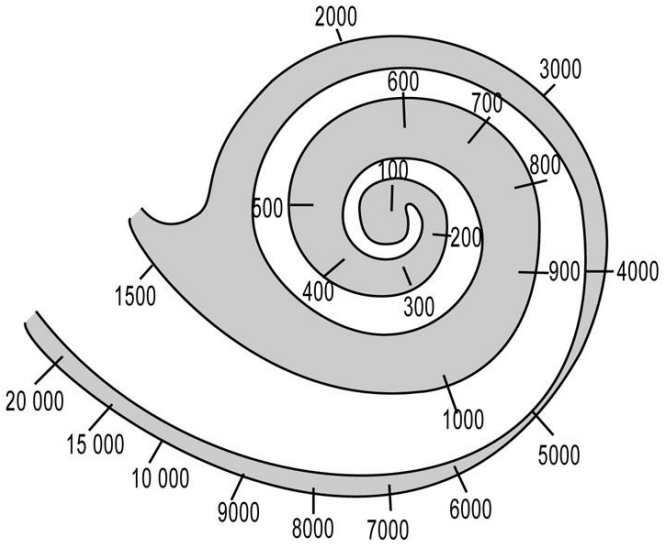
Quelle: https://pronuncian.com/the-vocal-tract

Menschliche Wahrnehmung

- Wahrnehmung durch Luftdruck
  - Schwankungen im Bereich von ca. 20 Hz – 20 kHz hörbar
- Frequenz
  - Objektives, wissenschaftliches Attribut, das gemessen werden kann
- Tonhöhe (Pitch)
  - Auditive Empfindung, Töne werden einer relativen Position auf einer Skala zuordnet
  - Beruht in erster Linie auf der Wahrnehmung der Schwingungsfrequenz (Tonfrequenz)
  - Logarithmische Wahrnehmung

Menschliche Wahrnehmung

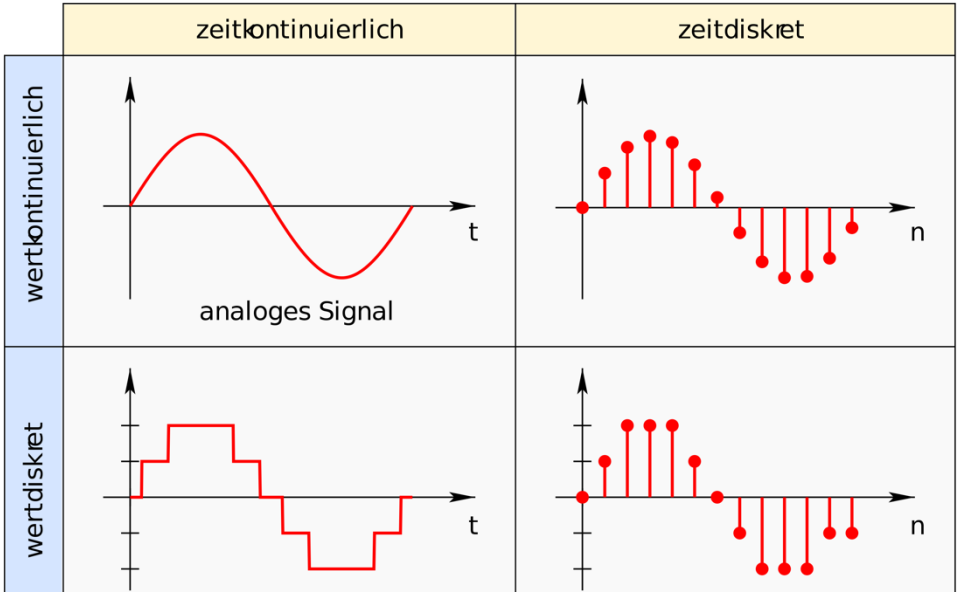


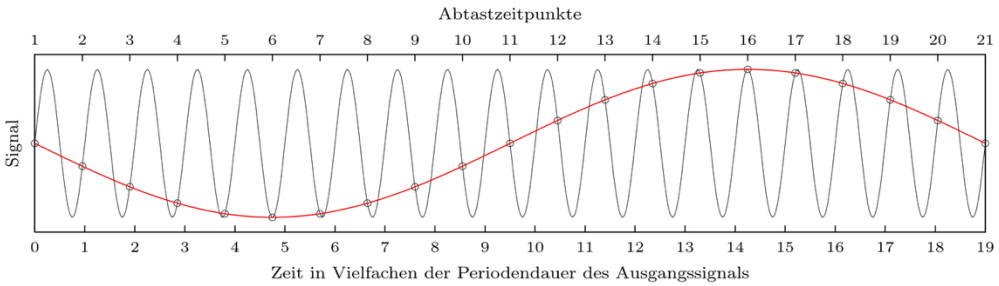


Quelle: Medienportal der Siemens Stiftung

Audio Signale

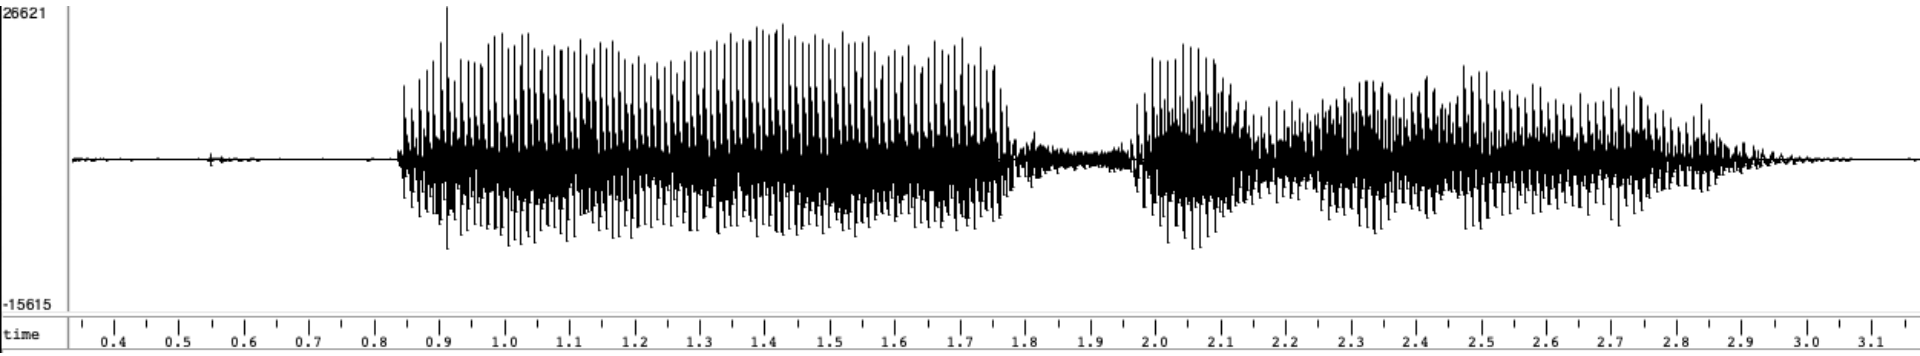
- Analoges Signal
  - Kontinuierlich
  - Prinzipiell beliebig genau
- Digitales Signal
  - Sampling (Hz)
  - Quantisierung
    - Auflösung: Anzahl von Bits
  - Pulse Code Modulation (PCM)





Das Sprachsignal – Wellenform

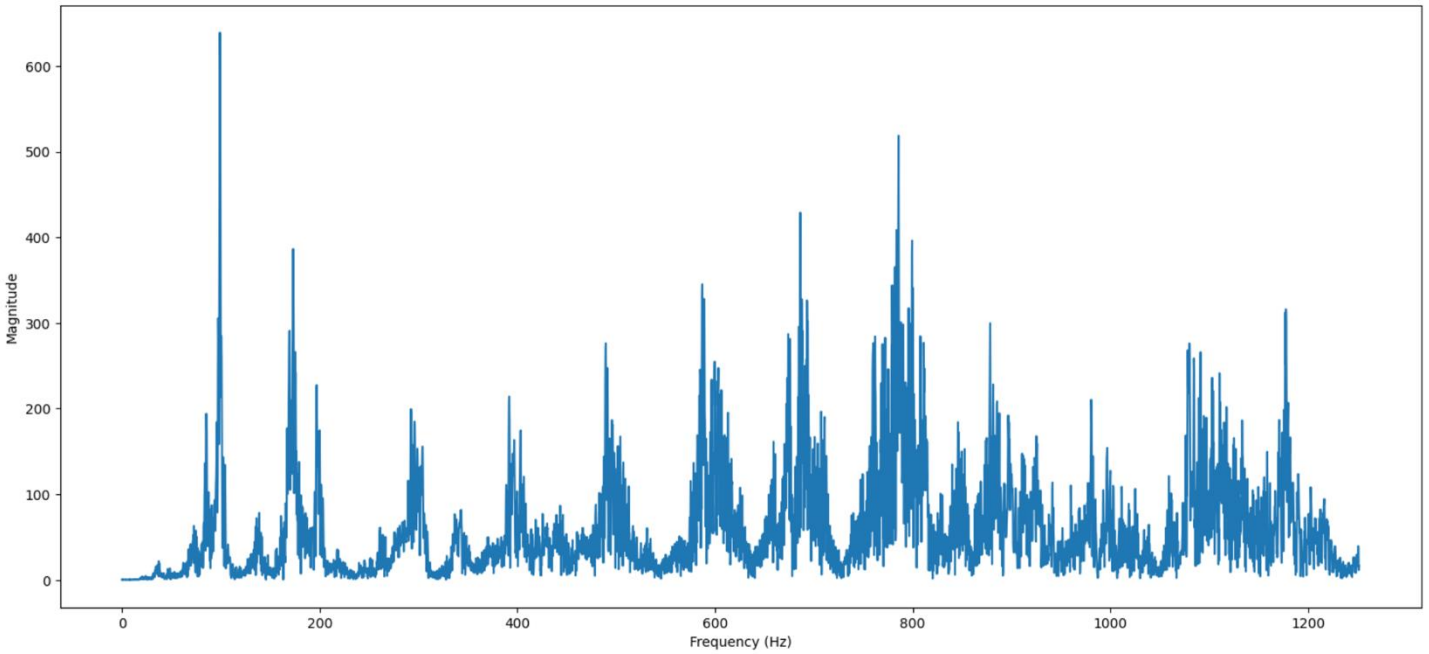
- Zeit-Domäne



Geeignete Tools:
- Audacity (https://www.audacityteam.org/)
- Wavesurfer (https://sourceforge.net/projects/wavesurfer/)

Das Sprachsignal – Spektrum

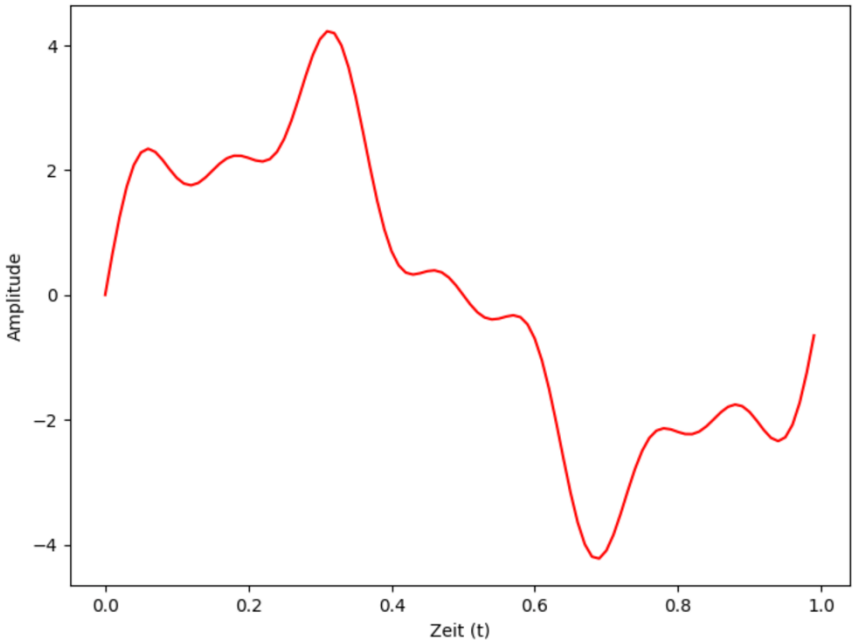
- Fourier-Transformation
- Frequenz-Domäne

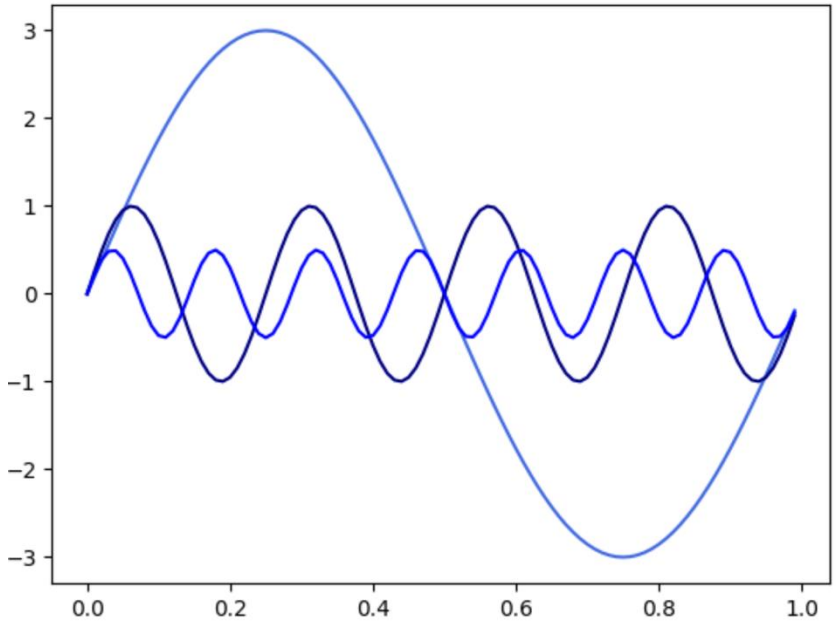


Die Schnelle Fourier-Transformation

Prof. Dr. Tobias Bocklet

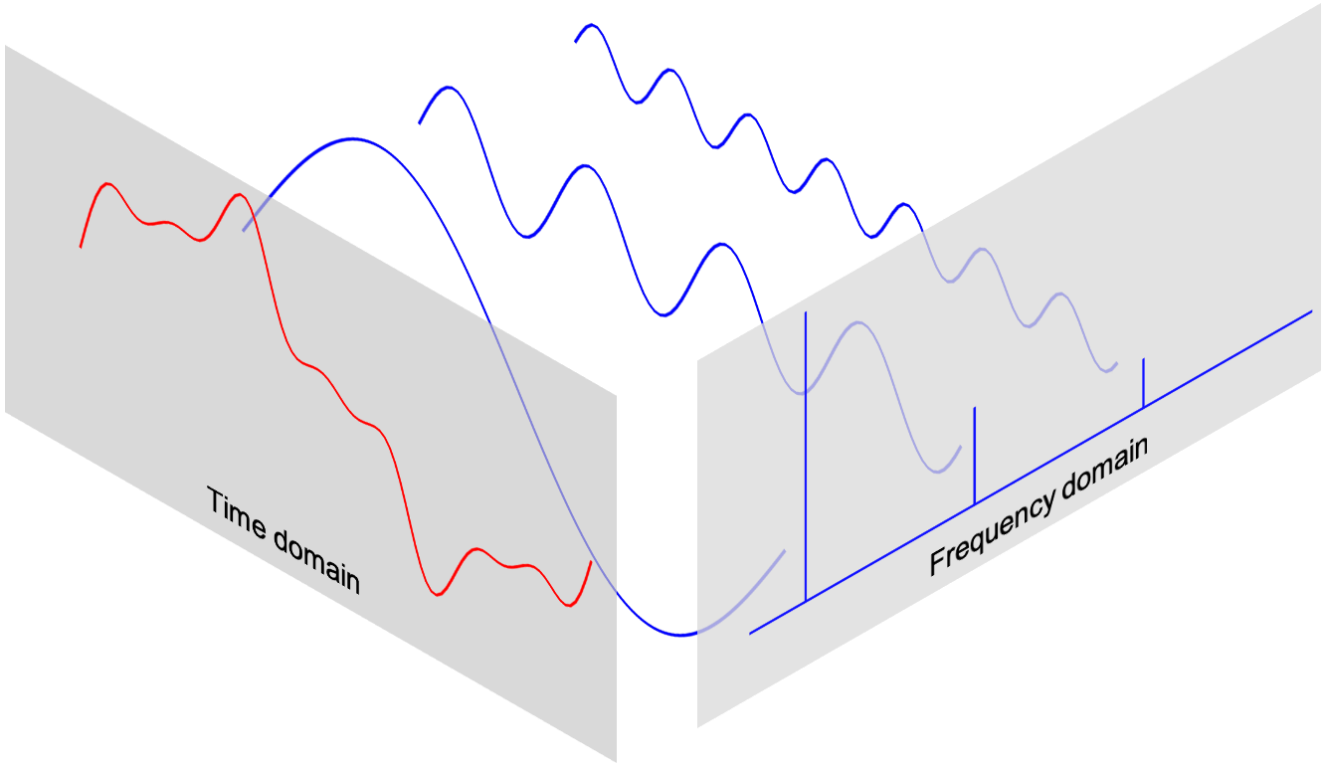
Motivation





f(t) = 3*sin(2*pi*1*t)+ sin(2*pi*4*t)+0.5*sin(2*pi*7*t)

Motivation



https://pythonnumericalmethods.berkeley.edu/notebooks/chapter24.02-Discrete-Fourier-Transform.html

Fourier-Transformation

Jede (quadratisch integrierbare) Funktion $f: \mathbb{R} \to \mathbb{C}$ kann man durch Superposition von harmonischen Schwingungen darstellen

Die Funktion $F(k)$ heißt Spektralfunktion oder Fourier-Transformierte von $f(x)$, es gilt:

$$f(x) = \int F(k)\, e^{2\pi i k x}\, dk$$

$$F(k) = \int f(x)\, e^{-2\pi i k x}\, dx$$

Diskrete Fourier Transformation (DFT)

Unser Signal wird periodisch abgetastet

Statt kontinuierlicher Funktion $f(n)$ nun diskretes Signal mit N Abtastwerten

Approximation des Integrals durch Partialsummen (mit N Summanden)

Die DFT ist definiert durch:

$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i k n / N}$$

Diskrete Fourier Transformation (DFT)

Die DFT kann in eine Matrix-Vektor-Multiplikation umgeformt werden

Dazu erzeugt man eine DFT-Matrix spezifisch für N mit folgenden Einträgen:

$$DFT_N(n,k) = e^{-2\pi ikn/N};\ \mathrm{n,k} = 0,\dots,\mathrm{N}-1$$

Die Berechnung der Fourierkoeffizienten ist dann

$$\boldsymbol{X = DFT_N\, x}$$

X beinhaltet alle N Fourierkoeffizienten

Diskrete Fourier Transformation (DFT)

- Beispiel N=8:

$$\begin{pmatrix} m_{0,0} & m_{0,1} & m_{0,2} & m_{0,3} & m_{0,4} & m_{0,5} & m_{0,6} & m_{0,7} \\ m_{1,0} & m_{1,1} & m_{1,2} & m_{1,3} & m_{1,4} & m_{1,5} & m_{1,6} & m_{1,7} \\ m_{2,0} & m_{2,1} & m_{2,2} & m_{2,3} & m_{2,4} & m_{2,5} & m_{2,6} & m_{2,7} \\ m_{3,0} & m_{3,1} & m_{3,2} & m_{3,3} & m_{3,4} & m_{3,5} & m_{3,6} & m_{3,7} \\ m_{4,0} & m_{4,1} & m_{4,2} & m_{4,3} & m_{4,4} & m_{4,5} & m_{4,6} & m_{4,7} \\ m_{5,0} & m_{5,1} & m_{5,2} & m_{5,3} & m_{5,4} & m_{5,5} & m_{5,6} & m_{5,7} \\ m_{6,0} & m_{6,1} & m_{6,2} & m_{6,3} & m_{6,4} & m_{6,5} & m_{6,6} & m_{6,7} \\ m_{7,0} & m_{7,1} & m_{7,2} & m_{7,3} & m_{7,4} & m_{7,5} & m_{7,6} & m_{7,7} \end{pmatrix} \cdot \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \\ x_7 \end{pmatrix} = \begin{pmatrix} X_0 \\ X_1 \\ X_2 \\ X_3 \\ X_4 \\ X_5 \\ X_6 \\ X_7 \end{pmatrix}$$

- Aufwandsabschätzung:
  - Pro Zeile der DFT-Matrix müssen N Multiplikationen und $(N-1)$ Additionen
  - Insgesamt: $N * (N + N + 1) = 2N^2 - N$
  - Laufzeitverhalten: $\mathrm{O}(\mathrm{n}^2)$

Symmetrien in der DFT-Matrix

$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i k n/N}$$

$$X_{N+k} = \sum_{n=0}^{N-1} x_n \, e^{-2\pi i (N+k) n/N} = \sum_{n=0}^{N-1} x_n \, e^{-2\pi i n} \, e^{-2\pi i k n/N}$$

1

$$X(N+k) = \mathrm{X(k)}$$

Schnelle Fourier-Transformation

- Algorithmus um DFT effizienter zu berechnen
- Wurde 1805 von Gauß gefunden und 1965 von Cooley und Tukey wiederentdeckt
- Algorithmus basiert auf der Entdeckung, dass eine DFT gerader Größe $N = 2M$ durch die Anwendung zweier DFTs mit Größe M ausgedrückt werden kann

Schnelle Fourier-Transformation

Für die ersten M Einträge in $X(k)$:

$$X_k = \sum_{n=0}^{N-1} x_n e^{-2\pi i k n/N}$$

$$= \sum_{m=0}^{N/2-1} x_{2m} e^{-2\pi i k (2m)/N} + \sum_{m=0}^{N/2-1} x_{2m+1}\, e^{-2\pi i k (2m+1)/N}$$

$$= \sum_{m=0}^{N/2-1} x_{2m} e^{-2\pi i k m/(\frac{N}{2})} + e^{-2\pi i k/N} \sum_{m=0}^{N/2-1} x_{2m+1}\, e^{-2\pi i k m/(\frac{N}{2})}$$

Schnelle Fourier-Transformation

Für die zweiten M Einträge in $X(k)$:

$$X_{M+k} = \sum_{n=0}^{N-1} x_n e^{-2\pi i(M+k)n/N}$$

$$\boldsymbol{e^{-2\pi i(M+k)(2m)/N} = e^{-2\pi ikm/(\frac{N}{2})} e^{-2\pi im}}$$

$$= \sum_{m=0}^{N/2-1} x_{2m} e^{-2\pi i(M+k)(2m)/N} + \sum_{m=0}^{N/2-1} x_{2m+1}\, e^{-2\pi i(M+k)(2m+1)/N}$$

$$= \sum_{m=0}^{N/2-1} x_{2m} e^{-2\pi ikm/(\frac{N}{2})} \quad -e^{-2\pi ik/N} \sum_{m=0}^{N/2-1} x_{2m+1}\, e^{-2\pi ikm/(\frac{N}{2})}$$

Schnelle Fourier-Transformation

Aufwandsabschätzung:

- $\log n$ pro Rekursionsschritt
- n/2 Subtraktionen, n/2 Additionen, n/2 Multiplikationen = 3n/2 Operationen
- Laufzeitverhalten: $O(n * \log n)$

Vergleich der DFT und FFT-Operationen:

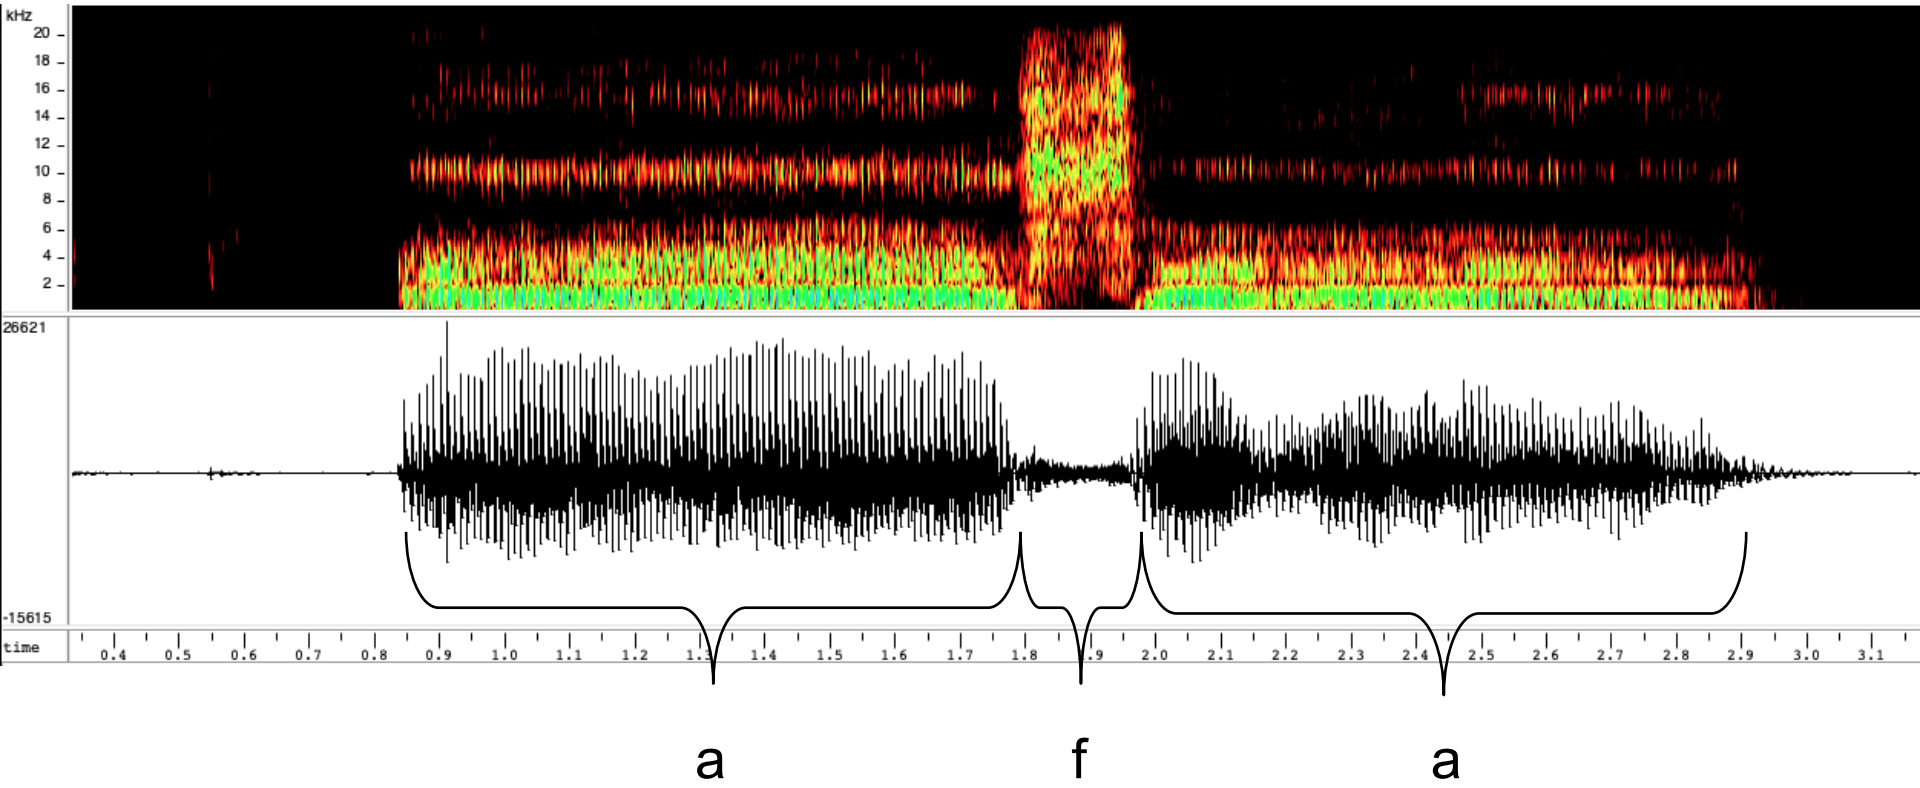
N	DFT Ops	FFT Ops
2^8	~130k	~3k
2^{10}	~2Mio	~15k
2^{12}	~ 33 Mio	~ 70k

Zusammenfassung – Fourier Transformation

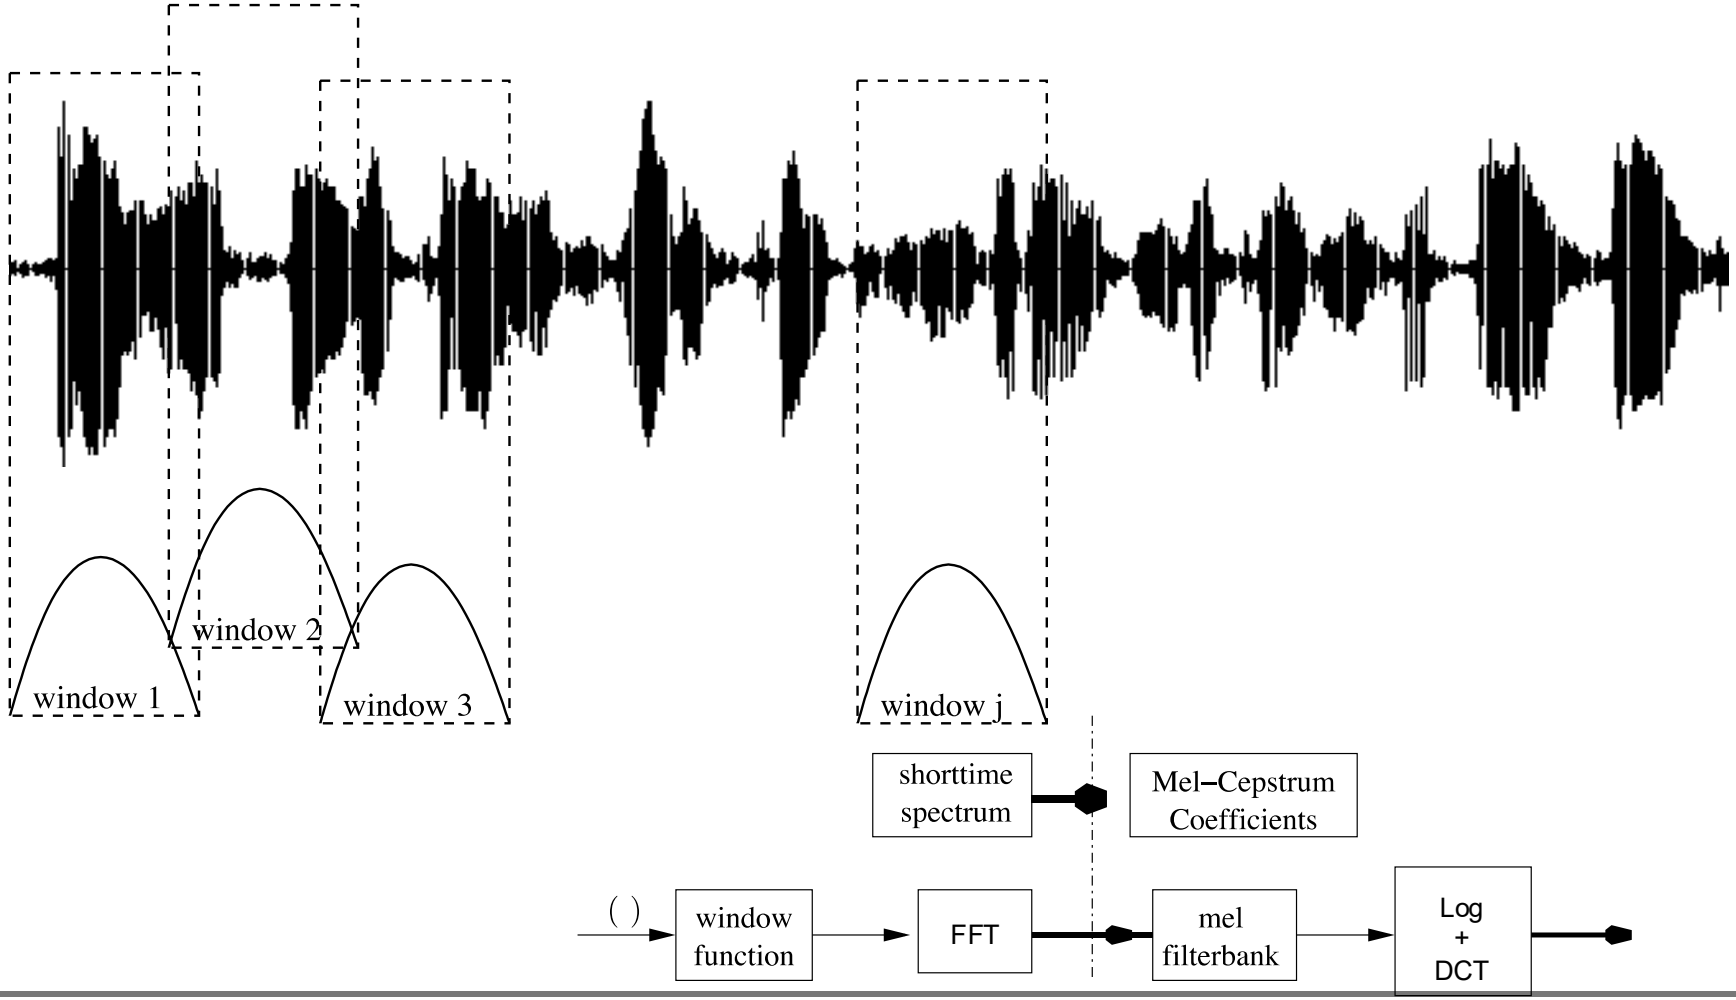
- DFT zur Bestimmung von Frequenzen in diskretem Signal
- Naive Implementierung sehr rechenaufwendig $O(n^2)$
- Nutzen von Symmetrien erlaubt Beschleunigung
- Fast Fourier Transform (FFT) viel effizienter: $O(n * \log n)$

Das Sprachsignal – Spektrogramm

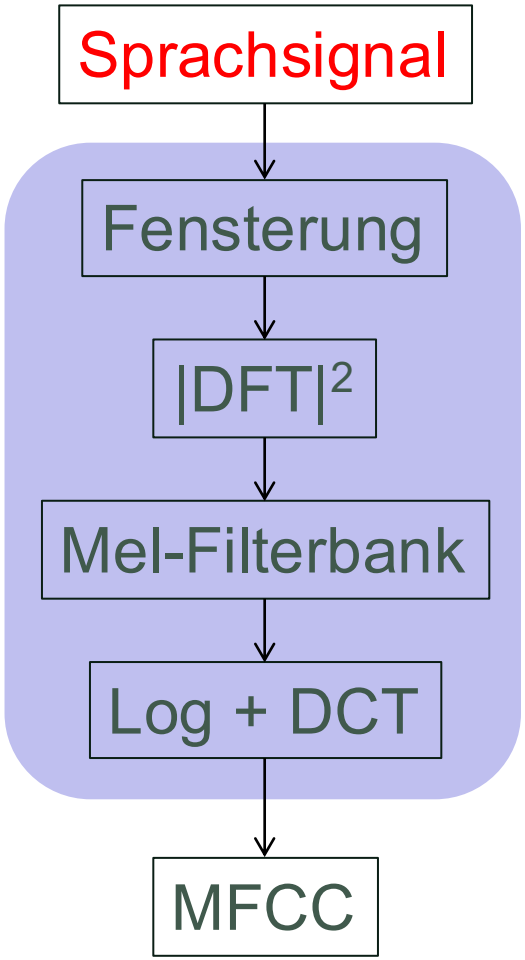
- Zeit-Frequenz Repräsentation, STFT

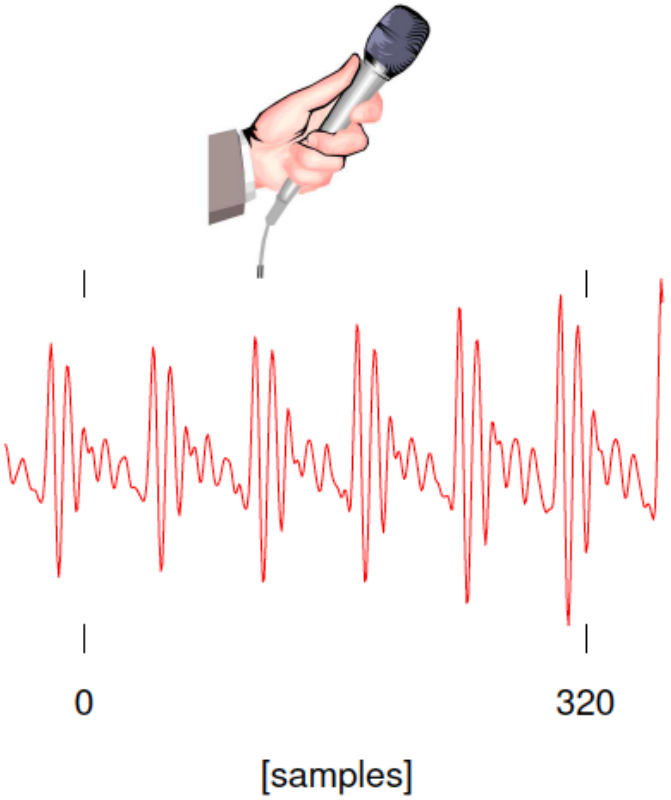


Mel Frequency Cepstrum Coefficients

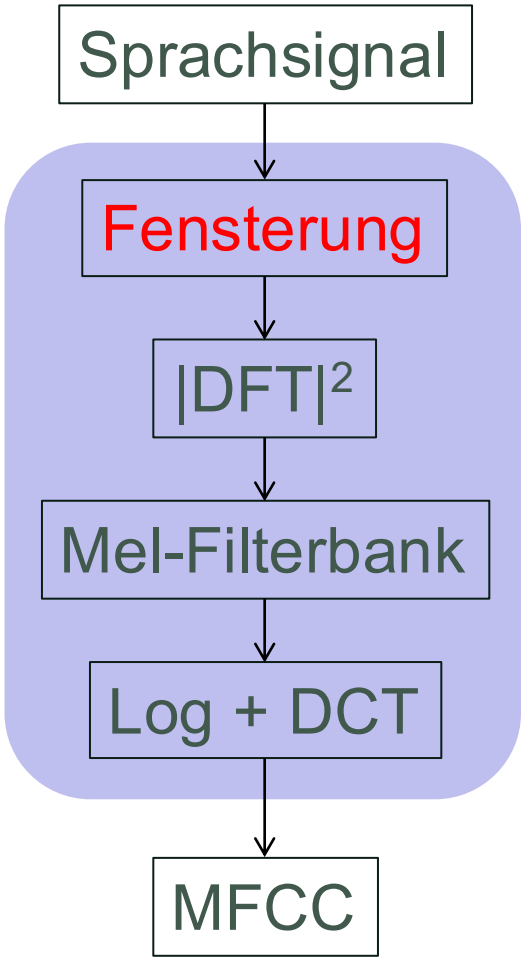


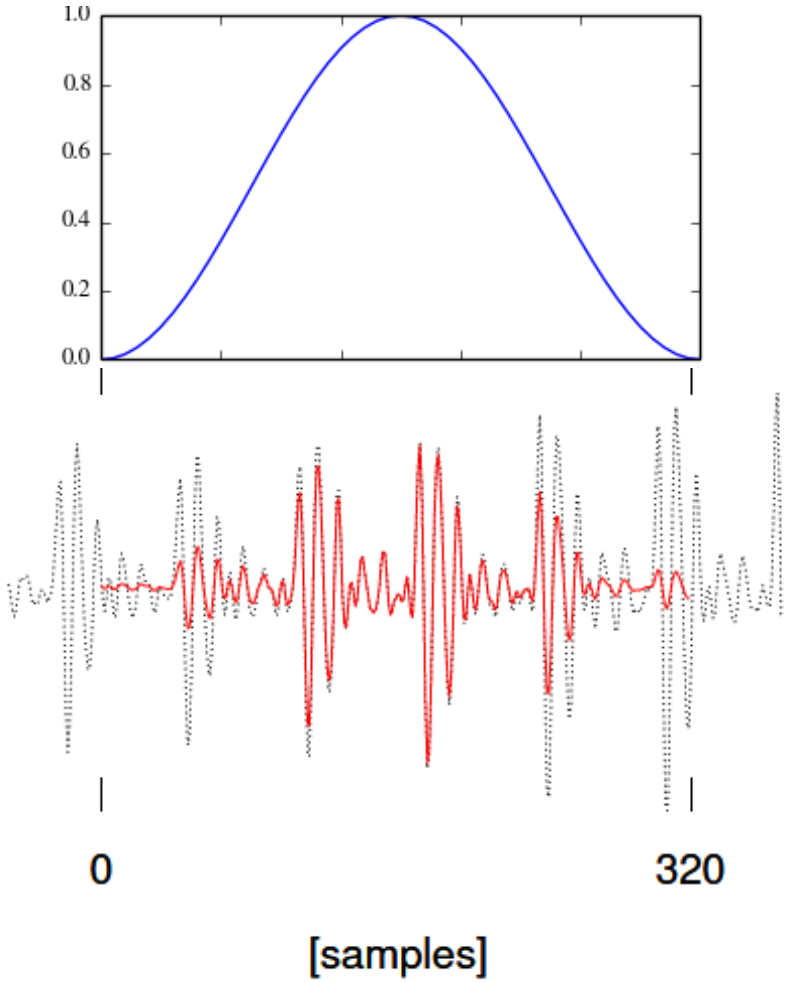
Merkmalberechnung



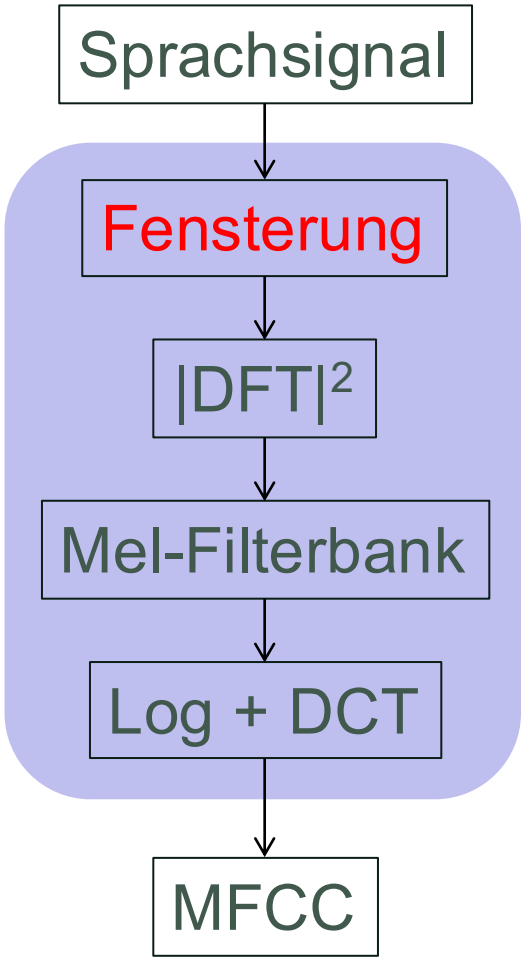


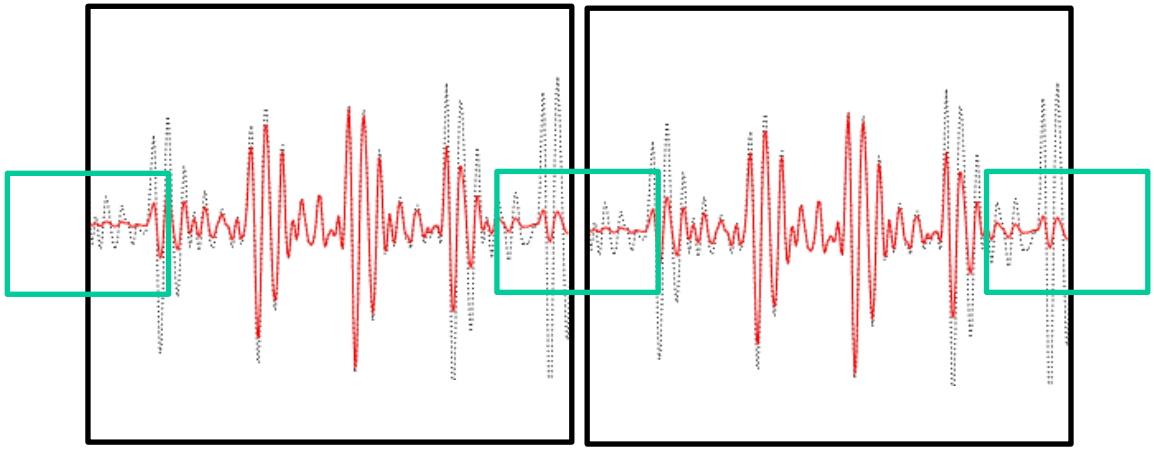
Merkmalberechnung



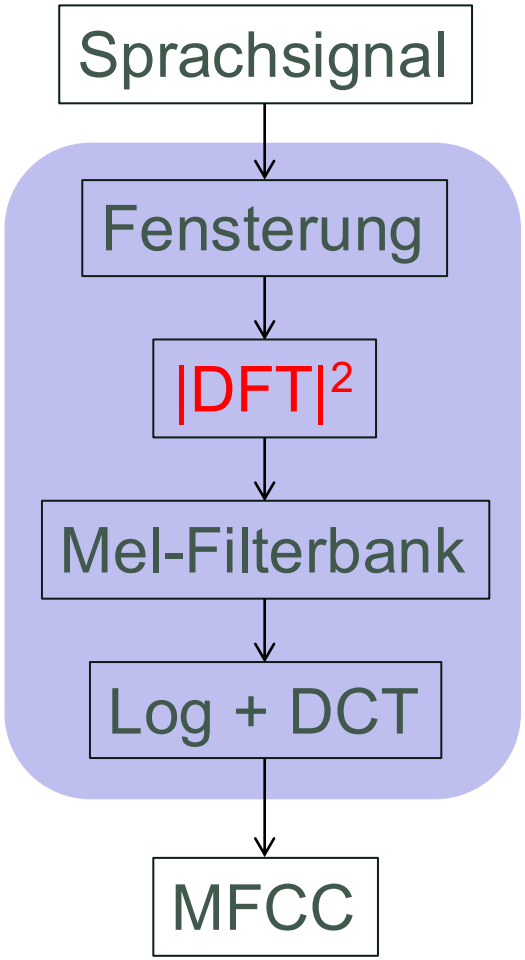


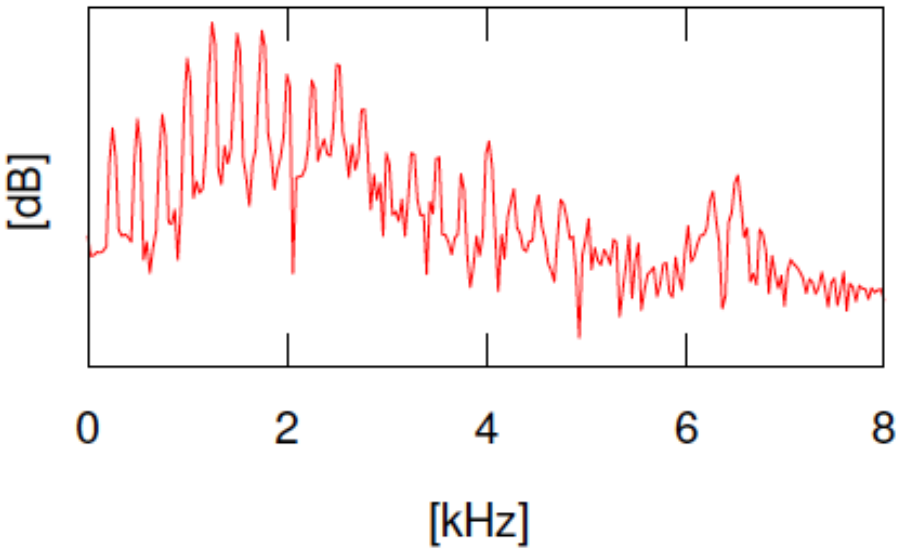
Merkmalberechnung



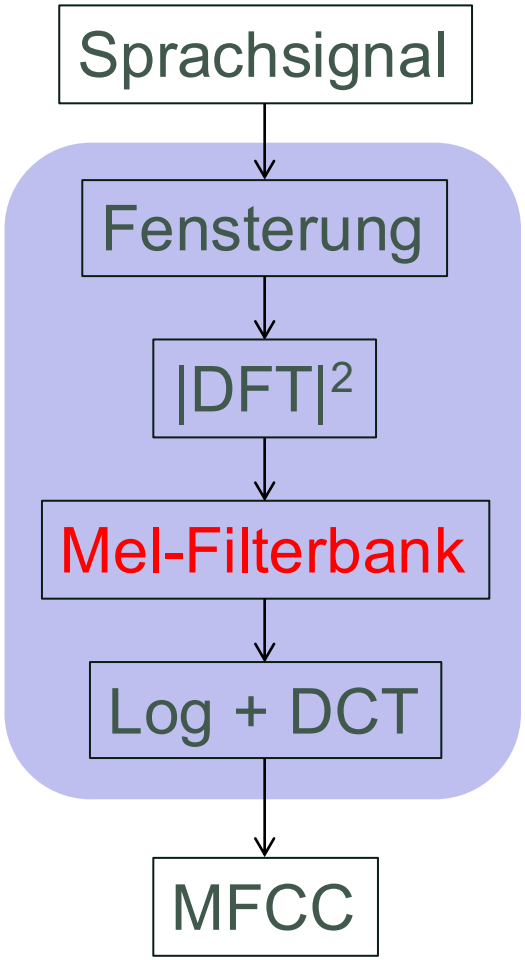


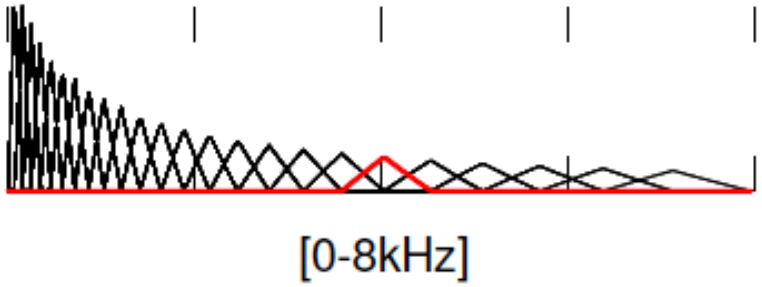
Merkmalberechnung

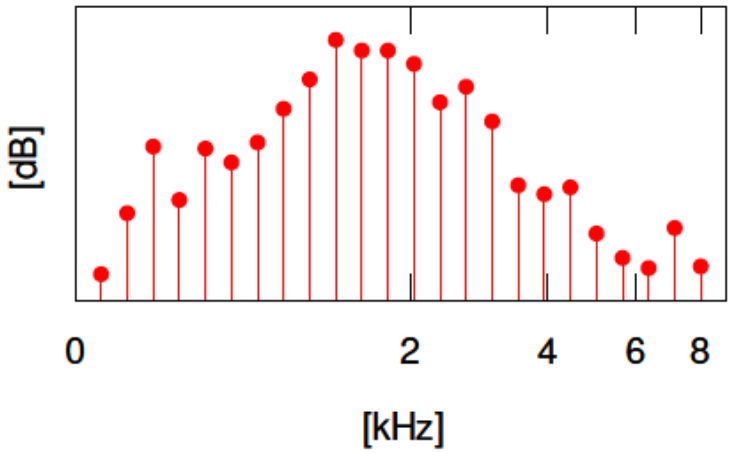




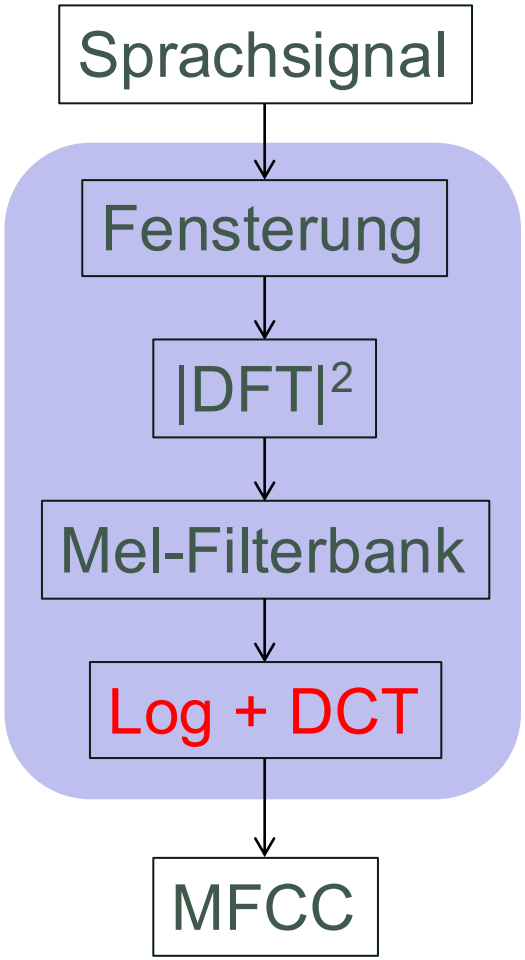
Merkmalberechnung

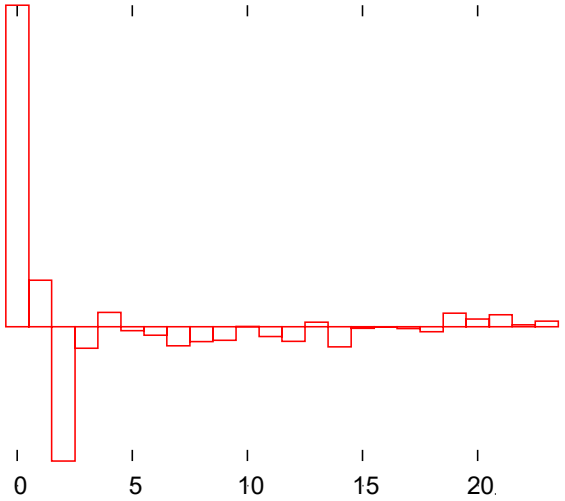




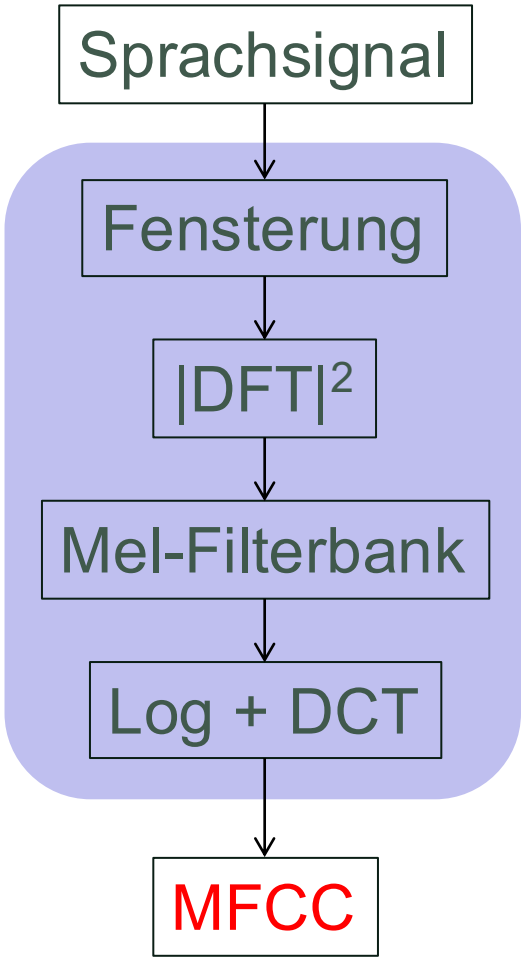


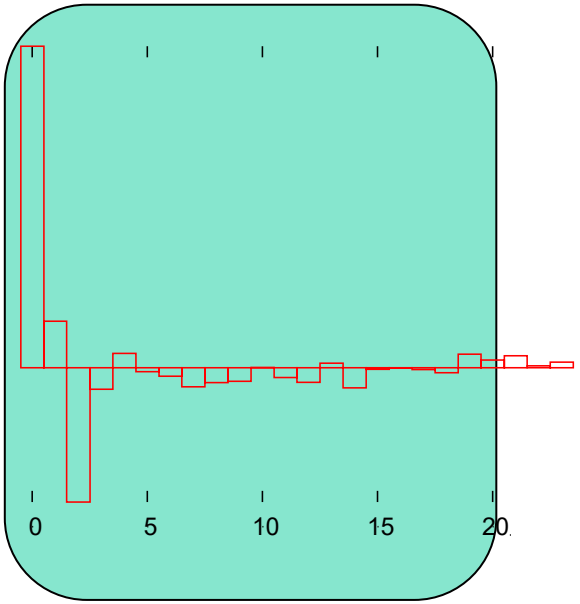
Merkmalberechnung





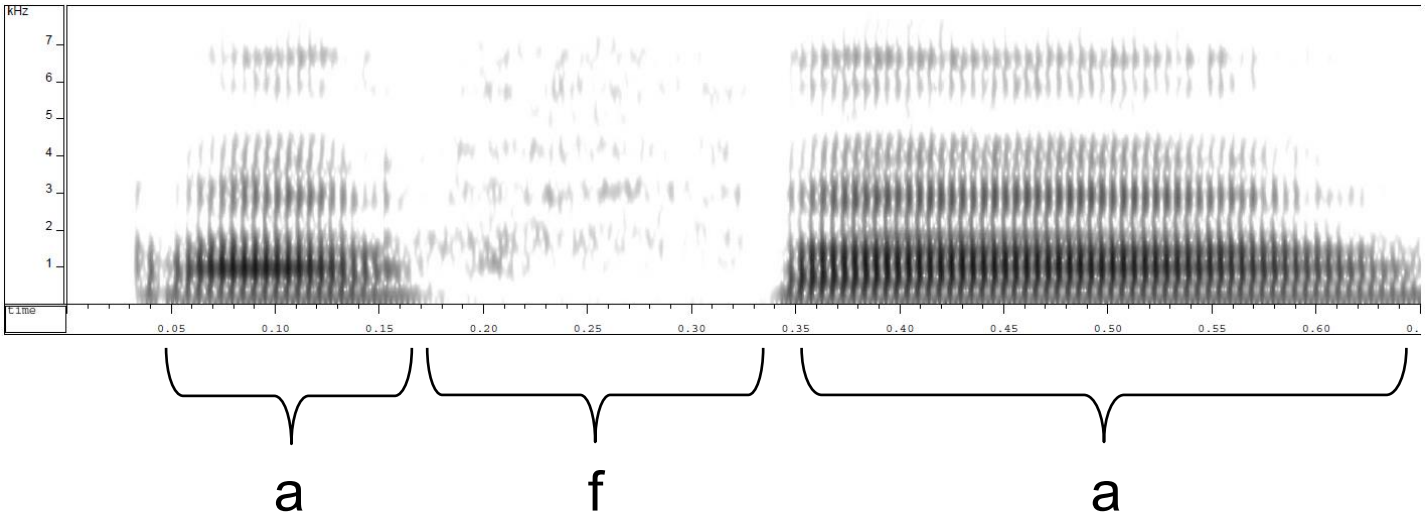
Merkmalberechnung



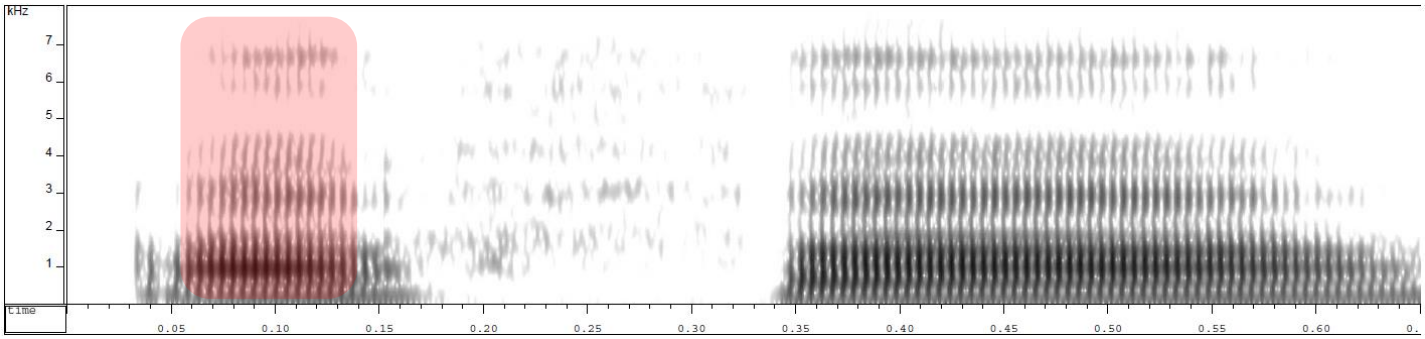


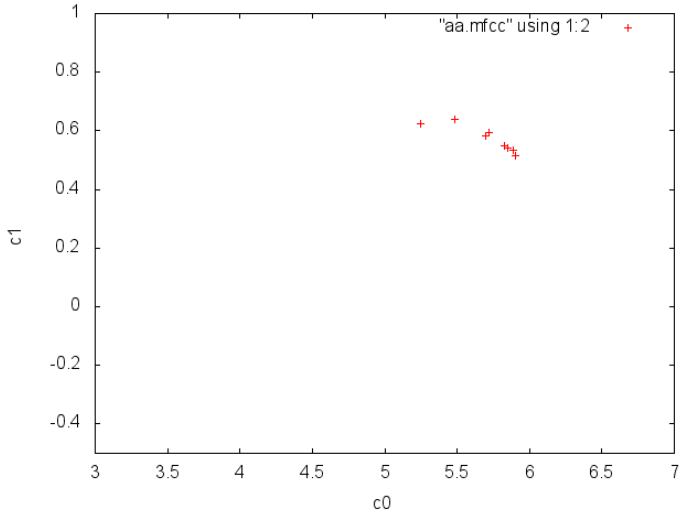
z.B. 20 Cepstrum-Koeffizienten

Vom Sprachsignal zu den Merkmalen

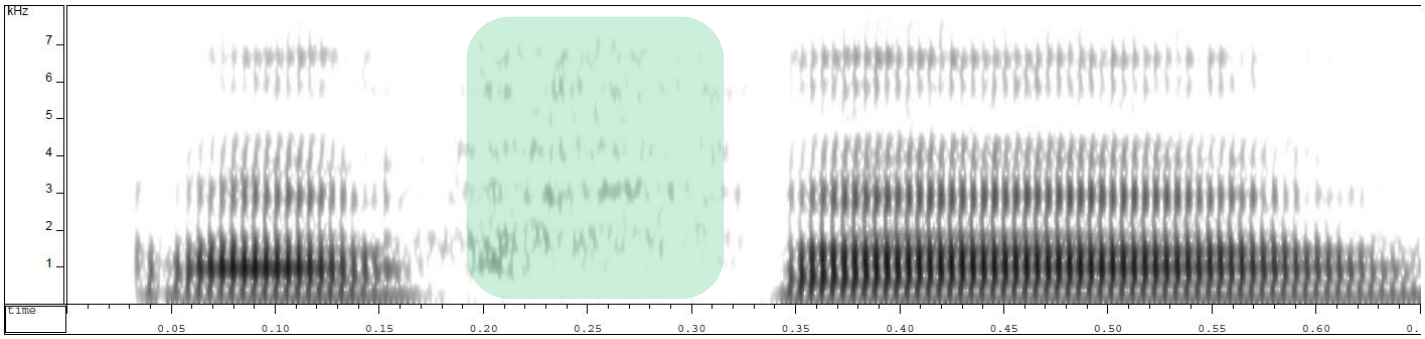


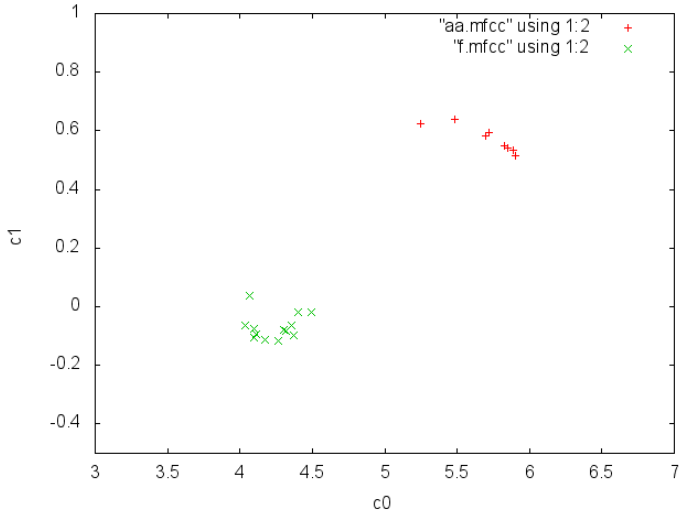
Vom Sprachsignal zu den Merkmalen



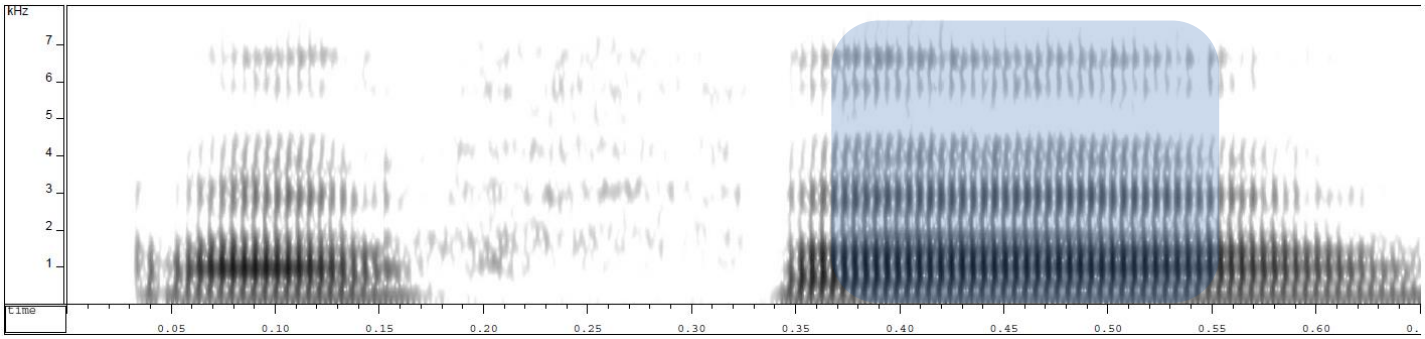


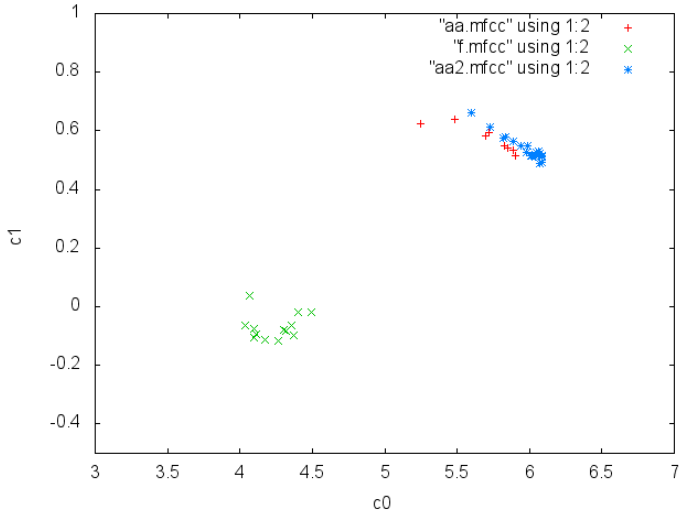
Vom Sprachsignal zu den Merkmalen



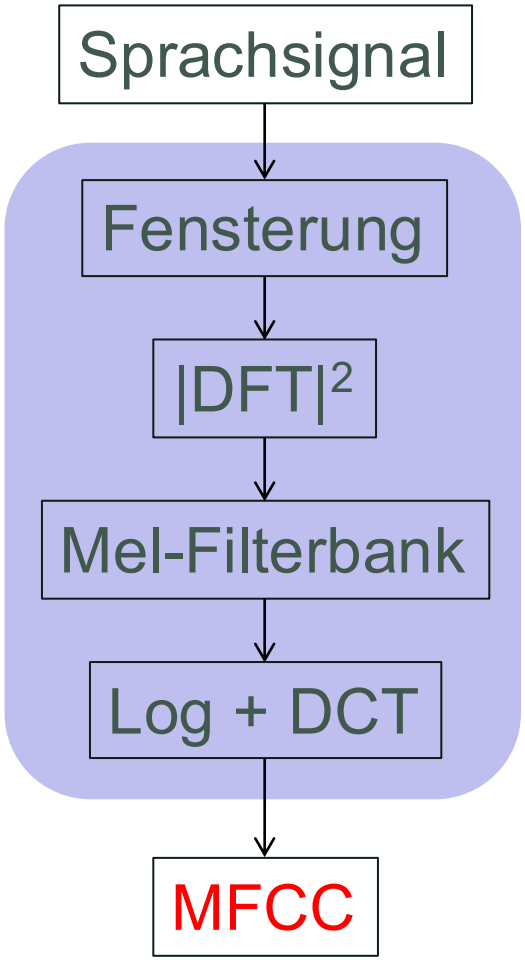


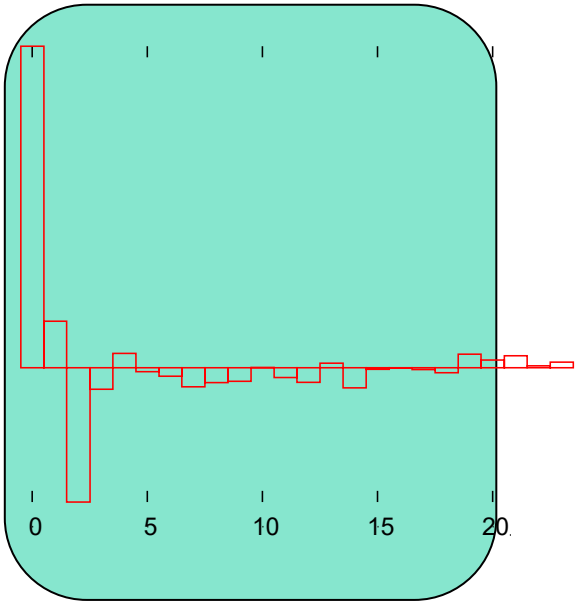
Vom Sprachsignal zu den Merkmalen





Merkmalberechnung





z.B. 20 Cepstrum-Koeffizienten

evtl. 1. + 2. Ableitung

---

60 Koeffizienten