Technische Hochschule Nürnberg

Maschinelles Lernen

Prof. Dr. Tobias Bocklet

Heute

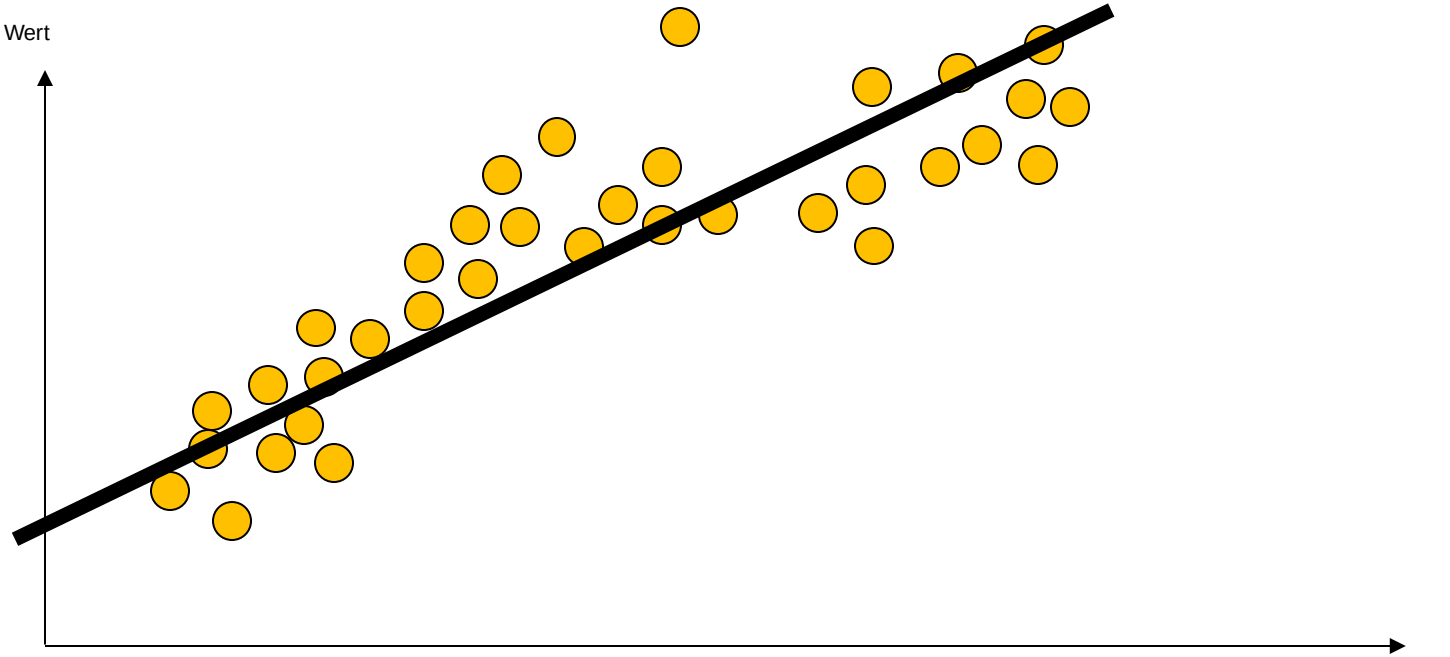
- Wdh. Lineare Regression
- Logistische Regression
  - Klassifikation
  - Interpretation
  - Entscheidungsgrenzen/Decision boundaries
  - Kostenfunktion
  - Gradientenabstieg
  - Multiklassen Probleme
- Motivation neuronaler Netze

Regressions- vs. Klassifikationsproblem

- Datensatz mit Merkmalen $\mathbf{x} = \left(x_1, x_2, \ldots, x_d\right)$
- Regression: Lernen der Abbildung $f(\mathbf{x}) : \mathbb{R}^d \mapsto \mathbb{R}$
- Klassifikation: Lernen der Abbildung $f(\mathbf{x}) : \mathbb{R}^d \mapsto \mathcal{Y}$

$$\mathcal{Y} = \{1, 2, \ldots, C\}$$

Lineare Regression



Trainingsbeispiele Merkmal 1 mit Wert

Ziel: Schätzen einer Funktion

Schätzen von Regressionsmodellen

- Form der Funktion $\mathrm{h}(x)$ muss festgelegt werden (z.B. Lineare Regression)

$$\mathrm{h}(x) = mx + b$$

- Datensammlung $(\mathbf{X}, \hat{\boldsymbol{y}})$ → Menge von M Vektoren mit zugehörigen Zielwerten
  - Genügend Daten um die Parameter von $\mathrm{h}(x)$ zu schätzen
  - Kann als ein überbestimmtes Gleichungssystem angesehen werden

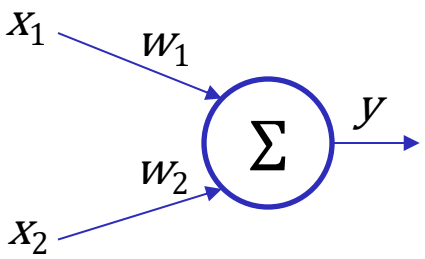
Regression

- Überwachtes Lernen
- Finde Funktion h(x), die möglichst nahe zu den Datenpunkten ist
- Fehler: Vorhergesagter Wert != Tatsächlicher Wert
- Kostenfunktion: Wie weit liegt tatsächlicher Wert vom vorhergesagten entfernt

$$C = \frac{1}{2M} \sum_{i=1}^{M} \left(\hat{y} - h(x)\right)^2$$

- Ziel: Minimieren der Kostenfunktion

Gradientenabstieg



- Ausgabe y ist gewichtetet Summe der Eingaben x_i

$$y = \sum_i x_i w_i = \boldsymbol{w}^T \boldsymbol{x}$$

- Training erfordert Trainingsbeispiele mit bekannten Ausgaben $\hat{y}$
- Quadratische Fehler- bzw. Kostenfunktion:

$$C = \frac{1}{2}(\hat{y} - y)^2$$

- Iteratives Verfahren zur Minimierung der Kostenfunktion C durch Anpassen der Gewichte $\boldsymbol{w}$ mittels

$$\Delta w_i = -\varepsilon \frac{\partial C}{\partial w_i}$$

Unterschiedliche Abstiegsverfahren

- Stochastic gradient descent
- Batch gradient descent
- Mini-batch gradient descent

Klassifikation

- Erkennen von Kategorien
  - 2-Klassen-Probleme:

From: cheapsales@buystufffromme.com
To: ang@cs.stanford.edu
Subject: Buy now!

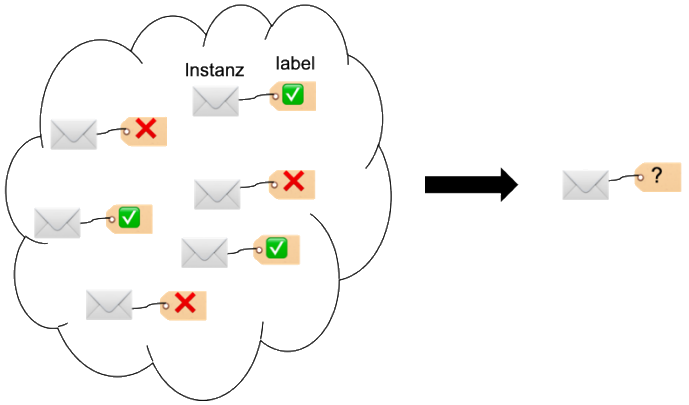
Deal of the week! Buy now!
Rolex w4tchs - $100
Medicine (any kind) - $50
Also low cost M0rgages
available.

Spam

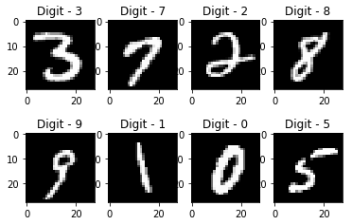
From: Alfred Ng
To: ang@cs.stanford.edu
Subject: Christmas dates?

Hey Andrew,
Was talking to Mom about plans
for Xmas. When do you get off
work. Meet Dec 22?
Alf

Non-spam



  - Mehr-Klassen-Probleme





Iris: Setosa Versicolor Virginica

Lineare Regression zur Klassifikation

Logistische Regression

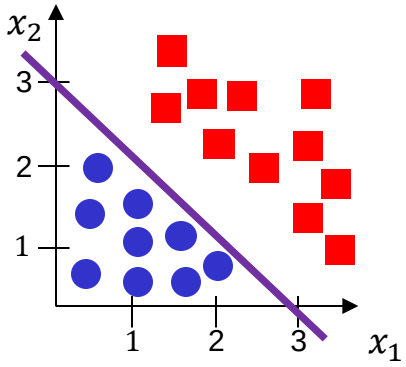
- Sigmoid-Funktion

$$g(z) = \frac{1}{1+e^{-z}}$$

$$h(x) = g(w^T x) = \frac{1}{1 + e^{-w^T x}}$$

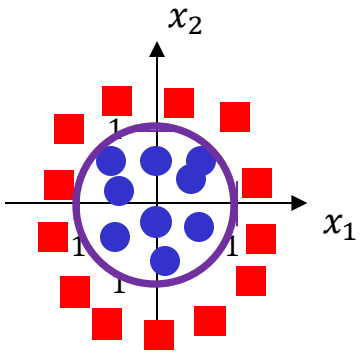
Interpretation in Form von Wahrscheinlichkeiten

Entscheidungsgrenzen – Linear



$$h(x) = g(w_0 + w_1 x_1 + w_2 x_2)$$

Entscheidungsgrenzen –Nichtlinear



$$h(x) = g(w_0 + w_1 x_1 + w_2 x_2 + \\ + w_3 x_1^2 + w_4 x_2^2)$$

Noch komplexer:

$$h(x) = g(w_0 + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + \\ + w_4 x_1^2 x_2 + w_5 x_1^2 x_2^2 + w_6 x_1^3 x_2 + \cdots)$$

Optimierung

- Training Set: $\{(\boldsymbol{x}^{(1)}, y^{(1)}), (\boldsymbol{x}^{(2)}, y^{(2)}), \ldots, (\boldsymbol{x}^{(m)}, \boldsymbol{y}^{(m)})\}$
- m Beispiele
- x kann mehrdimensional sein: $\boldsymbol{x} \in \begin{pmatrix} x_0 \\ x_1 \\ \vdots \\ x_N \end{pmatrix}$
- $y \in \{0,1\}$
- $h(x) = \frac{1}{1+e^{-w^T x}}$
- Wie Parameter w bestimmen?

Kostenfunktion

- Lineare Regression: $C = \frac{1}{2M} \sum_{i=1}^{M} (h(x^{(i)}) - y^{(i)})^2$

- $C = \frac{1}{M} \sum_{i=1}^{M} \underbrace{\frac{1}{2} (h(x^{(i)}) - y^{(i)})^2}_{\text{Cost}}$

Kostenfunktion

- Logistische Regression: $C = \frac{1}{2M}\sum_{i=1}^{M} Cost(h(x^{(i)}) - y^{(i)})$

- $Cost(h(x), y) = \begin{cases} -\log(h(x)), & wenn\ y = 1 \\ -\log(1 - h(x)), & wenn\ y = 0 \end{cases}$

- *y immer 0 oder 1*

Kostenfunktion – Umschreiben

- $Cost(h(x), y) = -y \log\big(h(x)\big) - (1 - y) \log\big(1 - h(x)\big)$

- $C = \frac{1}{m} \sum_{i=1}^{m} Cost\big(h\big(x^{(i)}\big), y^{(i)}\big)$

  $= -\frac{1}{m} \sum_{i=1}^{m} y^{i} \log\big(h\big(x^{(i)}\big)\big) + \big(1 - y^{(i)}\big) \log\big(1 - h\big(x^{(i)}\big)\big)$

Kostenfunktion – Umschreiben

- $C = \frac{1}{m}\sum_{i=1}^{m} Cost\left(h\left(x^{(i)}\right), y^{(i)}\right)$

  $= -\frac{1}{m}\sum_{i=1}^{m} y^{i}\log\left(h\left(x^{(i)}\right)\right) + \left(1 - y^{(i)}\right)\log\left(1 - h\left(x^{(i)}\right)\right)$

- Bestimmen von *w*: minimieren der Kostenfunktion *C*

- Vorhersage für neues ***x****:*

  $h(x) = \frac{1}{1+e^{-w^T x}}$

Gradient descent

- $C = -\frac{1}{m}\sum_{i=1}^{m} y^{i}\log\left(h\left(x^{(i)}\right)\right) + \left(1 - y^{(i)}\right)\log\left(1 - h\left(x^{(i)}\right)\right)$

- min(C):

$$w_j := w_j + \Delta w_j \qquad \Delta w_j = -\varepsilon\frac{\partial C}{\partial w_j}$$

$$\Delta w_j = -\varepsilon\frac{\partial C}{\partial w_j} = -\varepsilon\frac{1}{m}\sum_{i=1}^{m}\left(h\left(x^{(i)}\right) - y^{(i)}\right)x_j^{(i)}$$

Weitere Optimierungen

- Kostenfunktion C
- Repeat {

$$w_j := w_j + \Delta w_j$$

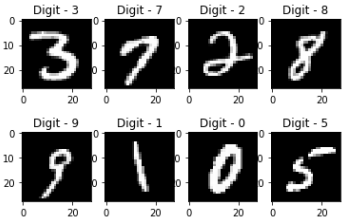
}

$$\Delta w_j = -\varepsilon \frac{\partial C}{\partial w_j}$$

- Optimierungen:
  - Conjugate gradient
  - BFGS
  - L-BFGS

- Vorteile:
  - ε muss nicht bestimmt werden
  - Oft schneller als Gradientenabstieg
- Nachteil:
  - Viel komplexer

Erweiterung zu mehreren Klassen



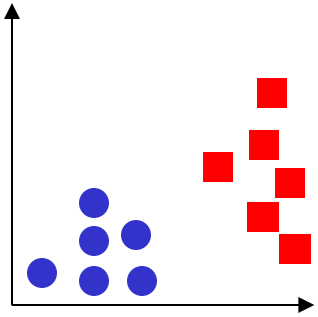


Iris: Setosa Versicolor Virginica

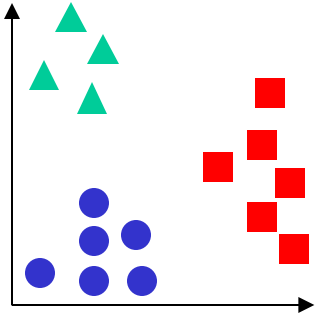
- E-Mail tagging: Arbeit, Familie, Freunde, Hobbies

One vs. All

Binäre Klassifikation

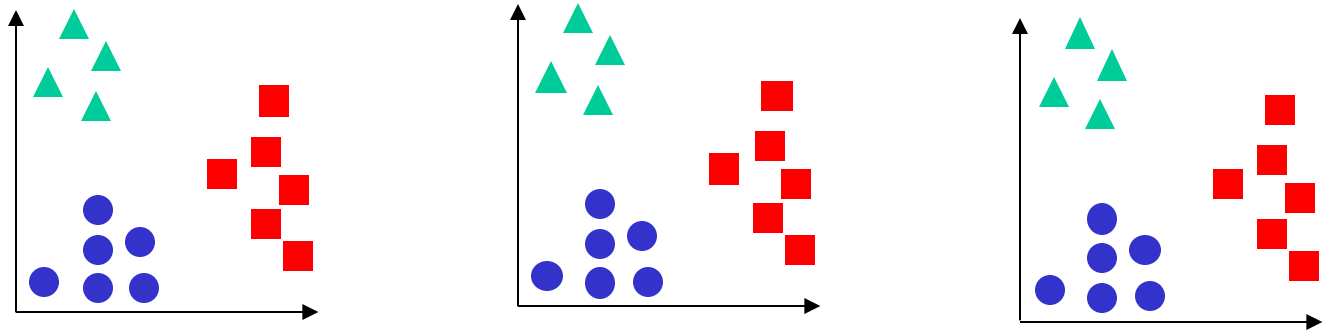


Multi-klassen-Klassifikation



One vs. All

Multi-klassen-Klassifikation



Klasse 1: ▲

Klasse 2: ●

Klasse 3: ■

- Trainiere einen Logistischen Regressions-Klassifikator $h^{(i)}(x)$ für jede Klasse i
- Für einen neuen Input ***x***, wähle Klasse *i*, die

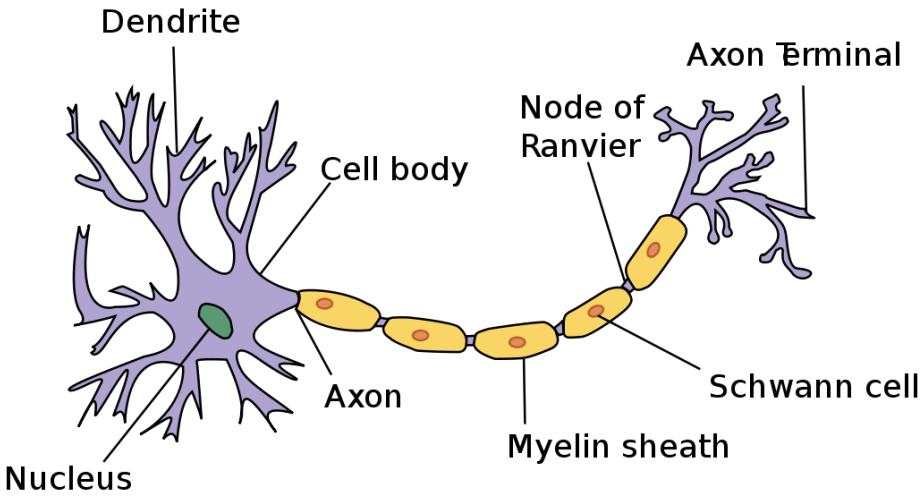
$$\max\left(h^{(i)}(x)\right)$$

maximiert

Zusammenfassung

- Logistische Regression ist ein Klassifikator
- Überwacht und parametrisch
- Andere Namen: Log-Linear Klassifikator, Logit-Regression
- Erweiterung der Linearen Regression mit Sigmoid-Funktion
- Training:
  - Gewichte $\boldsymbol{w}$ werden iterativ geschätzt
  - Mittels Gradientenabstieg
- Multiklassen Erweiterung z.B. durch One vs. All

Ausblick – Neuronale Netze



Perceptron

- Vereinfachtes Modell durch lineare Funktion mit Aktivierungsfunktion

