Technische Hochschule Nürnberg

Maschinelles Lernen

Regression Erweiterungen, Regularisierung, Merkmalnormierung

Prof. Dr. Tobias Bocklet

Wo sind wir?

- kNN
- Hierarchisches Clustering & kMeans
- MFCCs
- LinReg
- LogReg
- PolynomRegression//Regularisierung/Merkmalnormierung
- Neural Nets
- Backpropagation/Trainingsverfahren
- Convolutional Neural Networks
- Statistische Klassifikation
- Trees/Forrests
- Support Vektor Maschinen
- Principal Component Analysis

Heute

- Polynomregression
- Regularisierung
- Merkmalnormalisierung/Standardisierung

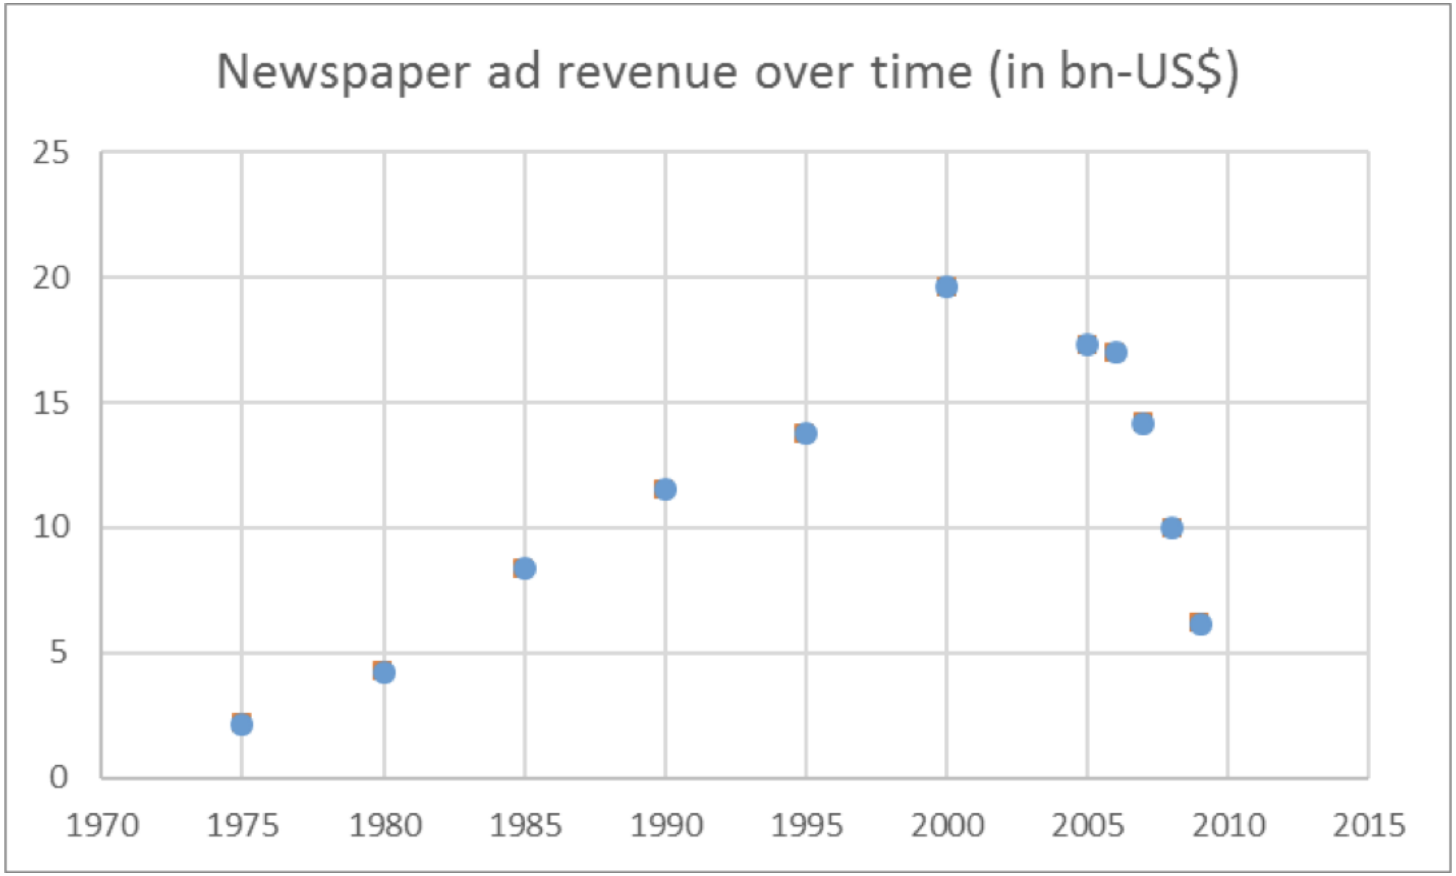
Polynomregression

- Anstatt der Linearen Regression $y = w_0 + w_1 x$ wird eine Polynomfunktion vom Grad d verwendet
- d=2: $y_m = w_0 + w_1 x_m + w_2 x_m^2$
- d=3: $y_m = w_0 + w_1 x_m + w_2 x_m^2 + w_3 x_m^3$
- d=4: $y_m = w_0 + w_1 x_m + w_2 x_m^2 + w_3 x_m^3 + w_4 x_m^4$
- d=5: $y_m = w_0 + w_1 x_m + w_2 x_m^2 + w_3 x_m^3 + w_4 x_m^4 + w_5 x_m^5$

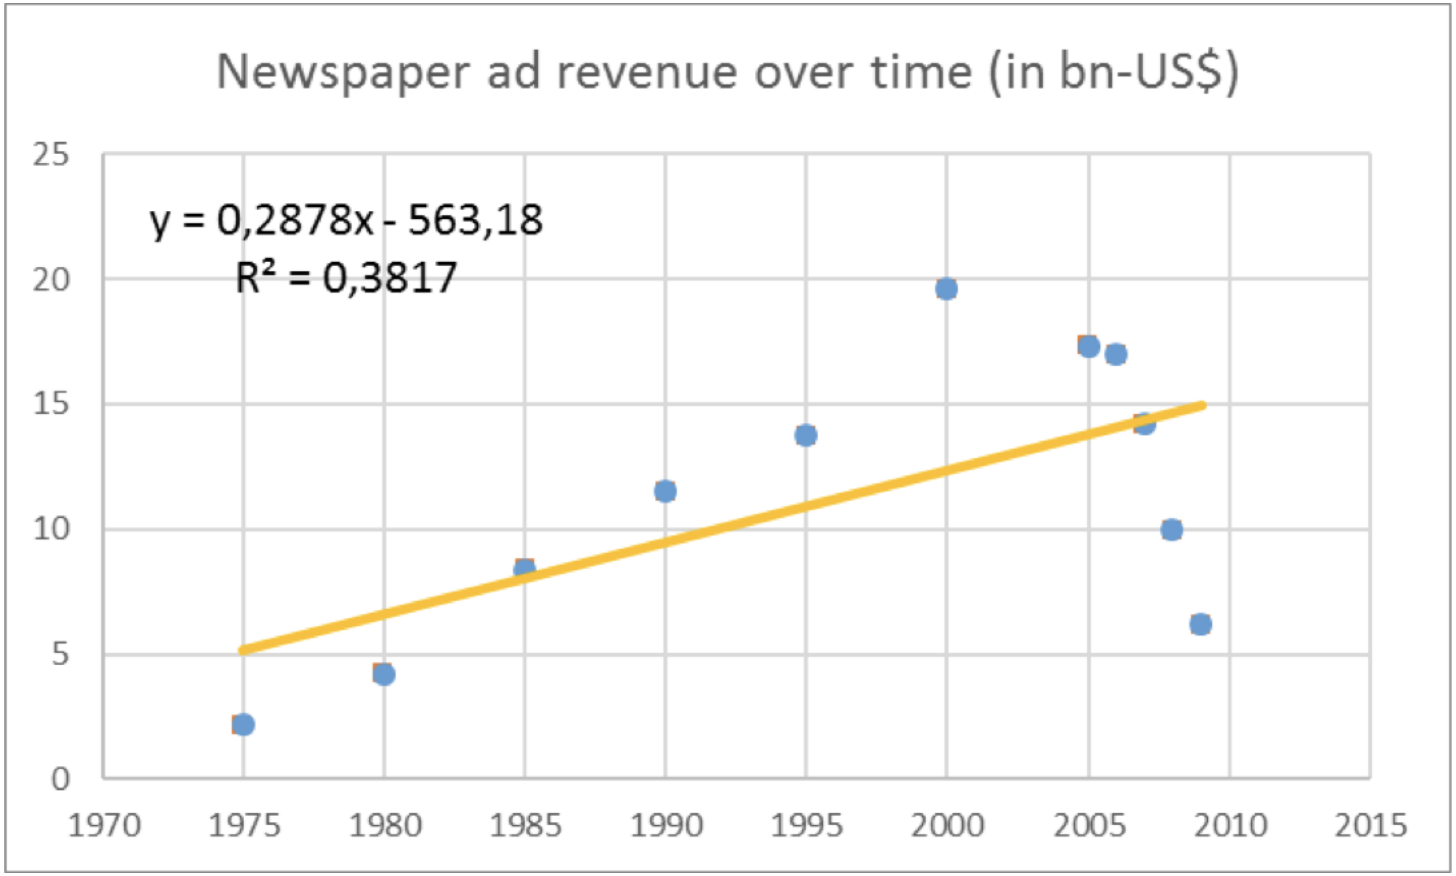
- Kann als Mehrfachregression behandelt werden
  - $x,\ x^2, x^3, x^4, x^5, \ldots$, werden als unabhängige Variablen angesehen
  - Beispiel für d=3: x_m durch x_{m1} ersetzen, x_m^2 durch x_{m2}, x_m^3 durch x_{m3}

$$y_m = w_0 + w_1 x_{m1} + w_2 x_{m2} + w_3 x_{m3}$$

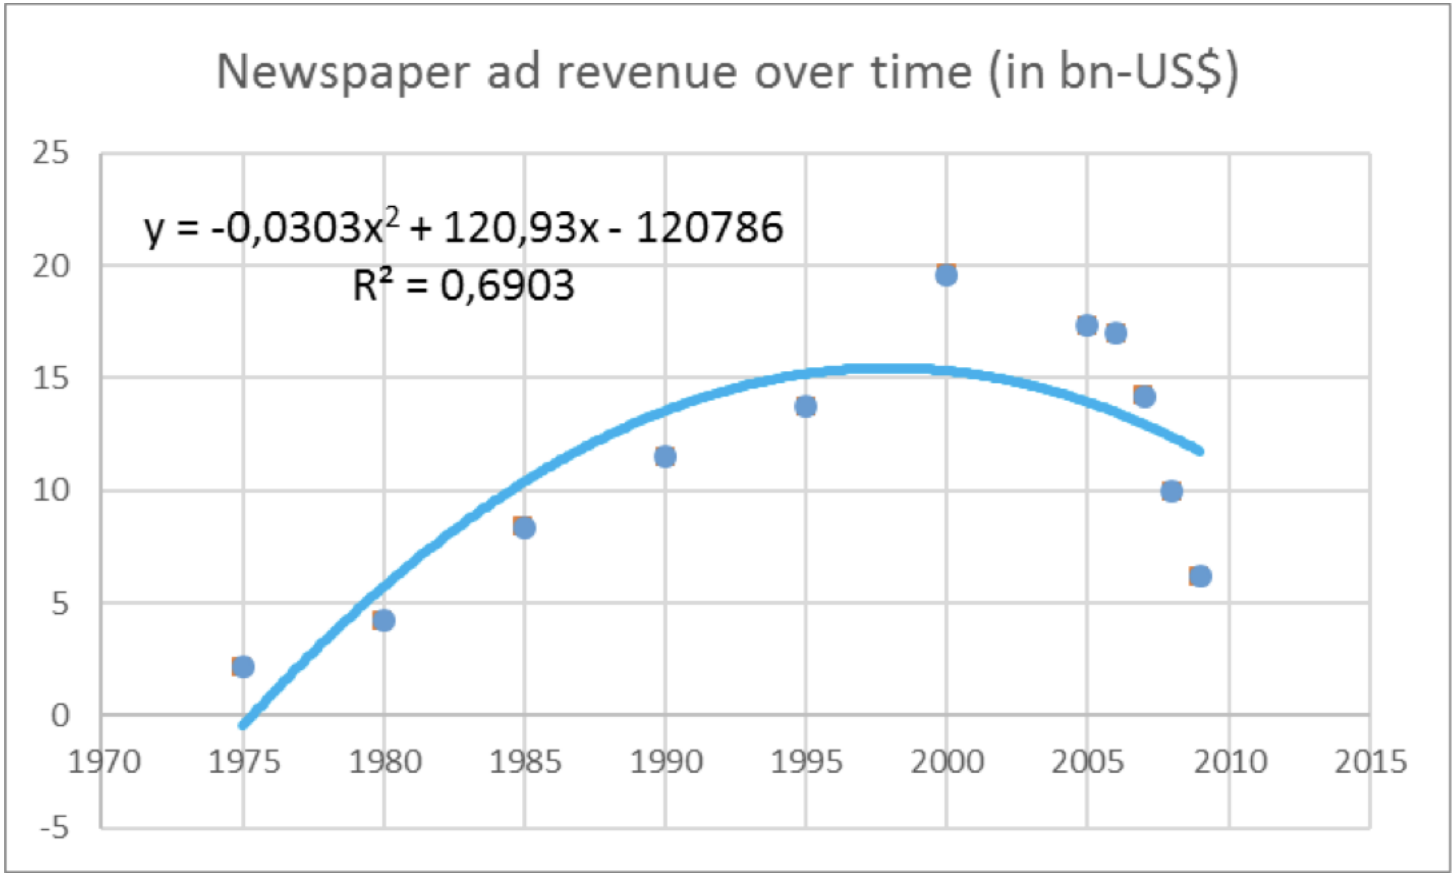
Polynomregression



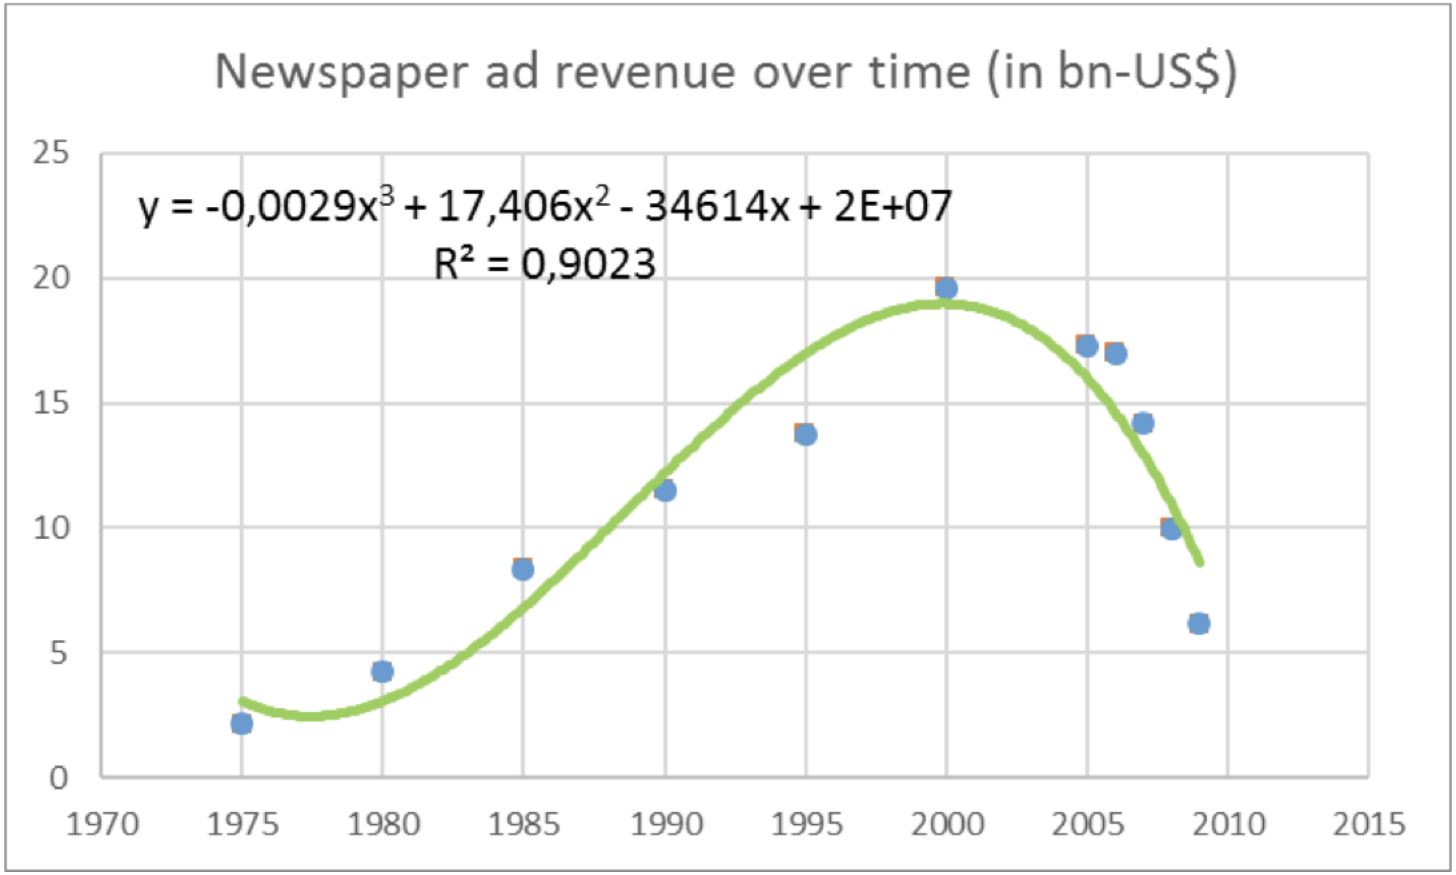
Polynomregression



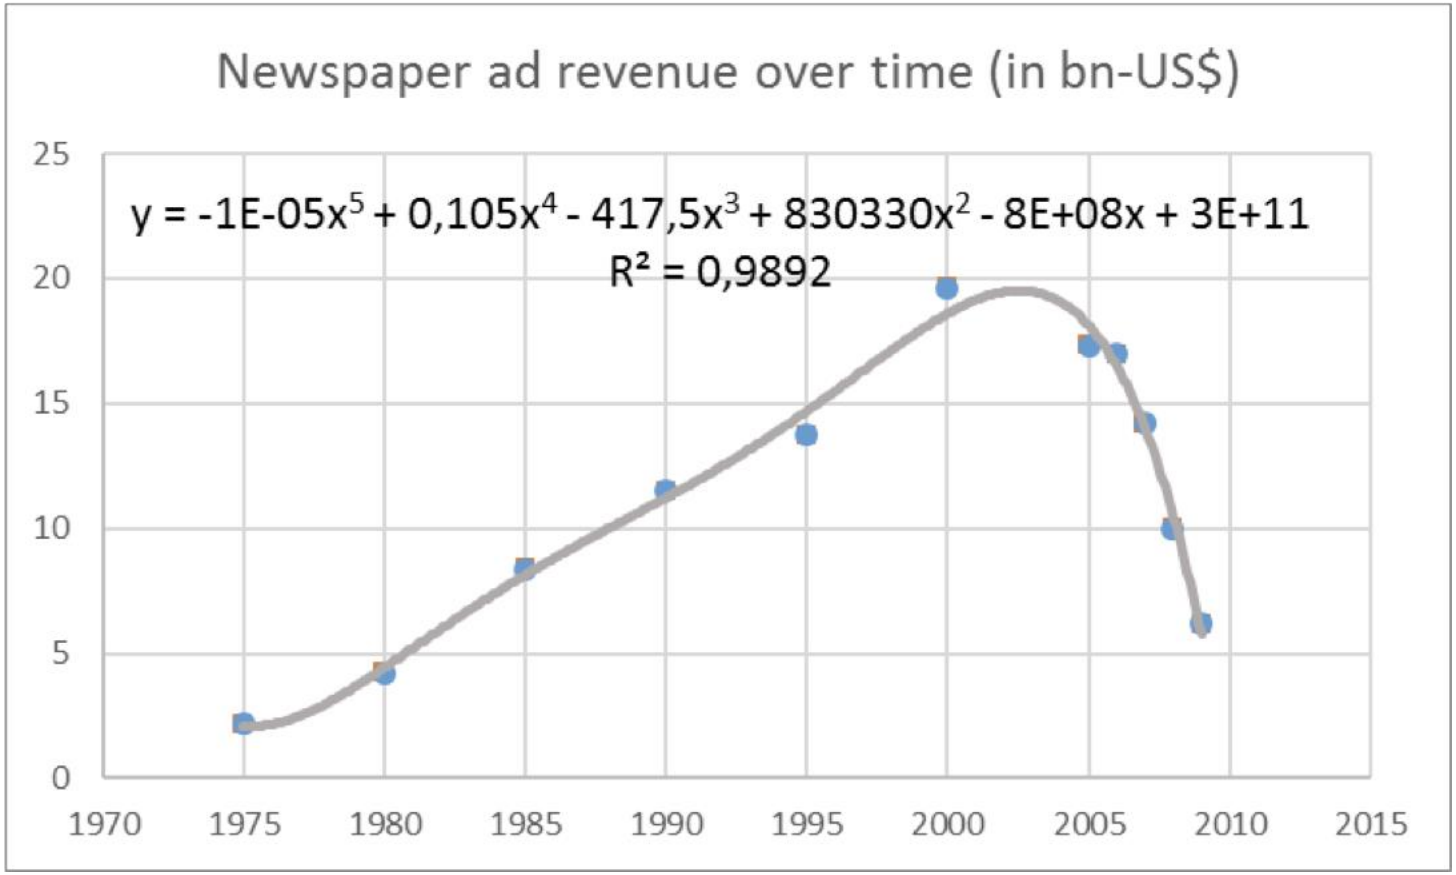
Polynomregression



Polynomregression



Polynomregression



Polynomregression mit mehreren unabhängigen Variablen

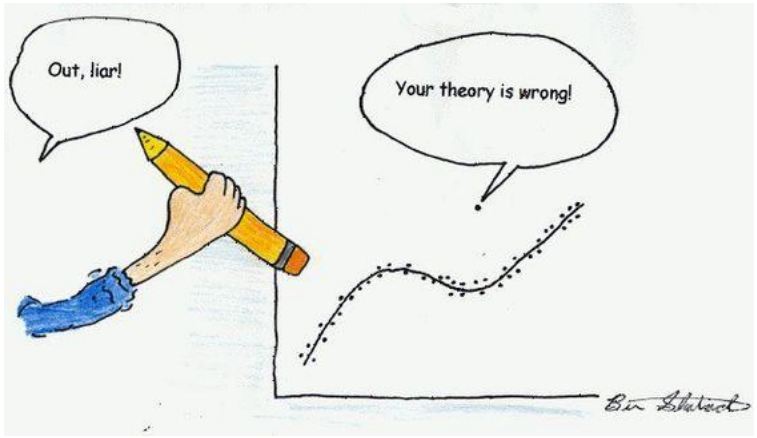
- Einfache Erweiterung zu mehreren unabhängigen Variablen durch Kombination aller Merkmale und Polynomausdrücke
- Beispiel: *y* hängt von zwei Merkmalen x_1 und x_2 ab

$$y_m = w_0 + w_1 x_{m1} + w_2 x_{m2} + w_3 x_{m1}^2 + w_4 x_{m2}^2 + w_5 x_{m1} x_{m2}$$

→ Mehrfachregression mit 6 Parametern

- Anzahl der Parameter wächst
  - Exponentiell mit der Anzahl der unabhängigen Variablen
  - Exponentiell mit dem Polynomgrad

Regularisierung



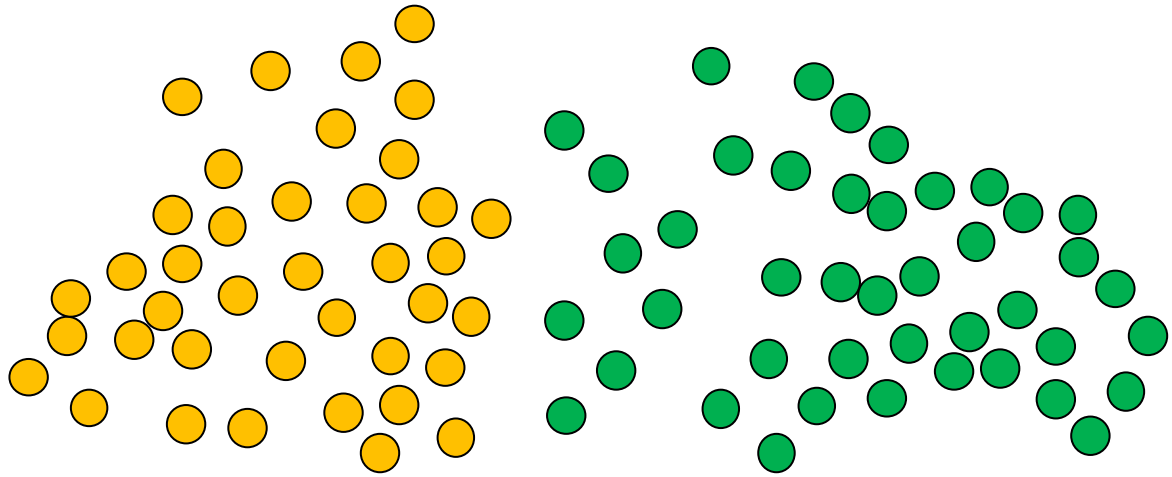
Overfitting

Overfitting: Zu viele Merkmale, die gelernte Hypothese wurde hervorragend an das Trainingset angpasst

$$C = \frac{1}{2M} \sum_{i=1}^{M} (h(x) - y)^2 \approx 0$$

Generalisiert aber nicht auf neuen, ungesehenen Daten

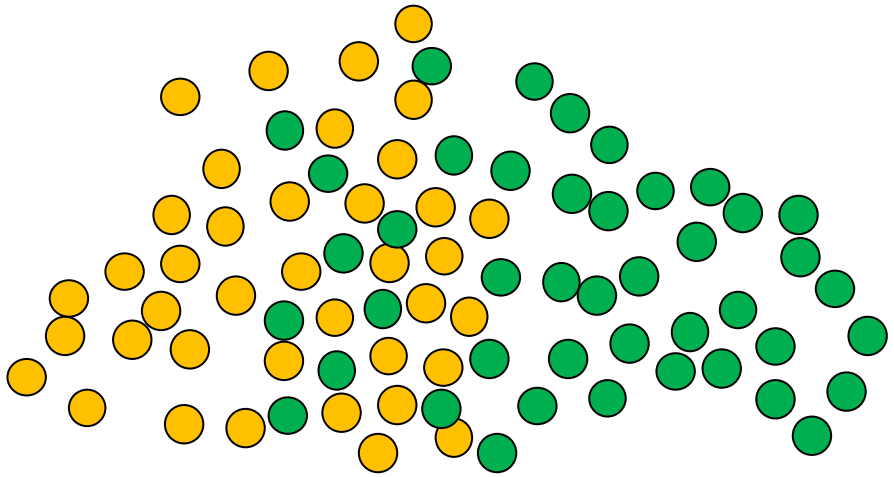
Overfitting in der Klassifikation



Trainingsbeispiel Klasse 1

Trainingsbeispiel Klasse 2

Overfitting in der Klassifikation

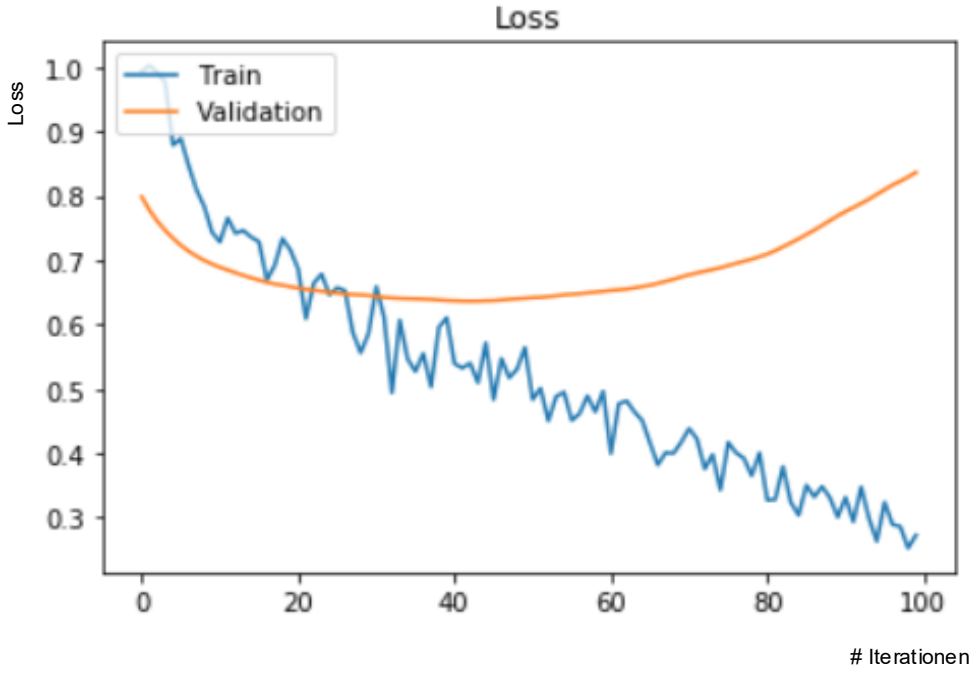


Trainingsbeispiel Klasse 1

Trainingsbeispiel Klasse 2

Wie erkennen

- Kosten/Loss während des Trainings im Blick behalten
- Einführen eines Validierungssets während des Trainings



Wie beheben

- Niedrig dimensionaler Fall: Plotten der Hypothese mit Daten und Analyse

- Hochdimensionaler Fall:

1. Anzahl der Merkmale reduzieren
   - Manuell, welche sind wichtig
   - Algorithmen zur Merkmalauswahl

2. Regularisierung
   - Behalte alle Merkmale, aber reduziere Wertebereiche der Parameter ***w***
   - Bei vielen Merkmalen, die alle „ein wenig“ zur Vorhersage beitragen

Regularisierung

- Beispiel:

$$w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4$$

- w_3 und w_4 sollen klein werden

$$\min_{\mathrm{w}} = \frac{1}{2M} \sum_{i=1}^{M} \left(h_w\left(x^{(i)}\right) - y^{(i)} \right)^2$$

- Minimierung der Kostenfunktion:

- Mit Regularisierung:

$$\min_{\mathrm{w}} = \frac{1}{2M} \sum_{i=1}^{M} \left(h_w\left(x^{(i)}\right) - y^{(i)} \right)^2 + 1000 w_3^2 + 1000 w_4^2$$

Regularisierung – Idee

- Kleine Werte für Parameter $w_0, \dots, w_N$
  - Einfachere Hypothesen
  - Weniger anfällig für Overfitting
- Hauspreise:
  - Merkmale: $x_0, \dots, x_{100}$
  - Parameter: $w_0, \dots, w_{100}$

Tradeoff

$$\min_{\mathrm{w}} = \frac{1}{2M}\left(\sum_{i=1}^{M}\left(h_w\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda \sum_{j=1}^{N} w_j^2\right)$$

Passe ***w*** an Trainingsset an

Erzwinge kleine w_j

Ridge Regression

- Implementiert die Regularisierung mit quadratischer Gewichtsbestrafung für lineare Regression

$$C(w) = MSE(w) + \lambda \sum_{j=1}^{N} w_j^2$$

- λ regelt die Bestrafung:

  Wenn sehr groß → alle Gewicht nahe 0, Schätzfunktion erzeugt eher eine Gerade

Lasso Regression

- Least Absolute Shrinkage and Selection Operator Regression
- Bestraft mit einer $l_1 - Norm$

$$C(w) = MSE(w) + \lambda \sum_{j=1}^{N} |w_j|$$

- Tendiert dazu, Gewichte von Merkmale zu eliminieren (Die Gewichte der am wenigsten wichtigsten Merkmale)
- Automatische Merkmalauswahl, Eingabevariablen werden gelöscht
- λ regelt die Bestrafung:

  Wenn sehr groß → alle Gewicht nahe 0, Schätzfunktion erzeugt eher eine Gerade

Ridge vs Lasso

Aspekt	Ridge Regression (L2)	Lasso Regression (L1)
Art der Strafe	Straft das **Quadrat** der Koeffizienten: $\lambda \sum \beta_j^2$ (L2-Strafe).	Straft den **absoluten Betrag** der Koeffizienten: $$\lambda \sum
Wirkung auf Koeffizienten	Schrumpft alle Koeffizienten in Richtung 0, aber **keiner wird exakt 0**.	Kann einige Koeffizienten **exakt auf 0** setzen und damit Merkmale „ausschalten“.
Feature-Selection	**Keine automatische Merkmalsauswahl**: alle Variablen bleiben im Modell.	**Führt automatische Merkmalsauswahl** durch, weil unwichtige Koeffizienten zu 0 werden.
Modellkomplexität	Alle Features bleiben, Modell bleibt „dicht“.	Modell kann **spärlich** (sparse) sein, weil viele Koeffizienten 0 sind.
Multikollinearität	**Sehr robust** bei stark korrelierten Prädiktoren (verteilt den Einfluss).	Kann bei mehreren stark korrelierten Features **willkürlich eines „löschen“**.
Wann typisch sinnvoll	Wenn viele Prädiktoren sind, aber **viele sind relevant** bzw. Multikollinearität besteht.	Wenn du vermutest, dass **nur ein Teil der Merkmale wirklich wichtig** ist.

Technische Hochschule Nürnberg

Merkmalnormierung

Probleme bei unterschiedlichen Wertebereichen

- Beispiel: Merkmale PS-Zahl und Gewicht von Autos

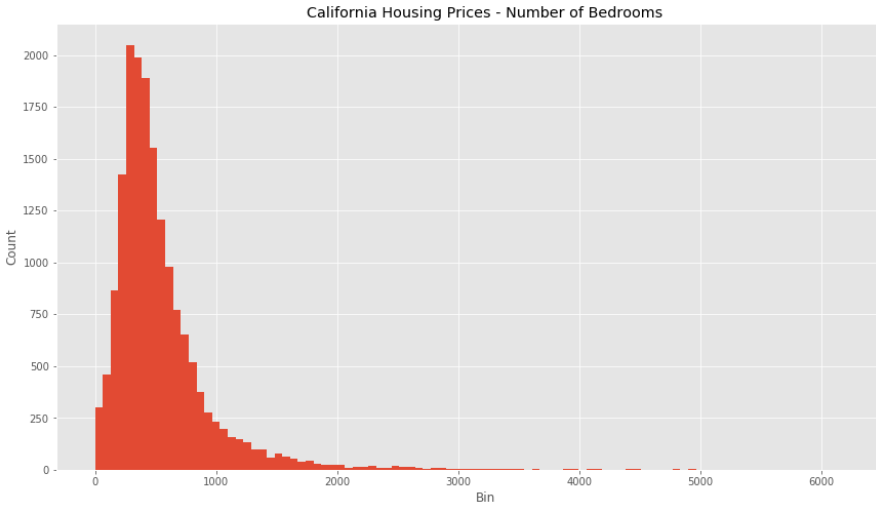
PS	Gewicht [kg]
130	2501
165	2140
140	2812
113	3400
150	2397

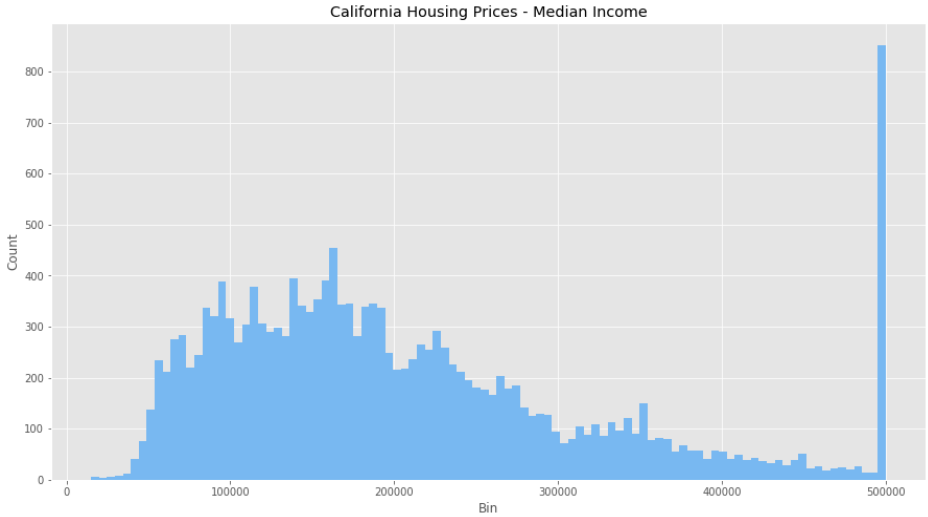
- Die Merkmale haben unterschiedliche Wertebereiche
- Varianz der Gewichte tendenziell größer und dominiert die berechneten Distanzen



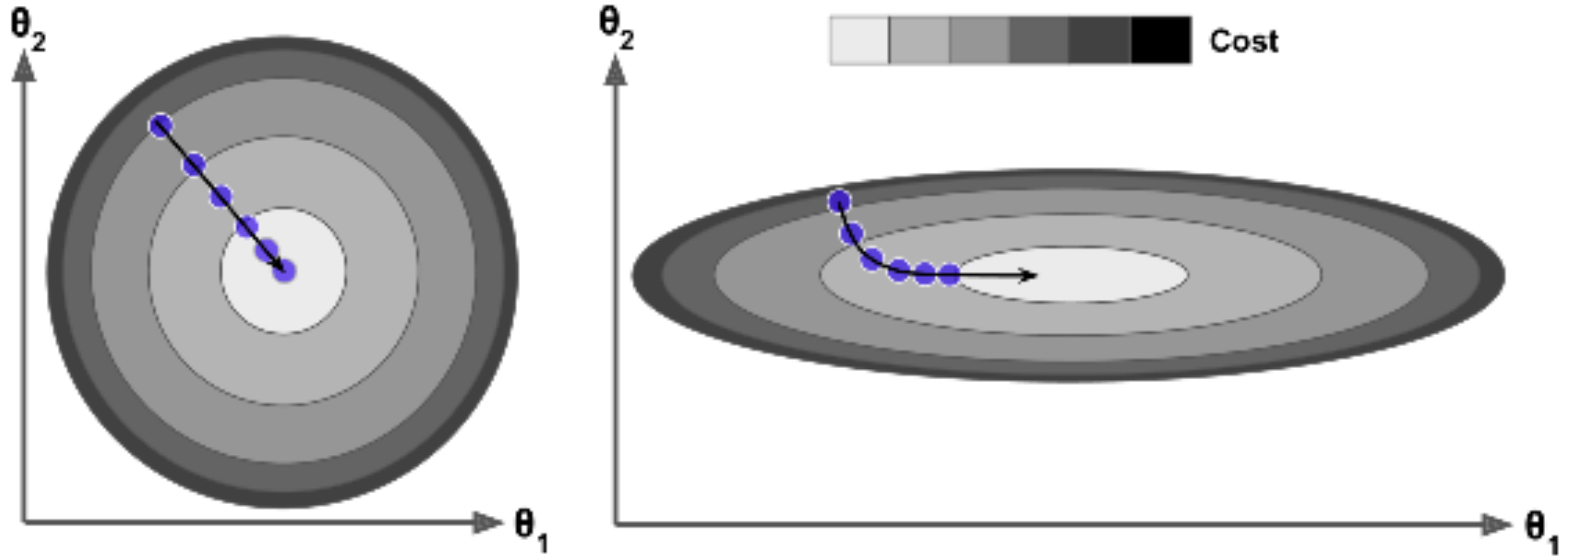
Wertebereich der Merkmale muss angepasst werden

Probleme bei unterschiedlichen Wertebereichen





Probleme bei unterschiedlichen Wertebereichen beim Gradientenabstieg



Kostenfunktion in Abhängigkeit der Gewichte. Links Merkmale skaliert, rechts unskaliert

Elongated Bowl



Min-Max-Normierung

- Min-Max-Normalisierung bildet Merkmale auf den Wertebereich [0,1] ab
- es seien x^k die beobachteten Werte des Merkmals $(k = 1, \dots K)$

$$\hat{x} = \frac{x - \min(x^k)}{\max(x^k) - \min(x^k)}$$

- der normalisierte Wert einer Beobachtung ist dann
  - Minimum wird auf 0 und Maximum wird auf 1 abgebildet
  - Normalisierung reagiert sensibel auf Ausreißer (outliers) in den Daten (z.B. Messfehler, fehlerhafte Eingaben)

Min-Max-Normalisierung

- Beispiel, 2d-Vektoren, k=4 :

$$\begin{bmatrix}-1\\2\end{bmatrix}, \begin{bmatrix}-0.5\\6\end{bmatrix}, \begin{bmatrix}0\\10\end{bmatrix}, \begin{bmatrix}1\\18\end{bmatrix}$$

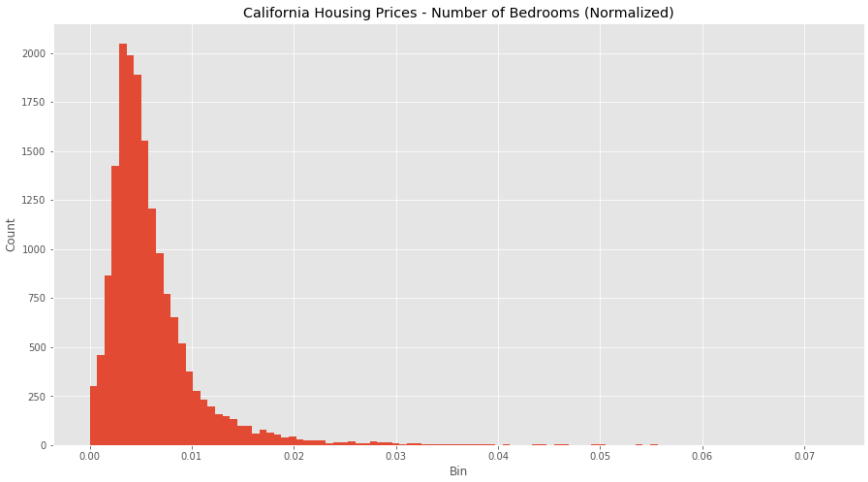
$$\widehat{x_d} = \frac{x_d - \min(x_d)}{\max(x_d) - \min(x_d)}$$

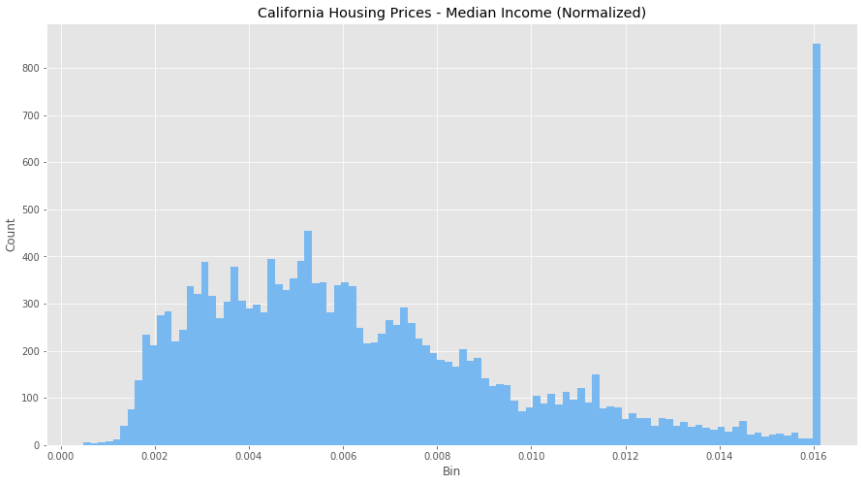
- $\min(x_1) = -1, \min(x_2) = 2$
- $max(x_1) = 1, \max(x_2) = 18$
- $\max(x_1) - \min(x_1) = 1 + 1 = 2$
- $\max(x_2) - \min(x_2) = 18 - 2 = 16$

- Normalisierte Vektoren:

$$\begin{bmatrix}0\\0\end{bmatrix}, \begin{bmatrix}0.25\\0.25\end{bmatrix}, \begin{bmatrix}0.5\\0.5\end{bmatrix}, \begin{bmatrix}1\\1\end{bmatrix}$$

Min-Max-Normalisierung





Standardisierung

- Standardisierten Werte sind mittelwertfrei und haben Standardabweichung von 1
- es seien x^k die beobachteten Werte des Merkmals $(k = 1, \dots K)$

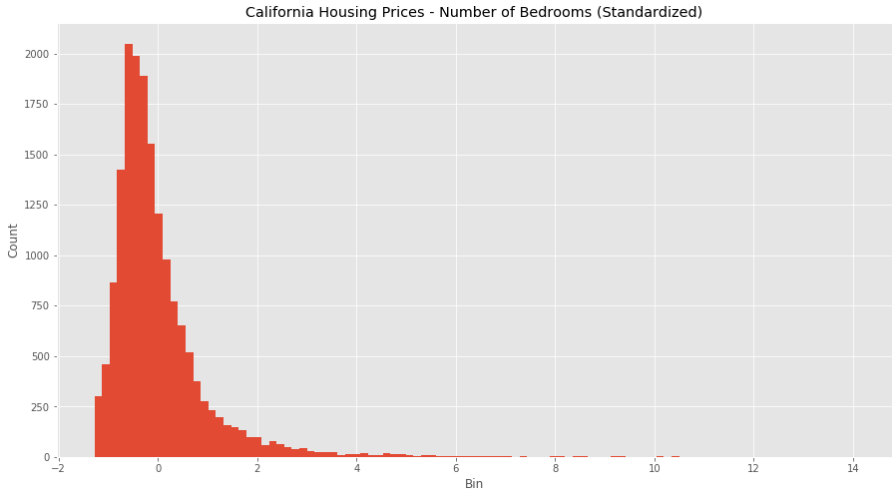
$$\hat{x} = \frac{x - \mu}{\sigma}$$

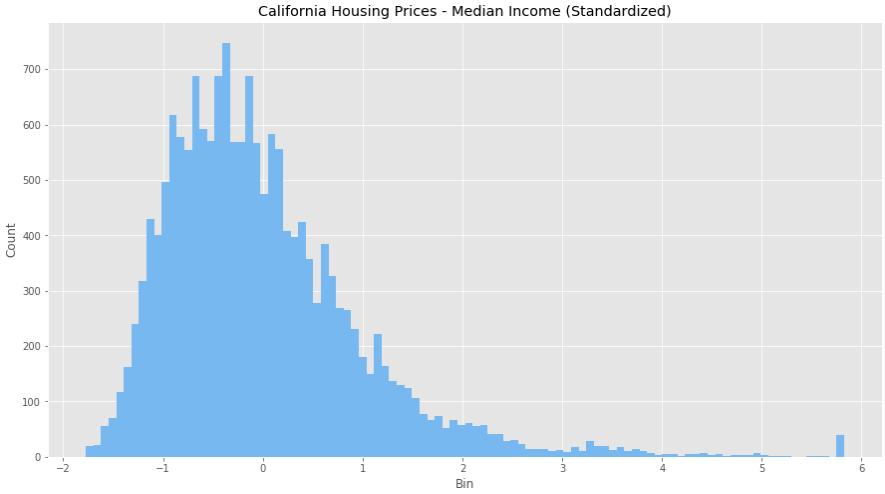
$$\mu = \frac{1}{K} \sum_{k=1}^{K} x^k$$

$$\sigma = \sqrt{\frac{1}{K} \sum_{k=1}^{K} (x^k - \mu)^2}$$

- μ und σ werden auf Trainingsstichprobe geschätzt
- Wird häufig z-Norm genannt

Standardisierung





Min-Max vs. Standardisierung

Aspekt	Min-Max-Normierung (z.B. 1)	Standardisierung (Z-Score)
Ziel	Alle Werte in einen festen Bereich schieben	Verteilung auf Mittelwert 0 und Standardabweichung 1 bringen
Formel	$x = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$	$x = \frac{x - \mu}{\sigma}$
Ergebnisbereich	Werte liegen in einem **festen, vorher definierten Intervall**, meist z.B. 1 oder –1, 1.	Werte liegen **theoretisch unbeschränkt**, in der Praxis meist ungefähr im Bereich –3, 3.
Empfindlichkeit gegenüber Ausreißern	hoch: Max- und Min-Werte legen den gesamten Bereich fest und beeinflussen alle anderen stark.	moderat: Ausreißer haben weiterhin extreme Werte, verzerren den Bereich aber nicht so stark wie bei Min-Max.
Wirkung auf Skalen	Merkmalsbereiche werden einheitlich, aber abhängig von Extremwerten.	Unterschiedliche Skalen werden „gleichwertig“, da Mittelwert und Standardabweichung genommen werden.
Typische Einsatzbereiche	Neuronale Netze, Bild-/Pixel-Daten, wenn ein klarer Eingangsbereich (z.B. 1) nötig ist.	Lineare Modelle, SVM, K-NN, PCA, Clustering, wenn Skalen unterschiedlich sind und Ausreißer möglich sind.

Zusammenfassung

- Erweiterung der Linearen Regression mit *PolynomialFeatures*
- Regularisierung zur Gewichtsbestrafung bei hochdimensionalen Merkmalvektoren
- Lasso- und Ridge-Regression: https://www.datacamp.com/tutorial/tutorial-lasso-ridge-regression

- Merkmalnormierung um Wertebereich der Merkmale anzupassen